Nombre del proyecto

Clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe: hacia un Índice de Madurez Normativa (IMN) escalable

Entregable: Guion del video de presentación final (15 minutos) · Proyecto Integrador en IA

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
Gladys María Villegas Rugel	Proyecto Integrador	8 de septiembre de 2026	25 de octubre de 2026

Resumen del Proyecto

Guion de grabación del video de 15 minutos que acompaña la presentación final del Proyecto Integrador: ficha técnica, escaleta con tiempos por diapositiva, cobertura de los elementos evaluados, texto completo por bloque con indicación de pantalla y notas de grabación. Cubre problema, datos, diseño experimental, resultados, operación, limitaciones y conclusiones del clasificador de normativa sobre IA del corpus GENIAL.

Responsables del proyecto

Nombre	Rol	Tareas
Jorge Javier Maldonado Mahauad	Líder de las Fases 1, 2 y 4. Enlace con GENIAL.	Problema y estado del arte; depuración del corpus, variable idioma y muestreo; doble codificación a ciegas y cálculo de κ.
Melissa Figallo	Líder de las Fases 3 y 5.	Rama clásica y rama LLM few-shot con comparación pareada; ética, agregación al IMN, documentación y pitch.

Guion del video de presentación final (15 minutos)

Proyecto Integrador en IA (MIAR0545) · Presentación final · Grupo 9 — Jorge Javier Maldonado Mahauad · Melissa Figallo · Tutora: Gladys María Villegas Rugel. Guion para grabar el video que acompaña la presentación *Grupo_9_Presentacion_Final.pptx* (18 diapositivas). Cada bloque indica la diapositiva, el minuto de inicio y fin, lo que aparece en pantalla y el texto que se lee en cámara. El mismo texto está en las notas del orador de cada diapositiva.

1. Ficha técnica

Duración	15:00 (18 diapositivas; la portada y el cierre ocupan 40 segundos en total).
Extensión del texto	2258 palabras · ritmo de lectura ≈ 150 palabras por minuto (académico, pausado). Si el ensayo supera los 15:30, recortar primero los bloques 6, 7 y 14 (los más densos); si queda corto, ampliar las pausas en las diapositivas con figuras (10 y 15).
Formato	Grabación de pantalla con la presentación a pantalla completa y cámara del expositor en recuadro (PowerPoint → Grabar presentación, o Zoom/Meet con grabación local). Exportar en 1080p, 30 fps, MP4 (H.264).
Reparto	Se sugiere alternar: Jorge bloques 1-8 y 15-18; Melissa bloques 9-14 (resultados). Cambiar de voz en los cambios de sección, no a mitad de bloque.
Registro	Académico, en primera persona del plural. Cifras siempre con su intervalo o su n cuando aparecen por primera vez. Nombrar la observación de la tutora en los bloques 3, 13 y 14 (multi-etiqueta) y las decisiones metodológicas 1-4 donde corresponda.
Materiales	Presentación (.pptx/.pdf), cuaderno ejecutado *02_experimento.ipynb* (.html), documento técnico, ficha de decisión técnica, repositorio *github.com/jorgemaldonadom-cmd/genial-clasificador-normativa*.

2. Escaleta

Tabla 1. Escaleta del video: diapositiva, tiempos, duración y palabras por bloque.

N.°	Diapositiva	Inicio	Fin	Duración	Palabras
1	Portada	0:00	0:30	30 s	79
2	Estructura de la presentación	0:30	1:00	30 s	72
3	El problema	1:00	2:00	60 s	114
4	Pregunta de investigación y objetivos	2:00	2:50	50 s	122
5	El corpus GENIAL	2:50	3:35	45 s	106
6	Lo que el EDA cambió	3:35	4:35	60 s	145
7	Diseño experimental: del corpus al índice	4:35	5:40	65 s	159
8	Decisión técnica	5:40	6:35	55 s	139
9	Resultados: el modelo aprende y supera las líneas base	6:35	7:35	60 s	146
10	Resultados por dimensión	7:35	8:35	60 s	147
11	Ablaciones y desempeño desagregado	8:35	9:35	60 s	151
12	Conjunto de prueba a ciegas	9:35	10:30	55 s	135
13	Diagnóstico de multi-etiqueta	10:30	11:20	50 s	122
14	La codificación ciega del investigador	11:20	12:25	65 s	164
15	Operación: codificación asistida, no automatización	12:25	13:25	60 s	143

N.°	Diapositiva	Inicio	Fin	Duración	Palabras
16	Contraste con los umbrales prefijados y limitaciones	13:25	14:10	45 s	117
17	Conclusiones y trabajo futuro	14:10	14:50	40 s	144
18	Cierre	14:50	15:00	10 s	53

3. Cobertura de los elementos evaluados

La presentación final se evalúa sobre el ciclo completo del proyecto. La tabla indica en qué bloque se cubre cada elemento, para verificar antes de grabar que ninguno queda fuera.

Elemento	Bloques	Evidencia que se muestra
Problema y contexto	3	Flujo del observatorio GENIAL; tres problemas de la codificación manual
Pregunta y objetivos	4	Pregunta de investigación; O1-O4; umbrales fijados antes de ejecutar
Datos y EDA	5, 6	813 normas, desbalance 4.7:1, texto corto; tres hallazgos que cambiaron el diseño
Selección de técnicas y arquitectura	7, 8	Diagrama del experimento; matriz comparativa de técnicas; justificación
Metodología y rigor	7, 9, 12	Conjunto ciego, CV por grupo, IC95, McNemar, κ; regla de ceguera
Resultados	9-14	CV, por clase, ablaciones, desagregación, prueba ciega, multi-etiqueta, codificación humana
Aplicación / operación	15	Curva de enrutamiento, regla de gobernanza, IMN trazable, codificación asistida
Evaluación crítica y limitaciones	16	Semáforo de criterios prefijados; limitaciones explícitas
Conclusiones y trabajo futuro	17	Tres conclusiones; cuatro líneas futuras
Reproducibilidad y ética de datos	5, 18	Hash del corpus, semilla, cuaderno ejecutado, licencias, corpus no redistribuible

4. Guion por diapositiva

Convenciones: **[pantalla]** describe lo que se ve; el texto en cuerpo normal es lo que se lee.

Diapositiva 1 · Portada · 0:00 – 0:30 (30 s)

[pantalla] Portada: título, autores, tutora, UEES, repositorio.

Buenas tardes. Somos Jorge Maldonado y Melissa Figallo, Grupo 9 de la Maestría en Inteligencia Artificial de la UEES. Presentamos el cierre de nuestro Proyecto Integrador: la clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe, un trabajo desarrollado sobre el corpus del proyecto GENIAL y orientado a construir un Índice de Madurez Normativa escalable. Agradecemos a nuestra tutora, la profesora Gladys Villegas, cuyas observaciones metodológicas cambiaron el diseño del experimento.

Diapositiva 2 · Estructura de la presentación · 0:30 – 1:00 (30 s)

[pantalla] Seis bloques numerados con minuto de inicio.

La presentación sigue el ciclo completo del proyecto. Primero el problema y los objetivos; luego los datos y lo que el análisis exploratorio nos enseñó; después el diseño experimental y la decisión técnica; el bloque central son los resultados, con su contraste frente a los umbrales que fijamos antes de ejecutar; y cerramos con la propuesta operativa para el observatorio, las limitaciones y las conclusiones. Todo es reproducible desde el repositorio público.

Diapositiva 3 · El problema · 1:00 – 2:00 (60 s)

[pantalla] Flujo norma → lectura → dimensión → IMN; tres tarjetas de problema; pregunta al pie.

El proyecto GENIAL, financiado por Erasmus+, mantiene un observatorio regional de normativa sobre inteligencia artificial en educación superior. Cada norma —una ley, una estrategia nacional, un reglamento universitario— es leída por un investigador y codificada en una de cinco dimensiones: Pedagógico, Ética, Administrativo, Protección de Datos y Técnico. El conteo por dimensión y país alimenta el Índice de Madurez Normativa.

Ese proceso tiene tres problemas. No escala: cada norma exige lectura y criterio experto, y el corpus crece con cada actualización. Depende de un solo codificador por norma, sin fiabilidad intercodificador medida. Y la etiqueta única fuerza decisiones difíciles cuando una norma toca dos dimensiones, algo que la tutora señaló desde la primera revisión.

Diapositiva 4 · Pregunta de investigación y objetivos · 2:00 – 2:50 (50 s)

[pantalla] Pregunta de investigación destacada; objetivos O1-O4; tabla de umbrales mínimo/excelencia.

La pregunta de investigación es: ¿con qué exactitud puede un clasificador automático asignar la dimensión de una norma a partir de su texto, y cómo se compara esa exactitud con el acuerdo entre codificadores humanos?

De ahí derivan cuatro objetivos: construir y evaluar dos técnicas distintas —una clásica supervisada y un modelo de lenguaje en modo few-shot— sobre un mismo conjunto de prueba a ciegas; medir el desempeño con intervalos de confianza y pruebas pareadas, no con cifras puntuales; diagnosticar el problema de la multi-etiqueta a partir de los errores; y especificar cómo se integraría el clasificador en la operación del observatorio sin que el índice quede a merced del modelo. Los umbrales de éxito se fijaron por escrito antes de ejecutar.

Diapositiva 5 · El corpus GENIAL · 2:50 – 3:35 (45 s)

[pantalla] Gráfico de barras de la distribución por dimensión; cuatro cifras clave; implicación de diseño.

Trabajamos con el corpus consolidado de GENIAL: 813 normas de 28 jurisdicciones, trece columnas por norma. La versión se congeló con un hash SHA-256 que el código verifica al cargar.

La variable objetivo está desbalanceada: 294 normas pedagógicas, 265 éticas, 120 administrativas, 71 de protección de datos y 63 técnicas; una razón de 4.7 a 1. El texto disponible es corto: título más observaciones del codificador, con una mediana de 44 palabras. Cinco países concentran dos tercios del corpus y muchas jurisdicciones tienen menos de 20 normas. Es el tamaño realista de un observatorio regional: suficiente para un modelo lineal regularizado, insuficiente para afinar un transformer.

Diapositiva 6 · Lo que el EDA cambió · 3:35 – 4:35 (60 s)

[pantalla] Tres hallazgos del EDA en tarjetas; tabla de decisiones de calidad de datos.

El análisis exploratorio, con pandas, matplotlib y seaborn, corrigió tres supuestos del plan. Primero, el idioma: 101 títulos están en portugués o inglés, pero las observaciones están en español en 798 de las 813 normas, porque las redactan los codificadores. Derivamos la variable idioma del título y anticipamos que sería un efecto de segundo orden.

Segundo, la pista léxica: la palabra que nombra la dimensión aparece en el texto en el 63 por ciento de las normas éticas y en el 73 por ciento de las de protección de datos. Decidimos medir el desempeño con y sin esa pista. Tercero, la metadata: el tipo de norma tiene una V de Cramér de 0.36 con la dimensión; la excluimos como predictor para evitar fugas y la convertimos en línea base. Y 14 grupos de normas con la misma URL se mantienen siempre en la misma partición.

Diapositiva 7 · Diseño experimental: del corpus al índice · 4:35 – 5:40 (65 s)

[pantalla] Diagrama «del corpus al índice»; tarjetas de rama clásica, rama LLM y evaluación; regla de ceguera.

El diseño compara dos ramas sobre idéntico conjunto de prueba. La rama clásica entrena una regresión logística sobre TF-IDF de uno y dos gramas, con cinco mil características y clases ponderadas, usando unas 670 normas etiquetadas. La rama LLM recibe las definiciones de las cinco dimensiones y quince ejemplos en el prompt, sin ajustar pesos, a temperatura cero y en tres ejecuciones.

Ambas se contrastan con dos líneas base sin inteligencia artificial: la clase mayoritaria, que fija el piso en 36 por ciento de exactitud, y la línea base de metadata sobre el tipo de norma. La evaluación es una sola: F1 macro y por clase con intervalos de confianza; McNemar entre ramas, porque el diseño es pareado; y kappa del modelo

frente a la referencia, comparable con el kappa entre dos humanos. Cada rama emite su primera y su segunda dimensión, lo que habilita el diagnóstico de multi-etiqueta. La validación cruzada es de cinco pliegues estratificados por grupo.

Diapositiva 8 · Decisión técnica · 5:40 – 6:35 (55 s)

[pantalla] Tabla comparativa de seis técnicas y decisión; recuadro sobre eficiencia de datos.

¿Por qué estas dos técnicas y no otras? En la Semana 2 comparamos ocho técnicas con una matriz de decisión ponderada. Los métodos tabulares —Random Forest, Gradient Boosting— quedaron descartados porque no hay variables numéricas nativas: la señal está en el vocabulario. Los transformers afinados como BETO o XLM-R exigen más datos de los que tenemos por clase minoritaria y ofrecen menos interpretabilidad. La regresión logística expone pesos por término y clase, entrega probabilidades calibradas para el umbral de confianza y entrena en segundos sin GPU. El LLM few-shot es la contraparte natural: mide eficiencia de datos, que es lo que decide si un observatorio puede automatizar sin financiar miles de horas de etiquetado. La literatura muestra que el desempeño relativo entre ambas depende del corpus; la única respuesta honesta era medirlo. La SVM lineal se incluyó como ablación.

Diapositiva 9 · Resultados: el modelo aprende y supera las líneas base · 6:35 – 7:35 (60 s)

[pantalla] Gráfico F1 macro de las cuatro alternativas; cifras 0.587 · 0.635 · 0.852 · 0.50; recuadro de lectura.

Vamos a los resultados. En validación cruzada por grupo sobre las 813 normas, la regresión logística alcanza una exactitud de 0.635 y un F1 macro de 0.587, con intervalo entre 0.55 y 0.62. La línea base de metadata obtiene 0.354 y la clase mayoritaria 0.107. El kappa frente a la referencia es 0.50, acuerdo moderado. Y la exactitud top-2 —la etiqueta correcta está entre las dos primeras propuestas— es de 0.852.

La lectura es doble. El modelo aprende algo real: casi duplica el F1 de la mejor línea base sin IA, y en el conjunto ciego McNemar rechaza la igualdad frente a ambas con valores p inferiores a 0.001 y de 0.012. Pero no alcanza el umbral de excelencia de 0.70: el intervalo incluye el mínimo de 0.60 y excluye el 0.70. Un umbral prefijado solo sirve si se respeta cuando el resultado no lo alcanza.

Diapositiva 10 · Resultados por dimensión · 7:35 – 8:35 (60 s)

[pantalla] Matriz de confusión y F1 por clase (figura del cuaderno); tres tarjetas por grupo de clases.

La matriz de confusión explica dónde se pierde el desempeño. Protección de Datos es la clase mejor reconocida, con F1 de 0.80: su vocabulario es específico y estable. Pedagógico y Ética están en 0.71 y 0.67, pero se confunden entre sí —57 normas pedagógicas se predicen como éticas y 49 en sentido contrario—, lo que coincide con la observación de la tutora: muchas normas pedagógicas tienen un componente ético explícito. Las dos clases minoritarias son el punto débil: Administrativo con 0.41 y Técnico con 0.35, por debajo del nivel de excelencia por clase, y Técnico incumple además el mínimo de 0.40. Técnico se dispersa hacia las otras cuatro: es una categoría definida por el objeto de la norma más que por un léxico propio, y con 63 ejemplos el modelo no consigue aislarla. El desbalance que el EDA identificó como riesgo principal es, efectivamente, la restricción dominante.

Diapositiva 11 · Ablaciones y desempeño desagregado · 8:35 – 9:35 (60 s)

[pantalla] Tabla de ablaciones (izq.) y tabla desagregada por idioma, ámbito y pista léxica (der.).

Las ablaciones varían una decisión a la vez. La más importante es la ponderación de clases: sin class_weight balanceado la exactitud casi no cambia, pero el F1 macro cae a 0.475 y Técnico prácticamente desaparece, con F1 de 0.03. La SVM lineal, la regularización más laxa, los unigramas solos y los n-gramas de caracteres se mueven todos entre 0.57 y 0.58: el resultado no depende de un hiperparámetro afortunado, sino del tamaño y del desbalance del corpus.

Desagregando, como exige la decisión metodológica cuatro: el español obtiene F1 de 0.61; el portugués 0.39 y el inglés 0.27, con 76 y 25 normas respectivamente. Las normas nacionales, más largas y heterogéneas, rinden peor que las institucionales. Y la pista léxica pesa: cuando la palabra que nombra la dimensión aparece en el texto la exactitud es 0.81; cuando no aparece, 0.54. El modelo generaliza, pero menos de lo que sugiere la cifra global.

Diapositiva 12 · Conjunto de prueba a ciegas · 9:35 – 10:30 (55 s)

[pantalla] Tabla de ramas sobre el conjunto ciego con IC95; tabla de McNemar; recuadro de lectura.

El conjunto ciego son exactamente las normas que el investigador de GENIAL codificó a ciegas: 125 con sus duplicados por URL, con las etiquetas leídas una única vez al final del cuaderno. Sobre él, la regresión logística obtiene exactitud de 0.69 y F1 macro de 0.62, con intervalo entre 0.51 y 0.71: compatible con la validación cruzada, aunque más alto, porque la muestra del investigador está dominada por normas de confianza alta y solo contiene diez normas técnicas. La SVM obtiene 0.65 de F1 macro; la diferencia no es significativa —McNemar da p de 0.13 sobre cuatro discordancias— y mantenemos la regresión logística por sus probabilidades calibradas. La rama LLM requiere una clave de API; el cuaderno la ejecuta y recalcula toda la comparación en cuanto la clave está disponible, antes del cierre del proyecto.

Diapositiva 13 · Diagnóstico de multi-etiqueta · 10:30 – 11:20 (50 s)

[pantalla] Cifras 39 · 23 · 59 %; tabla de la hoja de tipificación (tres tipos de error).

Aquí retomamos la observación de la tutora sobre la multi-etiqueta. De los 39 errores del modelo en el conjunto ciego, en 23 la segunda dimensión propuesta coincide con la etiqueta de referencia: el top-2 rescata el 59 por ciento de los errores, y el 85 por ciento en validación cruzada. Una parte sustantiva de los errores son normas en la frontera entre dos dimensiones. El cuaderno genera una hoja de tipificación con la referencia, la predicción y la alternativa para cada error; los codificadores de GENIAL clasifican cada caso como error genuino, segunda dimensión defendible o etiqueta original discutible. Así los errores del modelo se convierten en evidencia sobre la propia definición de las dimensiones, sin cambiar la tarea ni el índice.

Diapositiva 14 · La codificación ciega del investigador · 11:20 – 12:25 (65 s)

[pantalla] Cifras 76 % · 41 % · 0.89 vs 0.65 · 35/37; dos tarjetas: qué aporta el instrumento y robustez fuera de la versión congelada.

La codificación ciega del investigador de GENIAL nos permitió algo más que fijar el conjunto de prueba. Su instrumento registra seis dimensiones nuevas del framework, etiquetas secundarias y el nivel de confianza en cada norma. Cruzamos esa información con los errores del modelo. Con confianza alta del codificador, el modelo acierta el 76 por ciento; con confianza media, el 41: el modelo falla donde el humano también dudó. En las 19 normas sin etiquetas secundarias acierta el 89 por ciento; en las 100 con etiquetas secundarias, el 65, y 35 de los 37 errores caen en normas multidimensionales. Es la evidencia más directa de que la etiqueta única es una simplificación. El instrumento no recodifica la dimensión, así que el kappa humano-humano sigue pendiente. Y sobre 23 normas incorporadas después del corte, casi todas del Caribe anglófono, la exactitud cae a 0.39: fuera de la distribución de entrenamiento el modelo no es fiable, lo que justifica con datos la revisión obligatoria para esos segmentos.

Diapositiva 15 · Operación: codificación asistida, no automatización · 12:25 – 13:25 (60 s)

[pantalla] Curva enrutamiento-exactitud y diagrama de operación; cifras 0.50 · 84 % · 22/136 · 5→2; recomendación.

¿Puede el observatorio automatizar parte de la codificación? La curva de enrutamiento responde: para garantizar al menos 85 por ciento de exactitud en el tramo automático, el umbral de confianza debe ser 0.50, y con la regla completa —umbral, países con menos de 20 normas e idiomas minoritarios— el 84 por ciento de las normas va a revisión humana. La meta era 30 por ciento; el ahorro sería de 22 horas sobre 136 por pasada.

La conclusión operativa es codificación asistida, no automática: el modelo propone dos candidatas con su probabilidad, el codificador decide, y la tabla del índice registra por país cuántas normas tienen respaldo humano y cuántas solo del modelo, con un margen. El índice no queda a merced del modelo; el modelo reduce el espacio de decisión de cinco opciones a dos en el 85 por ciento de los casos.

Diapositiva 16 · Contraste con los umbrales prefijados y limitaciones · 13:25 – 14:10 (45 s)

[pantalla] Tabla semáforo de criterios prefijados (cumplido / en el borde / no alcanzado); lista de limitaciones.

Contrastamos cada resultado con el criterio prefijado. Superar ambas líneas base con significancia: cumplido. F1 macro mínimo de 0.60: en el borde, 0.587 en validación cruzada y 0.617 en el conjunto ciego. Excelencia de 0.70: no alcanzado. Ninguna clase bajo 0.40: incumplido por Técnico. Kappa de 0.60: no alcanzado, con 0.50 y 0.56. Enrutar menos del 30 por ciento con 85 por ciento de exactitud: no viable.

Las limitaciones: un solo codificador por norma en la referencia, así que parte del error puede ser desacuerdo legítimo; el kappa humano-humano sigue pendiente y la plantilla para obtenerlo está generada. Texto corto y en parte redactado por el codificador. Conjunto ciego pequeño. Y la rama LLM pendiente de ejecución.

Diapositiva 17 · Conclusiones y trabajo futuro · 14:10 – 14:50 (40 s)

[pantalla] Tres conclusiones en tarjetas; cuatro líneas de trabajo futuro.

Tres conclusiones. Primera: con 813 normas y texto corto, un modelo lineal interpretable aprende la estructura del framework GENIAL y supera con significancia a cualquier heurística sin IA, pero no alcanza la calidad necesaria para sustituir al codificador. Segunda: el valor del clasificador está en la asistencia —dos candidatas correctas en el 85 por ciento de los casos— y en el diagnóstico: sus errores señalan normas de frontera y dimensiones cuya definición conviene revisar. Tercera: los umbrales prefijados, los intervalos de confianza y las pruebas pareadas son lo que permite decir esto con rigor en lugar de celebrar una cifra.

Como trabajo futuro: cerrar la comparación con la rama LLM few-shot; incorporar la doble codificación para medir el techo humano; ampliar el texto de entrada con el cuerpo de la norma; y evaluar un esquema explícitamente multi-etiqueta cuando la tipificación de errores lo justifique.

Diapositiva 18 · Cierre · 14:50 – 15:00 (10 s)

[pantalla] Cierre: repositorio, reproducibilidad, agradecimientos.

Todo el código, el cuaderno ejecutado, las figuras, la síntesis de resultados y la documentación están en el repositorio público github.com/jorgemaldonadom-cmd/genial-clasificador-normativa, con licencia MIT para el código y una muestra anonimizada del corpus. Agradecemos al proyecto GENIAL por el acceso al corpus y a la profesora Gladys Villegas por su acompañamiento. Muchas gracias.

5. Notas de grabación

- Ensayar el guion completo al menos dos veces con cronómetro; anotar el minuto real al final de cada bloque y compararlo con la escaleta.
- En las diapositivas con figuras (10, 15) señalar con el cursor la celda o el punto que se menciona (confusiones Pedagógico ↔ Ética; umbral 0.50 en la curva).
- Pronunciar los decimales con punto («cero punto cinco ocho siete») y las siglas completas la primera vez (TF-IDF, LLM, IMN, κ «kappa»).
- Si la rama LLM se ejecuta antes de grabar, actualizar la fila «LLM few-shot» de la diapositiva 12, el punto 6 de la lectura del cuaderno y las frases correspondientes de los bloques 12 y 16.
- Si se obtiene la recodificación de Dominio del investigador (plantilla *results/coder2_labels_plantilla.csv*), el cuaderno calcula κ humano-humano al re-ejecutarse; actualizar entonces las diapositivas 14 y 16 y los bloques 14 y 16 del guion.
- Exportar también la presentación en PDF para adjuntarla al video; el cuaderno HTML se entrega como respaldo de todas las cifras.