Nombre del proyecto

Clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe: hacia un Índice de Madurez Normativa (IMN) escalable

Entregable: Análisis Exploratorio de Datos (EDA) del corpus — Semana 2

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
Gladys María Villegas Rugel	Proyecto Integrador	8 de septiembre de 2026	25 de octubre de 2026

Resumen del Proyecto

Análisis exploratorio del corpus consolidado GENIAL (813 normas × 13 columnas) con pandas, matplotlib y seaborn: estructura, valores faltantes, calidad de la metadata, distribuciones, idioma, longitud del texto y atípicos, asociaciones categóricas (V de Cramér), correlaciones, duplicados y vocabulario. Cada hallazgo se traduce en una decisión del pipeline de datos que sustenta la Ficha de Decisión Técnica.

Responsables del proyecto

Nombre	Rol	Tareas
Jorge Javier Maldonado Mahauad	Líder de las Fases 1, 2 y 4. Enlace con GENIAL.	Problema y estado del arte; depuración del corpus, variable idioma y muestreo; doble codificación a ciegas y cálculo de κ.
Melissa Figallo	Líder de las Fases 3 y 5.	Rama clásica y rama LLM few-shot con comparación pareada; ética, agregación al IMN, documentación y pitch.

Análisis Exploratorio de Datos del corpus GENIAL

Proyecto Integrador · Semana 2 · Grupo 9 — Jorge Javier Maldonado Mahauad · Melissa Figallo. Documento de respaldo de la Ficha de Decisión Técnica y Arquitectura. El cuaderno ejecutable que produce todas las cifras y figuras de este informe (*EDA_corpus_GENIAL.ipynb*, con su exportación HTML) se entrega junto con este documento y se versiona en el repositorio del proyecto.

1. Propósito, datos y herramientas

Este análisis caracteriza el corpus consolidado del observatorio GENIAL antes de modelar. Su función no es describir por describir: cada hallazgo se traduce en una decisión concreta del *pipeline* de datos —qué se limpia, qué se excluye, cómo se particiona— y en un argumento de la Ficha de Decisión Técnica. El EDA cubre los seis frentes que pide la ruta de actividades de la semana: estadísticas descriptivas, valores faltantes, distribuciones, valores atípicos, correlaciones (numéricas y, dado que el corpus es casi enteramente categórico, asociaciones entre variables categóricas) y, por tratarse de texto, vocabulario y posibles fugas de la etiqueta.

Datos. *consolidado_limpio.xlsx*, hoja «Datos limpios»: 813 normas × 13 columnas, 27 países de América Latina y el Caribe (28 jurisdicciones incluyendo Puerto Rico). Versión congelada con SHA-256 *f9797147…7f33*, verificada al inicio del cuaderno. La columna *Investigador* se anonimiza (C01-C10) en toda salida. **Herramientas.** pandas, numpy, matplotlib, seaborn y scipy; scikit-learn solo para describir el vocabulario con TF-IDF. **No se entrena ningún clasificador**: el EDA es descriptivo y el proyecto sigue en fase de planificación del experimento.

2. Estructura del dataset y estadísticas descriptivas

Las trece columnas son de tipo objeto (texto o categoría); el corpus no tiene variables numéricas nativas, así que las numéricas del EDA se derivan del texto. La variable objetivo es *Dominio* (cinco clases) y el texto de entrada del modelo será *Título de la Norma* + *Observaciones*.

Tabla 1. Estructura del corpus: valores únicos, faltantes y ejemplo por columna.

Columna	Únicos	Faltantes	Ejemplo de valor	Papel en el proyecto
Investigador	10	0	Alexandra Correa	Sesgo de codificador (agregado); excluida como predictora
País	28	0	República Dominicana	Estratificación y desagregación
Título de la Norma	791	0	Dec. núm. 278-22 que aprueba la Política Nacional de Innovación 2030.	Texto de entrada
Tipo de norma	14	0	Decreto	Línea base de metadata; excluida como predictora
Estado	3	2	Vigente	Caracterización
Organismo Emisor/Universidad	497	0	Presidente de la República Dominicana	Caracterización
Dominio	5	1	Administrativo	Variable objetivo
Vínculo con Educación	2	0	Indirecto	Caracterización / análisis de errores
Dedicación del Texto	5	0	Mención breve	Caracterización
Fecha de Publicación	428	2	2022-05-27	Excluida (heterogénea)
URL Oficial	797	0	https://presidencia.gob.do/decretos/278-22	Deduplicación y trazabilidad
Observaciones	798	1	Aprobación de la Política Nacional de Innovación 2030 (PNI). Se establ	Texto de entrada
Ámbito	2	0	Nacional	Caracterización / análisis de errores

3. Valores faltantes

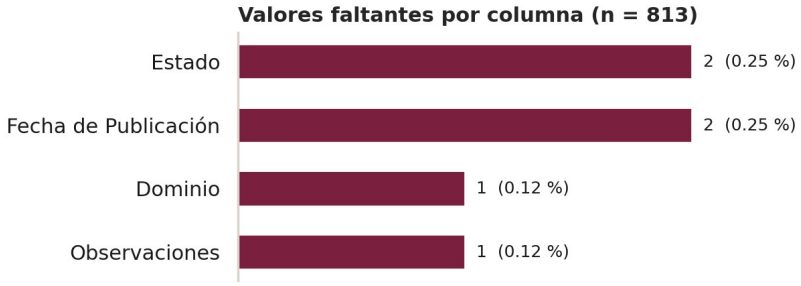


Figura 1. Valores faltantes por columna. Seis celdas vacías en 813 × 13; solo una afecta a la variable objetivo.

La completitud es alta: 6 celdas vacías en total. El único faltante relevante para el modelo es el de *Dominio* (una política de privacidad universitaria de Ecuador), que se corrige con criterio experto documentado —Protección de Datos— y no por imputación automática. El faltante de *Observaciones* deja a una norma con el título como único texto; los de *Estado* y *Fecha* no afectan al modelo.

4. Calidad de la metadata: fecha y tipo de norma

Fecha de Publicación es texto libre heterogéneo: 474 valores (58.3 %) se interpretan como fecha, 123 (15.1 %) declaran explícitamente que no la tienen («N/D», «s/f», «No indica») y 216 tienen formatos no interpretables (rangos, meses en texto, fechas parciales). Se excluye como variable; donde existe, el año confirma que el corpus es muy reciente: 74 normas de 2023, 104 normas de 2024, 193 normas de 2025, 64 normas de 2026.

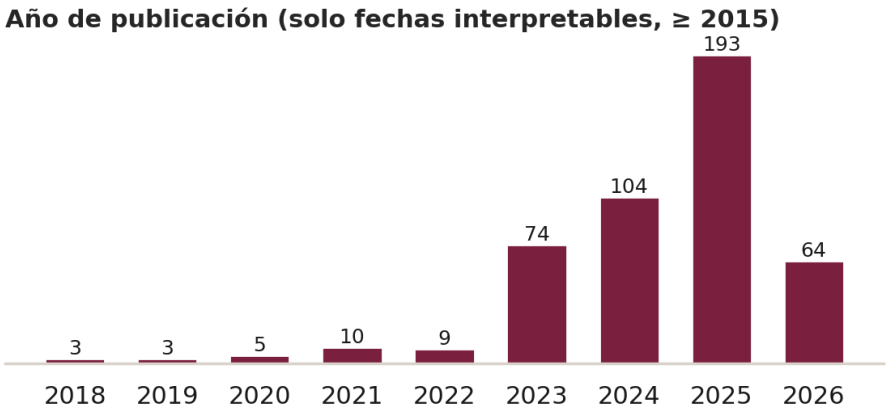


Figura 2. Año de publicación entre las fechas interpretables (≥ 2018). La normativa se concentra en 2023-2026.

Tipo de norma presenta 14 categorías crudas que se reducen a 11 al normalizar la capitalización («Estrategia Nacional» / «Estrategia nacional», «Lineamiento Académico» / «Lineamiento académico»). Tras normalizar: Lineamiento académico (137), Guía ética (126), Guía pedagógica (119), Resolución rectoral (110), Reglamento (93), Ley (89), y cinco categorías menores.

5. Distribuciones

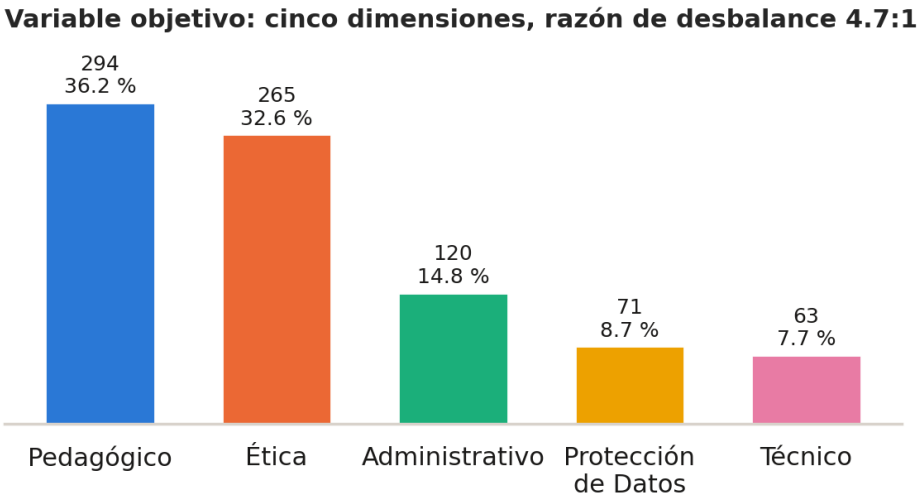


Figura 3. Variable objetivo. Razón de desbalance 4.7:1 entre Pedagógico (294) y Técnico (63).

El desbalance 4.7:1 impone F1 macro como métrica principal y ponderación de clases; dos dimensiones quedan por debajo de 75 casos. Piso aritmético de un predictor de clase mayoritaria, calculado sin entrenar nada: 36.2 % de exactitud y 0.106 de F1 macro.

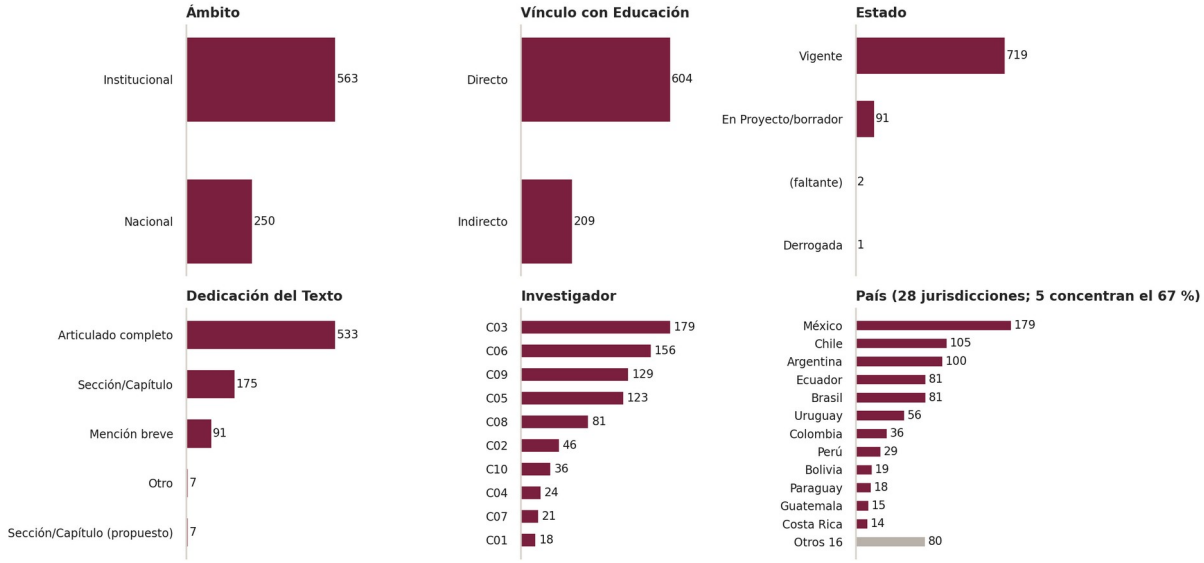


Figura 4. Variables categóricas. Ámbito, vínculo con la educación, estado, dedicación del texto, codificador (anonimizado) y país.

Cuatro hechos con consecuencia directa para el diseño: (1) el 69.2 % de las normas son institucionales —el corpus habla sobre todo de universidades, no de Estados—; (2) el 74.3 % tiene vínculo directo con la educación; (3) 28 jurisdicciones, de las que cinco reúnen el 67.2 % de las normas y 20 aportan menos de 20 cada una, lo que obliga a desagregar el desempeño por país y a exigir revisión humana en los países con pocas normas; (4) diez codificadores con cargas muy desiguales (entre 18 y 179 normas; los dos mayores codificaron el 41.2 % del corpus), lo que motiva medir la fiabilidad intercodificador.

6. Idioma del corpus

Tabla 2. Idioma detectado del título (filas) frente al de las observaciones (columnas). «indet.»: texto demasiado corto o ambiguo.

Título ↓ / Observaciones →	es	indet.	pt
en	12	6	0

Título ↓ / Observaciones →	es	indet.	pt
es	654	6	0
indet.	66	2	1
pt	66	0	0

Hallazgo principal del EDA

El corpus no es multilingüe de la manera que se había supuesto en la planificación. Los títulos conservan el idioma original (66 en portugués y 18 en inglés detectados), pero las *Observaciones* —la parte más larga del texto de entrada— están redactadas en español por los codificadores en 798 de 813 casos, incluidas las de Brasil y del Caribe anglófono. La variable *idioma* se deriva por tanto del título (con el país como respaldo cuando el título es demasiado corto): 712 normas en español, 76 en portugués y 25 en inglés.

Consecuencias: el riesgo de que la rama clásica sea «ciega» ante las normas no hispanohablantes es menor de lo previsto, porque siempre ve un resumen en español; subsiste una asimetría real —el título aporta señal en otro idioma— que justifica mantener la estratificación por idioma y las métricas desagregadas. La hipótesis del documento técnico se conserva pero se reformula: el idioma es un efecto de segundo orden, no el explicador principal de la eventual diferencia entre ramas.

7. Longitud del texto y valores atípicos

Tabla 3. Estadísticas descriptivas de las longitudes derivadas (palabras).

Variable	Media	Desv. est.	Mín.	P5	P25	Mediana	P75	P95	Máx.
Título	10.8	5.5	1	3	7	10	14	21	39
Observaciones	40	27.7	0	13.6	19	33	53	87	267
Texto de entrada (título + observaciones)	50.9	28.3	6	21	31	44	63	98.4	274

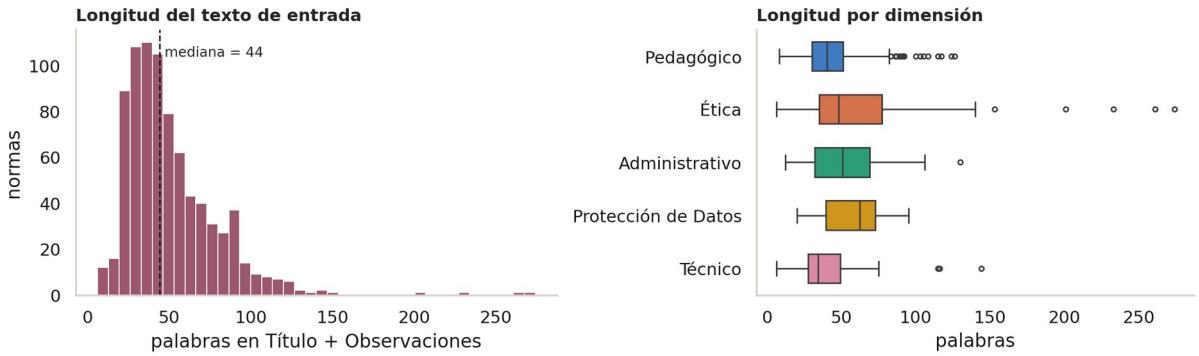


Figura 5. Longitud del texto de entrada: distribución (mediana 44 palabras) y comparación por dimensión.

Los textos son cortos —mediana 44 palabras, media 50.9— con cola derecha larga. La regla del rango intercuartílico marca 26 normas atípicamente largas (más de 111 palabras; máximo 274) y 10 tienen menos de 12 palabras. Los atípicos **no se eliminan**: son normas legítimas que el clasificador tendrá que procesar; se documentan y, en la rama LLM, no plantean problemas de contexto. La longitud difiere entre dimensiones (Kruskal-Wallis $H = 55.3$, $p < 0.001$), pero con distribuciones muy solapadas: la longitud por sí sola no discrimina la clase. La señal está en el vocabulario, no en el tamaño.

8. Asociaciones entre variables categóricas

Con un corpus casi enteramente categórico, la «matriz de correlaciones» pertinente es la de V de Cramér con corrección de sesgo, que mide la asociación entre pares de variables nominales en la escala 0-1.

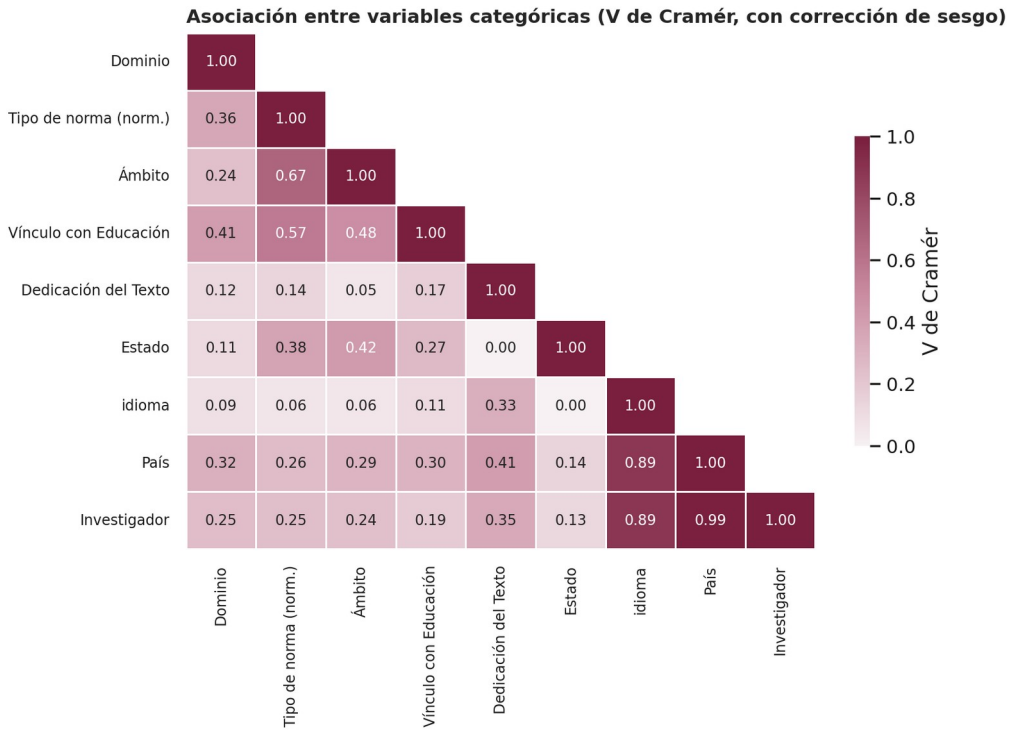


Figura 6. V de Cramér entre las variables categóricas del corpus (triángulo inferior).

Tabla 4. Asociación de cada variable con la dimensión (V de Cramér).

Variable	V con Dominio	Lectura
Vínculo con Educación	0.408	Las normas de vínculo indirecto concentran Técnico, Administrativo y Protección de Datos.
Tipo de norma (normalizado)	0.362	Guías pedagógicas → Pedagógico y guías éticas → Ética casi en su totalidad; base de la línea base de metadata.
País	0.320	Efecto combinado de qué países producen qué tipo de normativa y de qué codificador cubrió cada país.
Investigador	0.251	Cada codificador tiende a concentrar dimensiones; confundido con País (V = 0.989).
Ámbito	0.243	Las normas nacionales concentran Técnico y Administrativo; las institucionales, Pedagógico y Ética.
Dedicación del Texto	0.119	Asociación débil.
Estado	0.114	Asociación débil.
Idioma	0.086	Asociación débil: la dimensión no depende del idioma.

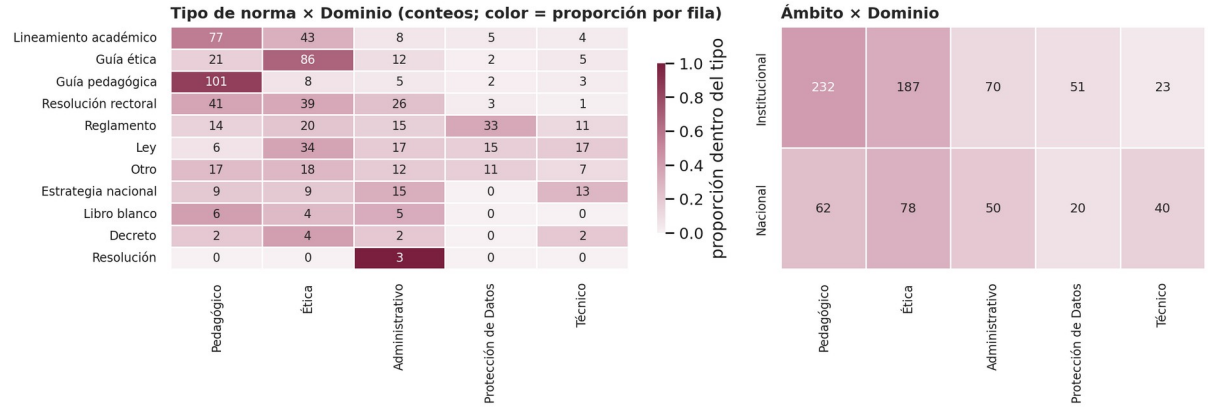


Figura 7. Tipo de norma × Dominio (conteos; color = proporción por fila) y Ámbito × Dominio.

Tabla 5. Dimensión modal y pureza por tipo de norma.

Tipo de norma	n	Dimensión modal	Pureza (proporción modal)
Lineamiento académico	137	Pedagógico	0.56
Guía ética	126	Ética	0.68
Guía pedagógica	119	Pedagógico	0.85
Resolución rectoral	110	Pedagógico	0.37
Reglamento	93	Protección de Datos	0.35
Ley	89	Ética	0.38
Otro	65	Ética	0.28
Estrategia nacional	46	Administrativo	0.33
Libro blanco	15	Pedagógico	0.40
Decreto	10	Ética	0.40
Resolución	3	Administrativo	1.00

La asociación de *Tipo de norma* con *Dominio* es exactamente la razón para excluirla como variable predictora: asignar el tipo a una norma nueva exige el mismo juicio experto que se busca automatizar, y un modelo que la usara parecería competente sin haber leído el texto. El EDA cuantifica lo que el documento técnico llamó «línea base de metadata», que el Sprint 2 medirá formalmente sobre el conjunto de prueba. La asociación de *Ámbito* y *Vínculo* anticipa que las normas nacionales serán más difíciles que las institucionales, y la de *País* con *Investigador* (V = 0.989) muestra que el sesgo geográfico y el sesgo de codificador están confundidos: no se podrán separar con estos datos.

9. Correlaciones entre variables numéricas derivadas

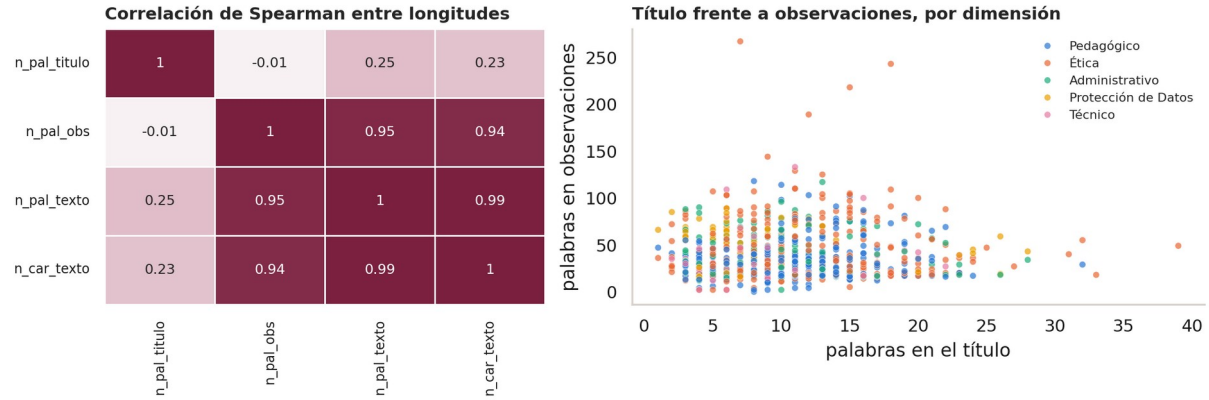


Figura 8. Correlación de Spearman entre las longitudes y relación título-observaciones por dimensión.

La longitud del título y la de las observaciones son prácticamente independientes (ρ de Spearman = -0.01); las medidas del texto combinado son redundantes entre sí. Ninguna correlación numérica sustituye a la señal léxica: el EDA confirma que el problema es de clasificación de texto corto y no de variables tabulares, lo que descarta desde ya las técnicas pensadas para datos estructurados como candidatas principales (véase el Análisis comparativo de algoritmos).

10. Duplicados y prevención de fuga entre particiones

Tras normalizar, hay 14 grupos de URL oficial repetida (30 normas) y 28 grupos de título repetido (64 normas). De los grupos por URL, 6 comparten la misma dimensión —candidatos a duplicado real— y 8 tienen dimensiones distintas: documentos diferentes alojados en la misma página, o una misma norma codificada de forma distinta

por dos personas, que es justamente el fenómeno que el proyecto quiere medir. Decisión para el *pipeline*: los registros con la misma URL se mantienen siempre en la misma partición (muestreo por grupo), y los grupos con dimensiones distintas se revisan a mano como candidatos a multi-etiqueta.

11. Vocabulario por dimensión y pista léxica de la etiqueta

Tabla 6. Términos (1-2 gramas TF-IDF, vocabulario de 2421 términos) que más caracterizan a cada dimensión frente al resto.

Dimensión	Términos más característicos
Pedagógico	guía, generativa, aprendizaje, orientaciones, enseñanza, aula, chatgpt, artificial generativa, ia generativa, docente, docentes, lineamientos
Ética	ética, ético, uso, uso ético, principios, éticos, integridad, transparencia, código, establece principios, ético inteligencia, uso ia
Administrativo	resolución, 2025, mediante resolución, política, gestión, ecuador, pública, aprueba, innovación, transformación, unne, 2030
Protección de Datos	datos, personales, datos personales, privacidad, tratamiento, protección, protección datos, tratamiento datos, sin, articulado, política privacidad, fecha
Técnico	ley, nacional, capacidades, robótica, desarrollo, políticas, sistemas, digital, país, políticas públicas, implementación, públicas

El vocabulario separa bien a Protección de Datos y a Pedagógico; Ética y Administrativo comparten términos de gobernanza, una razón temprana para esperar confusión entre ambas y la hipótesis de partida del diagnóstico de multi-etiqueta.

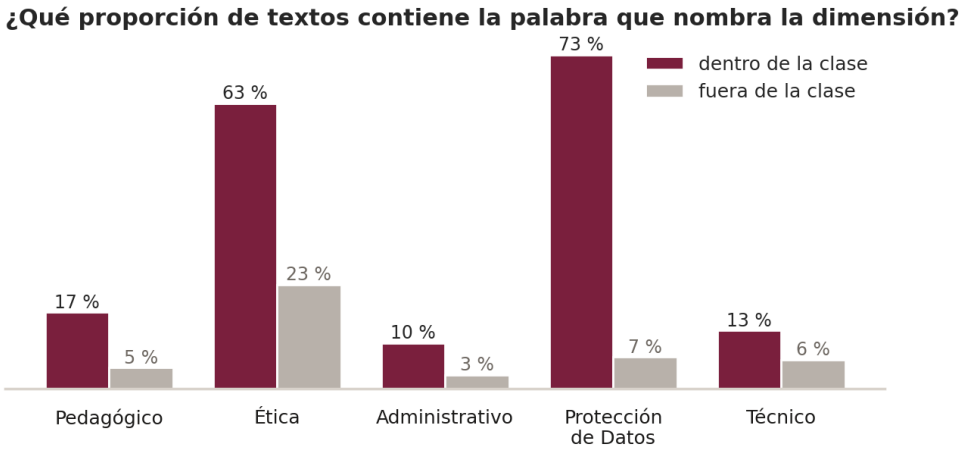


Figura 9. Proporción de textos que contienen la palabra que nombra su dimensión, dentro y fuera de la clase.

Tabla 7. Pista léxica de la etiqueta por dimensión.

Dimensión	Textos de la clase con la pista	% dentro de la clase	Textos de otras clases con la pista	% fuera de la clase
Pedagógico	49	16.7 %	24	4.6 %
Ética	166	62.6 %	125	22.8 %
Administrativo	12	10 %	21	3 %
Protección de Datos	52	73.2 %	51	6.9 %
Técnico	8	12.7 %	47	6.3 %

La palabra que nombra la dimensión aparece con frecuencia en los textos de su clase —«ética» en el 63 % de las normas éticas, «datos personales» o «privacidad» en el 73 % de las de Protección de Datos— pero también fuera de ella. No es una fuga en sentido estricto, porque el resumen describe legítimamente el contenido de la

norma, pero sí una **pista superficial que un modelo de bolsa de palabras explotará.** Se controlará en el análisis de errores: si los aciertos de la rama clásica se concentran en los textos con la pista, el modelo está leyendo la etiqueta y no el contenido.

12. Hallazgos e implicaciones para el pipeline

Tabla 8. Del hallazgo a la decisión de preprocesamiento o de diseño.

#	Hallazgo del EDA	Decisión de preprocesamiento / diseño
1	Un faltante en Dominio, cinco en otras columnas	Corrección experta documentada (Protección de Datos); sin imputación automática
2	Fecha de Publicación heterogénea: solo el 58 % interpretable	Excluida como variable; heterogeneidad reportada como hallazgo de calidad
3	Tipo de norma con 14 → 11 categorías; V = 0.36 con Dominio y pureza alta en guías	Normalización; excluida como predictora (fuga de información); línea base de metadata en el Sprint 2
4	Desbalance 4.7:1; Técnico y Protección de Datos < 75 casos	F1 macro como métrica principal; class_weight balanceado; umbral mínimo de F1 por clase
5	Cinco países = 67 %; 20 jurisdicciones con < 20 normas	Métricas por país; revisión humana obligatoria para países subrepresentados
6	Títulos en idioma original (76 pt, 25 en) pero observaciones en español casi siempre	Variable idioma derivada del título; estratificación por dimensión e idioma; idioma como efecto de segundo orden
7	Textos cortos (mediana 44 palabras), cola larga, longitud poco discriminante	TF-IDF 1-2 gramas suficiente; ningún texto excede el contexto del LLM; atípicos conservados
8	Ámbito y Vínculo asociados con la dimensión; Ética y Administrativo comparten vocabulario	Análisis de errores por ámbito; frontera Administrativo-Ética como hipótesis del diagnóstico de multi-etiqueta
9	14 grupos de URL repetida; 8 con dimensiones distintas	Muestreo por grupo de URL (misma partición); revisión manual de los grupos discordantes
10	Pista léxica de la etiqueta dentro y fuera de cada clase	Control en el análisis de errores: desempeño con y sin la pista
11	Diez codificadores con cargas desiguales y confundidos con el país (V = 0.99)	Doble codificación ciega; Investigador excluido como predictor y anonimizado

Estas decisiones están implementadas en *src/genial_clf/data.py* y *split.py* del repositorio *github.com/jorgemaldonadom-cmd/genial-clasificador-normativa* y constituyen el punto de conexión entre el EDA y la Ficha de Decisión Técnica: el clasificador recibe un texto corto en español con título en idioma original, sin metadata predictora, particionado por grupo de URL y estratificado por dimensión e idioma.