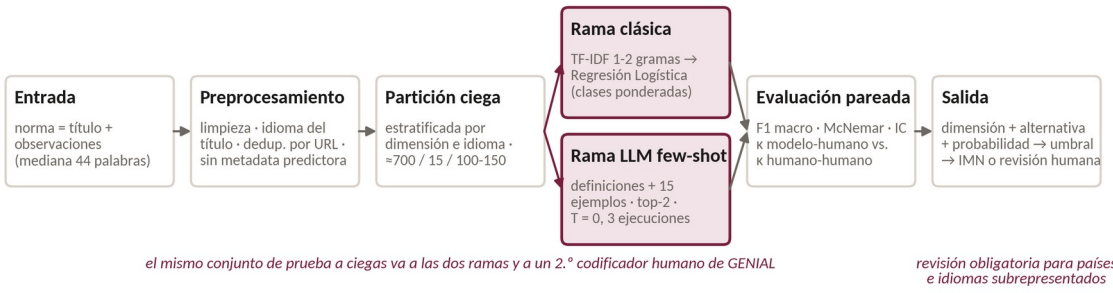
Ficha de Decisión Técnica y Arquitectura

Proyecto Integrador en IA (MIAR0545) · Unidad 2 · Semana 2 · Grupo 9 · Docente: Gladys María Villegas Rugel

Estudiantes: Jorge Javier Maldonado Mahauad · Melissa Figallo	**Proyecto:** Clasificación automática de normativa sobre IA en educación superior de ALC: hacia un Índice de Madurez Normativa (IMN) escalable — corpus GENIAL (Erasmus+)	**Fecha:** 21 de septiembre de 2026

Técnicas de IA seleccionadas	**1 · Regresión Logística sobre TF-IDF (rama clásica y línea base).** Modelo lineal multiclase sobre 1-2 gramas (≈5 000 características) con clases ponderadas y validación cruzada estratificada; entrena con ≈700 normas etiquetadas y devuelve probabilidad y segunda dimensión (top-2). **2 · Modelo de lenguaje de gran escala en modo *few-shot* (rama de comparación).** *Prompt* con las definiciones de las cinco dimensiones del framework GENIAL y 15 ejemplos codificados (3 por dimensión), sin ajuste de pesos; devuelve primera y segunda dimensión; temperatura 0 y tres ejecuciones para medir estabilidad. Ambas se comparan sobre **idéntico conjunto de prueba a ciegas** y frente a dos líneas base sin IA (clase mayoritaria: 36.2 % de exactitud y 0.106 de F1 macro; línea base de metadata sobre *Tipo de norma*). La SVM lineal se ejecuta como ablación de la rama clásica; los transformers afinados y los agentes quedan como trabajo futuro (Análisis comparativo, §3.6 y §3.8).
Justificación · tipo de problema	Clasificación supervisada multiclase (5 dimensiones, etiqueta única) sobre **texto no estructurado y corto**: título + observaciones, mediana de 44 palabras (EDA §7). El mapa de estimadores de scikit-learn conduce, para < 100 000 muestras de texto etiquetado, a los clasificadores lineales como primer intento; la literatura del dominio muestra que el desempeño relativo del LLM *few-shot* frente al lineal depende del corpus hasta invertirse (97 % en PolicyGPT frente a 47.6 % en LexGLUE), así que la única respuesta honesta es medirlo en este corpus. Se descartan las técnicas tabulares (Random Forest, Gradient Boosting): el EDA confirma que no hay variables numéricas nativas y que la señal está en el vocabulario, no en la longitud ni en la metadata.
Justificación · datos y recursos	813 normas con desbalance 4.7:1 y dos clases con menos de 75 casos: suficiente para un modelo lineal regularizado, insuficiente para afinar un transformer o entrenar una red profunda sin alta varianza (Análisis comparativo §3.5-3.6). El LLM *few-shot* opera con 15 ejemplos: la comparación mide **eficiencia de datos**, que es lo que decide si un observatorio puede automatizar sin financiar miles de horas de etiquetado. Recursos: dos portátiles sin GPU, siete semanas, API con costo estimado inferior a USD 5 por pasada completa del corpus; el modelo clásico entrena en segundos y no tiene costo.
Justificación · interpretabilidad	Los codificadores de GENIAL exigen saber *por qué* se propone cada dimensión y la coordinación necesita un índice auditable que compara países. La regresión logística expone pesos por término y clase; el LLM devuelve la alternativa y puede justificar en lenguaje natural. Ambas emiten top-2, lo que permite tipificar cada error como error genuino, segunda dimensión defendible o etiqueta original discutible (diagnóstico de multi-etiqueta pedido por la tutora) y entregar al codificador humano dos candidatas en lugar de una adivinanza. Un transformer afinado o un agente ofrecerían menos explicación por más costo.

Arquitectura / flujo propuesto



El flujo retoma el *pipeline* construido en el EDA: corrección experta del único faltante de *Dominio*, normalización de *Tipo de norma* (14 → 11 categorías) y su exclusión como variable predictora, variable *idioma* derivada del título (el EDA mostró que las observaciones están en español incluso para Brasil y el Caribe), deduplicación por URL con muestreo por grupo, y partición estratificada por dimensión e idioma. Formato de entrada: cadena UTF-8 «título. observaciones»; salida: JSON con dimensión, alternativa y probabilidad. Implementado en *src/genial_clf/* del repositorio *github.com/jorgemaldonadom-cmd/genial-clasificador-normativa*.

Riesgos y mitigación	**Sobreajuste y potencia estadística** (813 normas, prueba de 100-150): regularización L2 y *class_weight* balanceado; curvas de validación; McNemar e intervalos de confianza en lugar de diferencias puntuales; si no hay significancia, el resultado se reencuadra como eficiencia de datos. **Pista léxica de la etiqueta** (EDA §11: «ética» aparece en el 63 % de las normas éticas): análisis de errores con y sin la pista. **Techo del estándar de referencia** (un solo codificador por norma): doble codificación ciega y κ humano-humano como referente. **Inestabilidad y costo del LLM**: temperatura 0, *prompt* versionado, tres ejecuciones, modelo abierto como alternativa.
Conclusión	Un lineal interpretable que aprende de ≈700 normas frente a un LLM que opera con 15, medidos sobre el mismo conjunto ciego y contra el acuerdo humano: la decisión responde al problema del observatorio —escalar la codificación sin perder el control experto— porque mide si conviene automatizar, con cuánta confianza y con qué explicación.

Esta ficha retoma y sintetiza dos entregables de la Semana 2 del mismo equipo: el **Análisis comparativo de algoritmos** (ocho técnicas, matriz de decisión ponderada) y el **Análisis Exploratorio de Datos** del corpus GENIAL (cuaderno ejecutable e informe de 11 hallazgos). Se reutilizará como sección «Selección de Técnicas y Arquitectura» del Documento de Alcance y de la Presentación Final.