Nombre del proyecto

Clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe: hacia un Índice de Madurez Normativa (IMN) escalable

Entregable: Workshop: Impacto Social y Responsabilidad en el Proyecto de IA · Semana 4 · Proyecto Integrador en IA

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
Gladys María Villegas Rugel	Proyecto Integrador	8 de septiembre de 2026	25 de octubre de 2026

Resumen del Proyecto

Análisis sistemático de impacto social y responsabilidad del clasificador de normativa sobre IA del corpus GENIAL: contexto, siete grupos de stakeholders, impactos positivos y negativos, auditoría de equidad por jurisdicción, seis riesgos éticos con evidencia, estrategias de mitigación, framework de responsabilidad, compliance (RGPD, LOPDP, Ley de IA de la UE, UNESCO) y compromiso ético; anexos con model card y datasheet.

Responsables del proyecto

Nombre	Rol	Tareas
Jorge Javier Maldonado Mahauad	Líder de las Fases 1, 2 y 4. Enlace con GENIAL.	Problema y estado del arte; depuración del corpus, variable idioma y muestreo; doble codificación a ciegas y cálculo de κ.
Melissa Figallo	Líder de las Fases 3 y 5.	Rama clásica y rama LLM few-shot con comparación pareada; ética, agregación al IMN, documentación y pitch.

Impacto social y responsabilidad en el proyecto de IA: clasificador de normativa sobre IA en educación superior (corpus GENIAL)

Proyecto Integrador en IA (MIAR0545) · Semana 4 · Workshop «Impacto Social y Responsabilidad en Tu Proyecto de IA» · Grupo 9 — Jorge Javier Maldonado Mahauad · Melissa Figallo · Tutora: Gladys María Villegas Rugel. El análisis sigue las ocho partes del workshop y se apoya en evidencia del propio proyecto (experimento, diagnóstico de la Semana 3 y una auditoría de equidad por jurisdicción ejecutada para esta actividad: *scripts/fairness_grupos.py*). Los anexos contienen la *model card* y la *datasheet* del sistema, incorporadas al repositorio público.

Parte 1. Contexto del proyecto

1.1 Descripción del sistema

Problema que resuelve	El observatorio del proyecto GENIAL (Erasmus+) codifica a mano cada norma sobre inteligencia artificial en educación superior de América Latina y el Caribe en una de cinco dimensiones (Pedagógico, Ética, Administrativo, Protección de Datos, Técnico); el conteo por dimensión y país alimenta el Índice de Madurez Normativa (IMN). La codificación manual no escala, depende de un solo codificador por norma y no tiene fiabilidad intercodificador medida.
Funcionalidad principal	A partir del texto de la norma (título + observaciones) propone la dimensión más probable y una segunda candidata (top-2) con su probabilidad; una regla de gobernanza envía a revisión humana obligatoria las predicciones de baja confianza y todas las normas de países e idiomas subrepresentados; la tabla del IMN registra cuántas normas de cada país tienen respaldo humano y cuántas solo del modelo. Modelo: regresión logística sobre TF-IDF (rama clásica); rama de comparación con un LLM *few-shot*.
Usuarios objetivo	Los investigadores codificadores de GENIAL (usuarios directos) y la coordinación del observatorio (usa el IMN y la estimación de carga). Indirectamente, quienes consumen el IMN: ministerios, agencias de acreditación, universidades y organismos regionales.
Dominio de aplicación	Política pública y gobernanza de la IA en educación superior; análisis documental de normativa (texto corto, multilingüe: español 88 %, portugués 9 %, inglés 3 %).

1.2 Alcance de implementación

Dónde. En el flujo de trabajo del observatorio GENIAL, como herramienta interna de codificación asistida; el código es público (MIT), el corpus no. **A cuántas personas afecta.** Directamente a los ≈10 codificadores y al equipo de coordinación; indirectamente, a los decisores de las 28 jurisdicciones cuyo IMN se publique y, en última instancia, a estudiantes y docentes de la región cuya normativa se compara (más de 30 millones de estudiantes de educación superior en América Latina y el Caribe). **Qué decisiones toma o informa.** No toma decisiones sobre personas: propone una etiqueta documental que un humano confirma, e informa un índice comparativo entre países. Ese índice sí puede influir en decisiones de política, financiamiento y reputación institucional, y ahí reside el impacto social relevante.

Parte 2. Análisis de stakeholders

Tabla 1. Stakeholders del sistema: descripción, beneficios, riesgos y poder/voz.

Stakeholder	Descripción	Beneficios	Riesgos	Poder/Voz
1 · Codificadores de GENIAL	≈10 investigadores que leen y codifican las normas; usuarios directos	menos tiempo por norma; dos candidatas en vez de cinco; criterios explícitos y trazables	automatización excesiva (sesgo de automatización); desvalorización del juicio experto; su nombre es dato personal en el corpus	Medio
2 · Coordinación del observatorio GENIAL	equipo que publica el IMN y gestiona el corpus (coordinación general en Toulouse, nacional en Cuenca)	escalabilidad, consistencia, estimación de carga; evidencia sobre la definición del framework	responsabilidad por un índice con errores no comunicados; dependencia de un proveedor externo de LLM	Alto
3 · Decisores y IES de los países	ministerios, agencias, universidades	diagnóstico comparable y	clasificación errónea que subestime su	Medio-Bajo (no

Stakeholder	Descripción	Beneficios	Riesgos	Poder/Voz
comparados	cuya normativa se cuenta y compara (sujetos indirectos de la decisión)	actualizado de su marco normativo	madurez; uso reputacional del ranking	participan en el diseño)
4 · Jurisdicciones pequeñas y no hispanohablantes	Caribe anglófono, Haití, Brasil, países con < 20 normas (grupo vulnerable)	visibilidad en un índice regional que suele omitirlos	peor desempeño del modelo (exactitud 0.38 en el Caribe frente a 0.67 en Hispanoamérica) → invisibilización o distorsión	Bajo
5 · Estudiantes y docentes de ALC	beneficiarios finales de una mejor normativa sobre IA en sus instituciones	políticas mejor informadas por evidencia regional	ninguno directo; indirecto si el índice orienta mal la política	Bajo
6 · Comunidad académica y público	usuarios del repositorio abierto, otros observatorios	método replicable, muestra abierta, documentación	reutilización fuera de contexto; expectativas de exactitud que el modelo no cumple	Medio
7 · Proveedor del LLM (tercero)	empresa cuya API clasifica en la rama *few-shot*	ingreso por uso	recibe textos de normas públicas (no personales); cambios de modelo rompen reproducibilidad	Alto sobre la rama LLM

Cómo afecta el sistema a cada grupo, si fue considerado y cómo se protegen sus intereses. Los **codificadores** fueron el centro del diseño: el modo asistido, el top-2 y la hoja de tipificación de errores nacen de sus necesidades (saber *por qué* se propone una dimensión y poder discrepar); su protección pasa por la decisión final humana, la anonimización de su nombre en toda publicación y por no usar el modelo para evaluar su trabajo (el efecto codificador está confundido con el país, V de Cramér 0.99). La **coordinación** participó en la autorización del corpus y recibe el IMN con trazabilidad (respaldo humano vs. modelo) y margen. Los **decisores de los países** no fueron consultados —es una limitación—; su interés se protege publicando el índice solo con revisión humana, con margen de incertidumbre y con la metodología abierta. Las **jurisdicciones pequeñas y no hispanohablantes** fueron consideradas desde la decisión metodológica 4 (desagregar por idioma y país) y están protegidas por la regla de revisión obligatoria, que la auditoría de esta semana confirma y amplía (Parte 5). **Estudiantes y docentes** no interactúan con el sistema; su interés se atiende evitando que un índice distorsionado oriente políticas. La **comunidad** recibe código MIT, muestra anonimizada, *model card* y *datasheet*. El **proveedor del LLM** está sujeto a prompt versionado, registro de la versión exacta y alternativa con modelo abierto.

Parte 3. Evaluación de impacto social

3.1 Impactos positivos

1. **Escalabilidad y sostenibilidad del observatorio.** *Descripción:// el modelo reduce el espacio de decisión de cinco a dos opciones en el 85 % de las normas (top-2) y permite estimar la carga residual de cada actualización.* Beneficiados:// codificadores y coordinación GENIAL; a mediano plazo, los países, porque un observatorio sostenible se actualiza. *Evidencia:// con la regla de gobernanza, 21 de 136 horas-persona por pasada se ahorran hoy; el ahorro crece si mejora el modelo o se relaja el umbral para países bien representados.*
2. **Consistencia, trazabilidad y mejora del propio framework.** *Descripción:// criterios de codificación explícitos (pesos por término, probabilidades), registro de qué normas tienen respaldo humano, y una hoja de tipificación que convierte los desacuerdos modelo-humano en evidencia sobre normas de frontera.* Beneficiados:// coordinación y comunidad académica. *Evidencia:// 35 de los 37 errores del modelo caen en normas que el investigador marcó como multidimensionales; el 84 % de las normas releídas recibieron etiquetas secundarias. El sistema hace visible que la etiqueta única es una simplificación y empuja a GENIAL a revisar su framework.*
3. **Democratización del método y transferencia de capacidades.** *Descripción:// repositorio público con código MIT, muestra anonimizada, cuadernos ejecutados,* model card *y* datasheet*: cualquier observatorio (CEPAL, OCDE, redes universitarias) puede replicar el pipeline sobre su propio corpus.* Beneficiados://

comunidad académica, otros observatorios, estudiantes de la maestría. *Evidencia:// [1]–[3]; el proyecto GENIAL tiene entre sus objetivos la generación de capacidades de IA en instituciones de educación superior de la región.*

4. **Visibilidad de jurisdicciones habitualmente omitidas.** *Descripción:// el corpus incluye 13 jurisdicciones del Caribe y Centroamérica con menos de 20 normas, ausentes de la mayoría de índices regionales [4].* Beneficiados:// esas jurisdicciones y sus IES. *Evidencia:// el sistema las trata explícitamente (revisión obligatoria) en lugar de ignorarlas, y la auditoría cuantifica su situación.*

3.2 Impactos negativos y riesgos

Tabla 2. Impactos negativos y riesgos sociales del sistema.

Riesgo / impacto negativo	Descripción	Grupos vulnerables	Severidad	Probabilidad
R1 · Sesgo geográfico y lingüístico en el IMN	El modelo acierta 67 % en Hispanoamérica continental, 47 % en Brasil y 38 % en el Caribe; en títulos en inglés 36 %. Sin salvaguardas, los países pequeños y no hispanohablantes recibirían un IMN sistemáticamente distorsionado (invisibilización de dimensiones o inflación de otras).	Caribe anglófono, Haití, Brasil, países con < 20 normas	Alta	Alta (sin la regla de gobernanza); Baja (con ella)
R2 · Sesgo de automatización y erosión del juicio experto	Si el codificador acepta por defecto la propuesta del modelo, los errores sistemáticos del modelo (Técnico F1 0.35, Administrativo 0.41) se trasladan al índice y el conocimiento experto se degrada [5].	Codificadores; clases minoritarias del framework (Técnico, Administrativo)	Media-Alta	Media
R3 · Uso reputacional o político del índice sin su incertidumbre	Un IMN presentado como ranking puede usarse para presionar, premiar o sancionar países o IES, cuando parte de sus cifras proviene de un modelo con κ 0.50-0.56 frente a la referencia.	Países comparados, IES, decisores	Alta	Media
R4 · Reificación del framework de cinco dimensiones	El modelo aprende y amplifica la simplificación «una norma = una dimensión»; las normas de frontera (pedagógico-ético, datos-ético) se fuerzan a una casilla y el índice pierde matiz.	Normas y países con normativa integral (estrategias nacionales)	Media	Alta
R5 · Datos personales de codificadores y dependencia de terceros	El corpus incluye el nombre del codificador; una fuga permitiría atribuir errores a personas. La rama LLM envía textos a un proveedor externo y depende de versiones de modelo que cambian.	Codificadores; coordinación (reproducibilidad)	Media	Baja (anonimización y exclusión ya aplicadas)

3.3 Análisis de equidad

¿Reduce o aumenta desigualdades existentes? Por diseño, las reduce —hace visibles jurisdicciones omitidas y evita que un observatorio sin recursos abandone la codificación—; por su comportamiento técnico, tendería a aumentarlas si se automatizara sin salvaguardas, porque rinde mejor justo donde hay más datos. La auditoría por grupo (Figura 1, Tabla 3) lo cuantifica con la regla de los cuatro quintos [6] como referencia orientativa (no como norma legal, ya que los grupos son jurisdicciones y no personas): la razón de exactitud frente al grupo de referencia es 0.54 para el inglés y 0.56 para el Caribe, muy por debajo de 0.8; por tamaño del país (0.86) y ámbito (0.82) la brecha es menor.

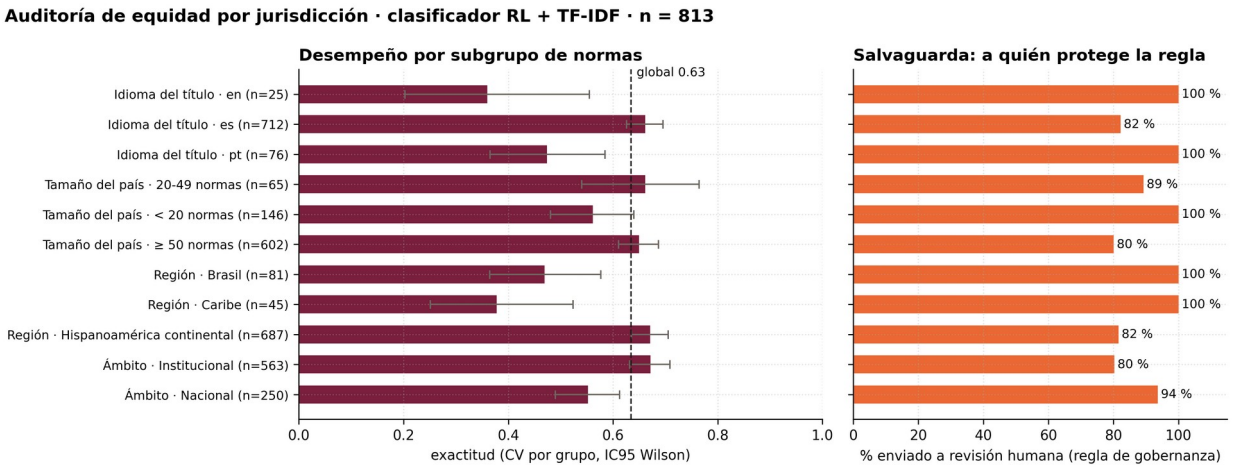


Figura 1. Auditoría de equidad por jurisdicción sobre las predicciones fuera de muestra (CV por grupo, n = 813). Izquierda: exactitud por subgrupo con IC95 de Wilson. Derecha: proporción de normas que la regla de gobernanza envía a revisión humana; los grupos con peor desempeño son los más protegidos.

Tabla 3. Métricas por subgrupo (CV por grupo). Razón = exactitud del grupo / exactitud del grupo de referencia.

Dimensión	Grupo	n	Exactitud [IC95]	F1 macro	Top-2	Razón	A revisión
Idioma del título	es	712	0.66 [0.63, 0.70]	0.61	0.88	1.00	82 %
Idioma del título	pt	76	0.47 [0.37, 0.58]	0.39	0.75	0.72	100 %
Idioma del título	en	25	0.36 [0.20, 0.55]	0.27	0.48	0.54	100 %
Región	Hispanoamérica continental	687	0.67 [0.64, 0.71]	0.62	0.89	1.00	82 %
Región	Brasil	81	0.47 [0.36, 0.58]	0.36	0.74	0.70	100 %
Región	Caribe	45	0.38 [0.25, 0.52]	0.39	0.51	0.56	100 %
Tamaño del país	≥ 50 normas	602	0.65 [0.61, 0.69]	0.60	0.87	1.00	80 %
Tamaño del país	20-49 normas	65	0.66 [0.54, 0.76]	0.50	0.92	1.02	89 %
Tamaño del país	< 20 normas	146	0.56 [0.48, 0.64]	0.53	0.76	0.86	100 %
Ámbito	Institucional	563	0.67 [0.63, 0.71]	0.59	0.89	1.00	80 %
Ámbito	Nacional	250	0.55 [0.49, 0.61]	0.56	0.76	0.82	94 %

Distribución de beneficios. Se benefician más los países grandes e hispanohablantes (México, Chile, Argentina, Ecuador): sus normas se clasifican mejor y son las que la regla deja pasar al tramo automático. **Distribución de riesgos.** Los asumen las jurisdicciones pequeñas y no hispanohablantes; la regla de gobernanza los transfiere al presupuesto del observatorio (revisión humana del 100 % de sus normas), que es donde deben estar. **Acceso.** El código es abierto, pero el corpus no es redistribuible y la rama LLM requiere una clave de pago: un observatorio sin financiamiento puede replicar la rama clásica, no la LLM. **Barreras.** Idioma de la documentación (español), competencias técnicas (Python, Git) y la necesidad de un corpus propio codificado. **Hallazgo accionable.** Brasil quedaba fuera de la revisión obligatoria por idioma (la regla cubría en/fr) y las pocas normas brasileñas que pasaban al tramo automático se clasificaban mal (exactitud 0.33 en ese tramo en la auditoría previa a la corrección): la regla se corrigió en esta actividad para incluir el portugués, y la Tabla 3 ya refleja el 100 % de revisión para Brasil.

Parte 4. Riesgos éticos específicos

Del *checklist* del workshop se analizan seis riesgos (fairness, privacidad, transparencia, autonomía, seguridad y accountability). Para cada uno se indica cómo se manifiesta en este proyecto, la evidencia, la severidad y el grupo afectado.

Riesgo E1	Fairness y sesgo: desempeño desigual por idioma y región (¿discrimina el modelo? ¿están balanceados los datos? ¿se evaluaron métricas de fairness?)
Descripción	El modelo no decide sobre personas, pero sí sobre jurisdicciones: una norma brasileña o caribeña tiene menos probabilidad de ser bien clasificada. Los datos no están balanceados ni por clase (4.7:1) ni por país (66 % en cinco países) ni por idioma (88 % español). Se evaluaron métricas por grupo: exactitud, F1 macro, top-2 e IC95 por idioma, región, tamaño del país, ámbito y codificador anonimizado (Tabla 3); las herramientas estándar de fairness (Fairlearn, AIF360) se diseñaron para atributos protegidos de personas y no aplican directamente, así que se adaptó su lógica (paridad de exactitud y regla de los cuatro quintos) [7], [8].
Evidencia	Exactitud es 0.66 / pt 0.47 / en 0.36; Caribe 0.38; normas nuevas del Caribe 0.39. Razón mínima frente al grupo de referencia 0.54 (idioma) y 0.56 (región). Además, el efecto codificador está confundido con el país (un codificador por país; exactitud por codificador entre 0.29 y 0.71), por lo que no es posible separar «sesgo del modelo» de «estilo de codificación».
Severidad	Alta: afecta directamente la validez comparativa del IMN, que es el producto del observatorio.
Grupo afectado	Jurisdicciones del Caribe, Brasil, Haití y países con < 20 normas.
Riesgo E2	Privacidad: datos personales de los codificadores, consentimiento, protección y re-identificación
Descripción	El corpus describe documentos públicos (sin datos de estudiantes ni docentes), pero la columna *Investigador* contiene el nombre de cada codificador. Como cada país fue codificado por una sola persona, cualquier tabla por país permite re-identificar al codificador aunque se elimine el nombre: el riesgo es que el desempeño del modelo se lea como evaluación de personas. Los codificadores consintieron la codificación para GENIAL, no necesariamente su uso en una tesis de maestría ni en publicaciones. Los textos enviados al LLM externo son títulos y observaciones de normas públicas; no incluyen el nombre del codificador.
Evidencia	V de Cramér País ↔ Investigador = 0.99; la columna se excluye del modelo, se anonimiza en la muestra pública y en la auditoría (Codificador A-J); el corpus completo no se redistribuye (hash publicado); el repositorio nunca ha contenido datos crudos.
Severidad	Media (dato personal poco sensible, pero con riesgo reputacional para 10 personas identificables).
Grupo afectado	Codificadores de GENIAL.
Riesgo E3	Transparencia y explicabilidad: ¿entienden los usuarios cómo funciona? ¿se comunican las limitaciones?
Descripción	El modelo es interpretable por construcción (pesos por término y clase, probabilidades, segunda candidata) y la documentación es pública (documento técnico, cuadernos ejecutados, README). El riesgo está en el consumidor final del IMN, que no verá el modelo sino un número por país: si el índice no comunica qué fracción de normas tiene respaldo humano y con qué margen, la transparencia del modelo no llega a quien toma decisiones. Un segundo riesgo es la rama LLM, cuya explicación en lenguaje natural es plausible pero no verificable.
Evidencia	Umbrales fijados antes de ejecutar y resultados por debajo de la meta reportados tal cual (F1 0.587 frente a 0.70); tabla del IMN con columnas «codificadas por modelo» y «margen»; *model card* y *datasheet* (anexos) redactadas en esta actividad.
Severidad	Media.
Grupo afectado	Decisores y público que consumen el IMN; codificadores (rama LLM).
Riesgo E4	Autonomía y supervisión humana: ¿controlan los usuarios la decisión? ¿hay sesgo de automatización?
Descripción	La decisión final es humana por diseño (codificación asistida), pero la literatura muestra que presentar una recomendación con probabilidad induce a aceptarla sin examinarla [5]. El riesgo crece con la carga: con ~84 % de las normas enviadas a revisión, la tentación de «aceptar y seguir» es alta. Si el codificador sigue al modelo, el κ modelo-humano medido en el futuro estará inflado y la supervisión será nominal.
Evidencia	El modelo falla donde el humano dudó (exactitud 0.41 con confianza media frente a 0.76 con confianza alta): justo en los casos difíciles, una recomendación automática puede desplazar un juicio que ya era incierto.
Severidad	Media-Alta.
Grupo afectado	Codificadores; indirectamente, la validez del índice.
Riesgo E5	Seguridad y robustez: ¿qué pasa si el modelo falla? ¿consecuencias de los errores?
Descripción	Un fallo no causa daño físico ni económico inmediato: produce etiquetas erróneas que, acumuladas, distorsionan el IMN de un país. Los modos de fallo conocidos son el cambio de distribución (normas nuevas, otro idioma, otra región: exactitud 0.39 en las 23

	normas del Caribe incorporadas después del corte), la deriva del corpus al actualizarse y, en la rama LLM, el cambio de versión del modelo del proveedor. También existe un riesgo de integridad: si el corpus de entrada se altera, los resultados dejan de ser reproducibles.
Evidencia	Hash SHA-256 verificado al cargar; 8 pruebas unitarias; regla de ceguera sobre el conjunto de prueba; umbral de confianza calibrado para ≥ 85 % de exactitud en el tramo automático; registro de la versión exacta del LLM en cada ejecución.
Severidad	Media.
Grupo afectado	Países con normativa nueva o atípica; coordinación (reproducibilidad).
Riesgo E6	Accountability: ¿quién responde si algo sale mal? ¿hay apelación y auditoría?
Descripción	El sistema es un trabajo académico en colaboración con un consorcio internacional: la responsabilidad se reparte entre los autores (modelo y código), la coordinación GENIAL (uso del índice) y los codificadores (etiquetas). Sin una cadena explícita, un IMN erróneo publicado no tendría responsable (*responsibility gap*). Hoy no existe un canal formal para que un país o IES cuestione su clasificación.
Evidencia	Cadena de responsabilidad y mecanismos definidos en la Parte 6; hoja de tipificación de errores como mecanismo de apelación interna (el codificador puede clasificar un error como «etiqueta original discutible» y pedir recodificación); auditoría de equidad reproducible con un comando [9].
Severidad	Media.
Grupo afectado	Países e IES comparados; coordinación GENIAL; autores.

Parte 5. Estrategias de mitigación

Una estrategia por riesgo, con la plantilla del workshop. Tres de ellas ya están implementadas en el repositorio y se marcan como tales; las demás son viables antes del cierre del proyecto (25 de octubre de 2026) o en la primera actualización del corpus.

Tabla 4. Estrategias de mitigación por riesgo.

Riesgo	Estrategia propuesta	Tipo	Implementación (pasos · cuándo · responsable)	Efectividad
E1 Fairness / R1	Regla de gobernanza ampliada y auditoría por grupo en cada versión. Revisión humana obligatoria para países con < 20 normas e idiomas distintos del español (se añade el portugués: Brasil pasaba al tramo automático con exactitud 0.33); auditoría por idioma/región/tamaño con la regla de los cuatro quintos como alerta; reporte del IMN con margen por país.	Técnica + Política	(1) `mandatory_review_languages: [en, fr, pt]` en config.yaml — hecho en esta actividad; (2) `scripts/fairness_grupos.py` en el flujo de cada reentrenamiento — hecho; (3) incluir la tabla por grupo en el informe del IMN — antes del cierre. Responsable: autores (técnica), coordinación GENIAL (política).	Alta para el índice (los grupos en riesgo quedan 100 % revisados); no mejora el modelo en sí
E1 Fairness / R1 (raíz)	Más normas codificadas de las clases y regiones minoritarias y doble codificación. Priorizar en la próxima ronda de GENIAL la codificación de normas del Caribe, Brasil y de las dimensiones Técnico y Administrativo; medir κ humano-humano con la plantilla ya generada.	Política (datos)	(1) Plantilla `coder2_labels_plantilla.csv` → segundo codificador — en curso; (2) propuesta de muestreo dirigido a la coordinación — octubre; (3) reentrenar y re-auditar — siguiente versión. Responsable: coordinación GENIAL con los autores.	Media-Alta a mediano plazo
E2 Privacidad / R5	Minimización y anonimización por diseño. Excluir `Investigador` del modelo y de cualquier artefacto publicado; seudonimizar (Codificador A-J) en análisis internos; no enviar la columna al LLM; informar a los codificadores del uso del corpus en la tesis y ofrecer retirar su nombre.	Técnica + Política	(1) Exclusión y seudonimización — hecho (`leakage_excluded`, auditoría); (2) nota informativa a los 10 codificadores vía coordinación — octubre; (3) *datasheet* con la política de datos personales — hecho (Anexo B). Responsable: autores; coordinación Ecuador.	Alta
E3 Transparencia	Model card, datasheet y «ficha de incertidumbre» del IMN. Documentar capacidades, límites y métricas por grupo; acompañar cada cifra del IMN con el	Diseño + Educación	(1) Anexos A y B publicados en `docs/` — hecho; (2) columna «margen» y «codificadas por modelo» en `imn_propuesta.csv` — hecho; (3) nota metodológica	Alta

Riesgo	Estrategia propuesta	Tipo	Implementación (pasos · cuándo · responsable)	Efectividad
	porcentaje de normas con respaldo humano y su margen; explicar al codificador los términos que pesaron en cada propuesta.		para lectores del IMN — antes del cierre. Responsable: autores.	
E4 Autonomía	Interfaz que exige decisión, no confirmación. Mostrar las dos candidatas sin preseleccionar ninguna, con los términos que las sustentan; exigir una justificación breve cuando el codificador acepte la propuesta en normas de confianza media/baja; muestrear al azar un 10 % de las aceptaciones para re-lectura independiente y medir el sesgo de automatización (tasa de acuerdo con el modelo vs. tasa esperada).	Diseño + Política	(1) Especificación de la pantalla de codificación asistida — antes del cierre (documento); (2) protocolo de muestreo del 10 % — primera operación real; (3) formación breve a codificadores sobre sesgo de automatización — con la coordinación. Responsable: autores (diseño), coordinación (operación).	Media (reduce, no elimina, el sesgo)
E5 Seguridad	Control de versiones de datos y modelo, pruebas y detección de deriva. Hash del corpus, versión del modelo y del LLM registradas en cada ejecución; pruebas unitarias; comparar la distribución de confianza y de clases predichas entre versiones del corpus y disparar revisión manual si cambian más de un umbral.	Técnica	(1) Hash + pruebas + meta.json — hecho; (2) script de comparación entre versiones (deriva) — siguiente actualización del corpus; (3) política: ninguna cifra del IMN se publica sin pasar la auditoría — coordinación. Responsable: autores.	Alta para integridad; Media para deriva
E6 Accountability / R3	Cadena de responsabilidad explícita y canal de apelación. Formalizar la Parte 6 como anexo del acuerdo con GENIAL; crear un canal (correo/formulario) para que países o IES soliciten revisión de su clasificación, con plazo de respuesta y registro público de correcciones.	Política	(1) Tabla de roles aprobada por la coordinación — octubre; (2) canal de apelación y registro de incidentes — antes de la primera publicación del IMN; (3) revisión anual. Responsable: coordinación GENIAL; autores como soporte técnico.	Media-Alta

Parte 6. Framework de responsabilidad

6.1 Cadena de responsabilidad

Rol	Quién	Responsabilidades	Rendición de cuentas
Desarrolladores / científicos de datos	J. Maldonado y M. Figallo (Grupo 9)	Implementación correcta; calidad de datos; auditoría de equidad; documentación (model card, datasheet); reproducibilidad	Repositorio público con historial de commits; pruebas unitarias; cuadernos ejecutados; auditoría por grupo en cada versión
Propietario del producto (observatorio)	Coordinación GENIAL (general: Université de Toulouse; Ecuador: Universidad de Cuenca)	Decidir cómo se usa el modelo (modo asistido), aprobar la regla de gobernanza, publicar el IMN con su incertidumbre, informar a codificadores	Acta de aprobación de la regla; nota metodológica pública del IMN; registro de correcciones
Codificadores	≈10 investigadores GENIAL	Decisión final sobre cada norma; tipificar errores; señalar normas de frontera	Hoja de tipificación; κ humano-humano; muestreo del 10 % de aceptaciones
Supervisión académica	Tutora del Proyecto Integrador (UEES)	Revisar rigor metodológico y ético de los entregables	Rúbricas y retroalimentación documentada
Proveedor del LLM	Empresa de la API (rama few-shot)	Disponibilidad y versionado del modelo; términos de uso de datos	Versión registrada en `pred_llm_runs.csv.meta.json`; alternativa con modelo abierto
Organización / financiador	Consorcio GENIAL · Erasmus+	Gobernanza de datos, recursos para revisión humana, ética de la investigación	Acuerdo de uso del corpus; gestión de datos del proyecto

6.2 Mecanismos de accountability

Mecanismo	Estado	Detalle
Documentación · Model card	☑ hecho	Anexo A; `docs/model_card.md`
Documentación · Datasheet	☑ hecho	Anexo B; `docs/datasheet_corpus.md`
Documentación · Ethics statement con análisis de riesgos	☑ hecho	Este documento (`docs/semana4/`)
Supervisión · Revisión humana en decisiones críticas	☑ hecho	Regla de gobernanza: confianza < 0.50, países < 20 normas, idiomas pt/en/fr
Supervisión · Proceso de apelación	☐ pendiente	Canal para países/IES y hoja de tipificación interna (E6)
Supervisión · Auditoría periódica	☑ definido	Frecuencia: en cada actualización del corpus y al menos anual (`fairness_grupos.py`)
Monitoreo · Métricas de fairness trackeadas	☑ hecho	`results/fairness/fairness_grupos.csv` por versión
Monitoreo · Alertas por deriva o anomalías	☐ pendiente	Comparación de distribuciones entre versiones (E5)
Monitoreo · Reportes de incidentes	☐ pendiente	Registro público de correcciones del IMN
Transparencia · Información clara sobre uso de IA	☑ hecho	README, documento técnico, nota «codificadas por modelo» en el IMN
Transparencia · Comunicación de limitaciones	☑ hecho	Semáforo de umbrales no alcanzados; model card §9
Transparencia · Acceso a explicaciones	☑ hecho	Términos por dimensión, probabilidad y segunda candidata por norma

6.3 Plan de respuesta a incidentes

1. **Detección.** Auditoría por grupo en cada versión (razón < 0.8 dispara alerta); muestreo del 10 % de aceptaciones; reclamaciones por el canal de apelación; discrepancia entre κ humano-humano y κ modelo-humano.
2. **Respuesta inmediata.** Congelar la publicación del IMN para la jurisdicción o dimensión afectada; marcar las normas implicadas como «pendientes de revisión humana»; comunicar a la coordinación en 48 horas.
3. **Investigación.** Reproducir el resultado con el hash y la versión registrados; localizar el origen (datos, etiqueta, modelo, versión del LLM, deriva) con la hoja de tipificación y los historiales del tracker.
4. **Corrección.** Recodificación humana de las normas afectadas; reentrenamiento si el origen es el modelo; publicación de la corrección con fecha y alcance en el registro de incidentes.
5. **Prevención.** Añadir el caso como prueba de regresión; ajustar la regla de gobernanza o el umbral; actualizar model card y datasheet; revisar el protocolo con los codificadores.

Parte 7. Consideraciones de compliance

Tabla 5. Regulaciones aplicables, requisitos, cumplimiento y cambios necesarios.

Regulación	¿Aplica?	Qué requiere	¿Cumple?	Cambios necesarios
RGPD (UE) [10]	Parcialmente: la coordinación general está en Francia y el corpus contiene nombres de codificadores (datos personales de identificables, algunos ciudadanos UE)	Base jurídica, minimización, información al interesado, seguridad; no hay decisiones automatizadas sobre personas (art. 22 no aplica) [11]	En gran parte: nombres excluidos del modelo y de publicaciones; corpus no redistribuido	Nota informativa a los codificadores sobre el uso en la tesis; confirmar con la coordinación la base jurídica del tratamiento
LOPDP Ecuador (2021) [12]	Sí: el coordinador nacional y parte de los codificadores están en Ecuador	Principios de finalidad, minimización y seguridad; derechos ARCO de los titulares	Sí en lo esencial	Documentar el tratamiento de la columna `Investigador` en la gestión de datos del proyecto
LGPD Brasil (2018) [13]	Marginal: posibles codificadores brasileños	Análogo a RGPD	Sí	Ninguno adicional

Regulación	¿Aplica?	Qué requiere	¿Cumple?	Cambios necesarios
Ley de IA de la UE (Reg. 2024/1689) [14]	Clasificación de riesgo: el sistema no está en los casos prohibidos ni en los de alto riesgo del Anexo III (no evalúa personas, no decide acceso a educación, empleo o servicios); es un clasificador documental de apoyo a la investigación → riesgo mínimo. Las obligaciones de modelos de propósito general recaen en el proveedor del LLM	Para riesgo mínimo: ninguna obligación vinculante; se recomiendan códigos de conducta voluntarios (transparencia, documentación)	Sí; además adopta voluntariamente documentación tipo alto riesgo (model card, datasheet, supervisión humana, registro)	Revisar la clasificación si el IMN pasara a condicionar financiamiento o acreditación de IES
Leyes antidiscriminación	No aplican en sentido estricto: no hay decisiones sobre personas ni atributos protegidos	—	—	Se aplica por analogía la equidad entre jurisdicciones (Parte 3.3)
Recomendación UNESCO sobre ética de la IA (2021) y Principios OCDE [15], [16]	Sí (soft law; además, el propio observatorio mide alineación con estos marcos)	Proporcionalidad, equidad, transparencia, supervisión humana, rendición de cuentas	Sí: los mecanismos de la Parte 6 responden a cada principio	Citar explícitamente estos marcos en la nota metodológica del IMN
Otros: acuerdo de uso del corpus GENIAL; licencias (MIT, muestra con atribución); términos de uso del proveedor de LLM; normativa de integridad académica UEES	Sí	No redistribuir el corpus; atribución; uso de la API conforme a sus términos; autoría y originalidad	Sí (`DATA_LICENSE.md`, `LICENSE`, `CITATION.cff`)	Verificar con la coordinación si el envío de textos del corpus a una API externa requiere autorización expresa

¿Se necesitaría asesoría legal para una implementación real? Sí, en dos puntos: la base jurídica del tratamiento de los nombres de los codificadores bajo RGPD/LOPDP en un proyecto multinacional, y los términos de uso de datos del proveedor de LLM respecto a un corpus con autorización restringida. Ninguno bloquea el prototipo académico; ambos deben resolverse antes de operar el flujo en el observatorio.

Parte 8. Reflexión y compromiso

8.1 Reflexión

El dilema ético más difícil: escalar sin invisibilizar. El observatorio necesita automatizar para sostenerse y cubrir la región; pero el modelo rinde peor precisamente en las jurisdicciones que un índice regional debería hacer visibles (Caribe, Brasil, países pequeños). Entran en conflicto la *beneficencia* (un observatorio sostenible beneficia a todos) con la *justicia* (que el beneficio no se concentre en los países ya bien representados) y la *autonomía* de los codificadores (que la herramienta no sustituya su criterio). También hay un dilema de *transparencia frente a utilidad*: publicar un IMN con márgenes amplios es menos atractivo para los decisores que un ranking nítido, pero es lo honesto. Lo resolvemos con una regla asimétrica: automatizar solo donde hay evidencia de calidad y revisar el 100 % donde no la hay, trasladando el costo al presupuesto del observatorio y no a los países; y publicando el índice únicamente con su incertidumbre y su proporción de respaldo humano. Si GENIAL no pudiera financiar esa revisión, nuestra recomendación sería no publicar el IMN de las jurisdicciones afectadas antes que publicarlo distorsionado [17], [18].

Qué aprendimos que no habíamos considerado. Tres cosas. Que el principal «atributo protegido» de nuestro sistema no es una característica de personas sino de jurisdicciones, y que las herramientas estándar de fairness no estaban pensadas para eso: tuvimos que adaptar su lógica. Que el efecto del codificador está confundido con el país (un codificador por país), de modo que el modelo podría estar aprendiendo estilos de redacción de las observaciones y no propiedades de las normas, y que cualquier tabla por país re-identifica a una persona. Y que la regla de gobernanza que creíamos protectora dejaba fuera a Brasil: la auditoría de esta semana lo mostró y la corregimos.

Qué cambiaríamos en el diseño. (i) La regla de revisión obligatoria incluye ahora el portugués. (ii) El IMN pasa a publicarse con margen y porcentaje de respaldo humano como parte del formato, no como nota al pie. (iii) La columna `Investigador` se seudonimiza en origen antes de que el corpus llegue al equipo técnico. (iv) La interfaz de codificación asistida exigirá decisión activa y justificación en los casos de confianza media. (v) Propondremos

a GENIAL una doble codificación dirigida a Caribe, Brasil y a las dimensiones Técnico y Administrativo. (vi) Incorporaremos a representantes de los países comparados en la validación del IMN antes de su publicación, porque hoy son el stakeholder con menos voz.

8.2 Compromiso ético

Declaración de compromiso

«Como creadores de este sistema de IA, nos comprometemos a: (1) ejecutar y publicar la auditoría de equidad por idioma, región y tamaño de país en cada versión del modelo y del corpus, y no publicar ningún valor del IMN cuyo grupo no pase la revisión humana obligatoria; (2) acompañar cada cifra del Índice de Madurez Normativa con el porcentaje de normas con respaldo humano y su margen de incertidumbre, y mantener actualizadas la model card y la datasheet con cada versión; (3) no usar el modelo ni sus métricas para evaluar el trabajo de codificadores individuales y proteger su identidad en todo artefacto público; (4) actuar responsablemente si se identifican daños, congelando la publicación afectada y corrigiendo con registro público; (5) priorizar el bienestar de usuarios y grupos vulnerables, en particular de las jurisdicciones pequeñas y no hispanohablantes; y (6) mantener transparencia sobre las limitaciones del sistema, incluidos los umbrales que no alcanza.» Firma / fecha: Jorge Javier Maldonado Mahauad · Melissa Figallo · Guayaquil/Cuenca, 3 de octubre de 2026.

Integración en la presentación final

Siguiendo la pauta de la Semana 4 (la reflexión ética integrada en la narrativa, no como apéndice), la presentación final de 18 diapositivas incorpora: en la introducción, el dilema «escalar sin invisibilizar» (diapositiva 3); en metodología, la decisión de excluir `Investigador` y la CV por grupo como decisiones éticas sobre datos (6-7); en resultados, la auditoría de equidad por jurisdicción (Figura 1) junto a la desagregación por idioma (11); en la reflexión, la regla de gobernanza, el framework de responsabilidad y las limitaciones (15-16); y en el cierre, los tres compromisos específicos (17). Se añade una diapositiva «Impacto social y responsabilidad» con la Figura 1 y la tabla de stakeholders resumida, y el guion del video incorpora un bloque de 60 segundos sobre el dilema y los compromisos.

Referencias

[1] Proyecto GENIAL (Erasmus+), “Corpus consolidado de normativa sobre inteligencia artificial en educación superior de América Latina y el Caribe (consolidado_limpio.xlsx, versión congelada de septiembre de 2026),” conjunto de datos de investigación, no publicado, 2026. Uso autorizado por la coordinación del consorcio.

[2] M. Mitchell et al., “Model cards for model reporting,” in Proc. Conf. on Fairness, Accountability, and Transparency (FAT*), Atlanta, GA, USA, 2019, pp. 220–229, doi: 10.1145/3287560.3287596.

[3] T. Gebru et al., “Datasheets for datasets,” Communications of the ACM, vol. 64, no. 12, pp. 86–92, 2021, doi: 10.1145/3458723.

[4] CEPAL and CENIA, “Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025: Hallazgos principales, IA aplicada y talento humano,” Comisión Económica para América Latina y el Caribe, Santiago, Chile, Rep. LC/TS.2026/1, 2026. [Online]. Available: https://repositorio.cepal.org/handle/11362/86007

[5] L. J. Skitka, K. L. Mosier, and M. Burdick, “Does automation bias decision-making?,” International Journal of Human-Computer Studies, vol. 51, no. 5, pp. 991–1006, 1999, doi: 10.1006/ijhc.1999.0252.

[6] U.S. Equal Employment Opportunity Commission et al., “Uniform Guidelines on Employee Selection Procedures,” 29 C.F.R. § 1607.4(D), 1978 (regla de los cuatro quintos).

[7] S. Barocas, M. Hardt, and A. Narayanan, Fairness and Machine Learning: Limitations and Opportunities. Cambridge, MA, USA: MIT Press, 2023.

[8] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman, and A. Galstyan, “A survey on bias and fairness in machine learning,” ACM Computing Surveys, vol. 54, no. 6, art. 115, 2021, doi: 10.1145/3457607.

[9] I. D. Raji et al., “Closing the AI accountability gap: Defining an end-to-end framework for internal algorithmic auditing,” in Proc. Conf. on Fairness, Accountability, and Transparency (FAT*), Barcelona, Spain, 2020, pp. 33–44, doi: 10.1145/3351095.3372873.

[10] Parlamento Europeo y Consejo de la Unión Europea, “Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (RGPD),” Diario Oficial de la Unión Europea, L 119, 4 may. 2016.

[11] S. Wachter, B. Mittelstadt, and L. Floridi, “Why a right to explanation of automated decision-making does not exist in the General Data Protection Regulation,” International Data Privacy Law, vol. 7, no. 2, pp. 76–99, 2017, doi: 10.1093/idpl/ipx005.

[12] Asamblea Nacional de la República del Ecuador, “Ley Orgánica de Protección de Datos Personales,” Registro Oficial Suplemento 459, 26 may. 2021.

[13] Brasil, “Lei n.º 13.709, de 14 de agosto de 2018 — Lei Geral de Proteção de Dados Pessoais (LGPD),” Diário Oficial da União, 2018.

[14] Parlamento Europeo y Consejo de la Unión Europea, “Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de IA),” Diario Oficial de la Unión Europea, L, 12 jul. 2024.

[15] UNESCO, Recomendación sobre la ética de la inteligencia artificial. París, Francia: UNESCO, 2021 (SHS/BIO/PI/2021/1).

[16] OECD, “Recommendation of the Council on Artificial Intelligence,” OECD/LEGAL/0449, adoptada en 2019 y enmendada el 3 may. 2024.

[17] A. D. Selbst, d. boyd, S. A. Friedler, S. Venkatasubramanian, and J. Vertesi, “Fairness and abstraction in sociotechnical systems,” in Proc. Conf. on Fairness, Accountability, and Transparency (FAT*), Atlanta, GA, USA, 2019, pp. 59–68, doi: 10.1145/3287560.3287598.

[18] L. Floridi et al., “AI4People — An ethical framework for a good AI society: Opportunities, risks, principles, and recommendations,” Minds and Machines, vol. 28, pp. 689–707, 2018, doi: 10.1007/s11023-018-9482-5.

Anexo A. Model card del clasificador (v0.3)

Formato basado en Mitchell et al. (2019). Cifras tomadas de results/sintesis_resultados.json, results/overfitting/sintesis_overfitting.json y results/fairness/fairness_grupos.csv.

1. Detalles del modelo

- **Desarrolladores://* Jorge Javier Maldonado Mahauad y Melissa Figallo (Grupo 9, Maestría en IA, UEES), en colaboración con el proyecto GENIAL (Erasmus+). Tutora académica: Gladys María Villegas Rugel.*
- **Tipo://* clasificador lineal multiclase (regresión logística, L2, class_weight='balanced') sobre TF-IDF de 1-2 gramas (5 000 características; configuración regularizada recomendada tras la Semana 3: C ≤ 0.1, 2 000 características, min_df = 2). Rama de comparación: LLM *few-shot* (15 ejemplos, temperatura 0), pendiente de ejecución.*
- **Versión / fecha://* v0.3, octubre de 2026. Repositorio: github.com/jorgemaldonadom-cmd/genial-clasificador-normativa. Licencia del código: MIT.*
- **Entrada://* texto UTF-8 «título de la norma. observaciones del codificador» (mediana 44 palabras). Salida://* dimensión predicha, segunda dimensión (top-2) y probabilidad máxima.

2. Uso previsto

- **Uso principal://* asistir a los codificadores del observatorio GENIAL proponiendo dos dimensiones candidatas con su probabilidad para cada norma sobre IA en educación superior de América Latina y el Caribe. La decisión final es humana (codificación asistida).*
- **Usuarios previstos://* investigadores codificadores de GENIAL; coordinación del observatorio para estimar carga de trabajo.*
- **Usos fuera de alcance://* publicar valores del Índice de Madurez Normativa (IMN) calculados solo con etiquetas automáticas; clasificar normas de otros dominios o idiomas sin reentrenar; tomar decisiones sobre personas; comparar o sancionar países sin revisión humana ni margen de incertidumbre.*

3. Factores relevantes

- **Idioma del título (es / pt / en), región (Hispanoamérica continental / Brasil / Caribe), tamaño del país en el corpus, ámbito (nacional / institucional), dimensión (cinco clases desbalanceadas 4.7:1), codificador original** (confundido con el país: V de Cramér 0.99).

4. Métricas

- F1 macro (principal, por el desbalance), exactitud, top-2, κ de Cohen frente a la etiqueta de referencia; intervalos de confianza de Wilson y *bootstrap*; McNemar frente a líneas base; desagregación por factor.

5. Datos de evaluación

- Validación cruzada de 5 pliegues estratificada por dimensión y por grupo de URL (n = 813). Conjunto ciego: las 125 normas leídas por un investigador de GENIAL con el instrumento de codificación ciega; etiquetas leídas una sola vez.

6. Datos de entrenamiento

- Corpus consolidado GENIAL, versión congelada (SHA-256 f9797147…3f33), 813 normas de 28 jurisdicciones; véase docs/datasheet_corpus.md.

7. Resultados cuantitativos

Métrica	CV por grupo (n = 813)	Ciego (n = 125)
F1 macro	0.587 [0.549, 0.623]	0.617 [0.505, 0.712]
Exactitud	0.635 [0.601, 0.667]	0.688 [0.602, 0.763]
Top-2	0.852	0.872

Métrica	CV por grupo (n = 813)	Ciego (n = 125)
κ vs referencia	0.50	0.56
F1 por clase	Ped 0.71 · Ética 0.67 · Adm 0.41 · PD 0.80 · Téc 0.35	—

Desagregado (exactitud, CV): es 0.66 · pt 0.47 · en 0.36; Hispanoamérica continental 0.67 · Brasil 0.47 · Caribe 0.38; institucional 0.67 · nacional 0.55; países < 20 normas 0.56. Normas nuevas del Caribe (n = 23, fuera de la versión congelada): 0.39.

8. Consideraciones éticas

- El modelo rinde peor en normas en portugués e inglés y en el Caribe: sin salvaguardas, el IMN de esas jurisdicciones quedaría sistemáticamente distorsionado. Regla de gobernanza: revisión humana obligatoria para países con < 20 normas e idiomas distintos del español (incluido el portugués desde v0.3) y para toda predicción con probabilidad < 0.50.
- Los errores se concentran en normas que el codificador humano marcó como multidimensionales o de confianza media: la etiqueta única es una simplificación del framework y el modelo la hereda.
- El corpus contiene el nombre del codificador de cada norma (dato personal): se excluye del modelo, se anonimiza en toda publicación y no se envía al proveedor de LLM.

9. Advertencias y recomendaciones

- No usar como sustituto del codificador: la automatización con ≥ 85 % de exactitud exigiría revisar ~84 % de las normas.
- Reentrenar y volver a auditar por grupo en cada actualización del corpus; publicar esta tarjeta actualizada con cada versión.
- Toda cifra del IMN debe acompañarse del porcentaje de normas con respaldo humano y de un margen de incertidumbre.

Anexo B. Datasheet del corpus GENIAL (versión congelada)

Formato basado en Gebru et al. (2021). Complementa data/README.md y DATA_LICENSE.md.

Motivación

- *¿Para qué se creó?* Para el observatorio regional del proyecto GENIAL (Erasmus+): inventariar y caracterizar la normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe y alimentar un Índice de Madurez Normativa (IMN) por país.
- *¿Quién lo creó y financió?* Diez investigadores del consorcio GENIAL, coordinados desde la Universidad de Cuenca para Ecuador y desde la Université de Toulouse a nivel general; financiación Erasmus+ (Unión Europea).

Composición

- 813 registros; cada uno es un instrumento normativo (ley, estrategia nacional, reglamento, política institucional, guía) de 28 jurisdicciones (27 países y Puerto Rico). Cinco países concentran el 66 % (México 179, Chile 105, Argentina 100, Brasil 81, Ecuador 81); 12 jurisdicciones tienen menos de 20 normas.
- 13 columnas: Investigador, País, Título de la Norma, Tipo de norma, Estado, Organismo Emisor/Universidad, Dominio (variable objetivo: Pedagógico 294, Ética 265, Administrativo 120, Protección de Datos 71, Técnico 63), Vínculo con Educación, Dedicación del Texto, Ámbito, Fecha de Publicación, Observaciones, URL Oficial.
- *Datos personales://* la columna Investigador contiene el nombre del codificador (dato personal de 10 personas identificables); el resto describe documentos públicos. No hay datos de estudiantes ni de docentes.

- **Errores y ruido conocidos://* 1 valor faltante de Dominio (corregido con criterio experto documentado); 14 grupos de URL repetida (30 normas, 8 con dimensiones distintas); 42 % de fechas no interpretables; Tipo de norma con 14 variantes que se normalizan a 11; textos muy cortos (10 con menos de 12 palabras).*
- **Etiqueta://* una sola dimensión por norma asignada por un único codificador; fiabilidad intercodificador no medida (κ humano-humano pendiente). El 84 % de las normas releídas por un segundo investigador recibieron etiquetas secundarias: la etiqueta única es una simplificación.*

Proceso de recolección

- Búsqueda documental por país (fuentes oficiales, portales legislativos, sitios institucionales), 2025-2026. Cada norma fue leída y codificada por un investigador; las Observaciones son resúmenes redactados por el codificador en español, incluso para normas en portugués o inglés. Cada país fue cubierto por un solo investigador: codificador y país están confundidos (V de Cramér 0.99).
- La versión usada en este proyecto está congelada con hash SHA-256 f9797147e7026f796d453fa84d09c4bf32c48ae75c3744912806a72db3ff7f33; GENIAL ha incorporado normas posteriores (p. ej., 23 del Caribe) que no están en ella.

Preprocesamiento

- Normalización de Tipo de norma, texto = título + observaciones, detección de idioma sobre el título, marcado de duplicados por URL, identificador id_norma. Tipo de norma, Investigador y Fecha se excluyen como predictores por diseño.

Usos

- Uso actual: entrenar y evaluar el clasificador de dimensión y el flujo asistido del observatorio; análisis exploratorio; auditoría de equidad por jurisdicción.
- **Usos que deben evitarse://* inferir calidad o rendimiento de los codificadores a partir del modelo (el efecto codificador está confundido con el país); publicar el corpus completo; usar el conteo por dimensión como medida de «calidad» de la política pública de un país sin contexto.*

Distribución

- El corpus completo **no se redistribuye** (autorización del consorcio GENIAL limitada al equipo). Se publican: el hash, las estadísticas agregadas, una muestra anonimizada de 40 normas (data/samples/) y los resultados agregados sin texto de normas. Licencia de la muestra: uso académico con atribución.

Mantenimiento

- Responsable de la versión congelada: coordinación Ecuador de GENIAL (J. Maldonado). Las actualizaciones del corpus generan una nueva versión con nuevo hash, reentrenamiento y nueva auditoría por grupo; los codificadores pueden solicitar la corrección o eliminación de su nombre en cualquier copia.