Nombre del proyecto

Clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe: hacia un Índice de Madurez Normativa (IMN) escalable

Entregable: Documento técnico de presentación del proyecto

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
Gladys María Villegas Rugel	Proyecto Integrador	8 de septiembre de 2026	25 de octubre de 2026

Resumen del Proyecto

Documento técnico de planificación del Proyecto Integrador con los ocho componentes del módulo: estado del arte (29 fuentes de 2021-2026), análisis de tres datasets, métricas con umbrales, stakeholders, alcance SMART, cronograma Scrum en cuatro sprints, plan de recursos con contingencia e hitos. Incluye el diseño «del corpus al índice», 41 referencias IEEE y seis anexos.

Responsables del proyecto

Nombre	Rol	Tareas
Jorge Javier Maldonado Mahauad	Líder de las Fases 1, 2 y 4. Enlace con GENIAL.	Problema y estado del arte; depuración del corpus, variable idioma y muestreo; doble codificación a ciegas y cálculo de κ.
Melissa Figallo	Líder de las Fases 3 y 5.	Rama clásica y rama LLM few-shot con comparación pareada; ética, agregación al IMN, documentación y pitch.

Tabla de contenidos

Resumen ejecutivo 3

1. Introducción: del corpus al índice 3

1.1 Contexto y problema 3
1.2 Selección del problema 4
1.3 La solución en dos flujos: el experimento y la operación 4
1.4 Organización del documento 6

2. Mapa del estado del arte 6

2.1 Método de revisión 6
2.2 Registro de fuentes revisadas 6
2.3 Análisis comparativo de enfoques existentes 8
2.4 Línea de tiempo de avances en el área (2021-2026) 9
2.5 Matriz de fortalezas y debilidades de los enfoques actuales 9
2.6 Identificación del gap 10
2.7 Posicionamiento de la propuesta 11

3. Análisis de datasets disponibles 11

3.1 Criterios de evaluación 11
3.2 Dataset 1: corpus consolidado GENIAL 12
3.3 Dataset 2: MultiEURLEX 13
3.4 Dataset 3: OECD.AI Policy Navigator 13
3.5 Tabla comparativa 13
3.6 Recomendación fundamentada 14
3.7 Plan B ante inaccesibilidad del dataset primario 14
3.8 Limitaciones y sesgos identificados 14
3.9 Plan de adquisición y preprocesamiento 15

4. Definición de métricas de éxito 15

4.1 Por qué los rangos genéricos de la industria no aplican 16
4.2 Métricas técnicas 16
4.3 Métricas de impacto 17
4.4 Métricas de usabilidad para la implementación 18
4.5 Umbrales de éxito 18
4.6 Benchmarks contra soluciones existentes 18
4.7 Protocolo de medición 19

5. Análisis de stakeholders 19

5.1 Identificación completa 19
5.2 Análisis por stakeholder 20
5.3 Matriz de influencia / interés 21
5.4 Plan de comunicación diferenciado 22

6. Documento de alcance del proyecto 22

6.1 Objetivo general (SMART) 22
6.2 Objetivos específicos 23
6.3 Alcance incluido 23
6.4 Alcance excluido 24
6.5 Entregables y criterios de aceptación 25
6.6 Criterios de aceptación del proyecto y procedimientos de validación 25
6.7 Supuestos fundamentales 25
6.8 Limitaciones y restricciones explícitas 26
6.9 Validación SMART del objetivo 26

7. Cronograma con metodología ágil 26

7.1 Adaptación de Scrum a un equipo de dos personas 27

7.2 Product Backlog priorizado....27
7.3 Definition of Done....29
7.4 Sprint 1 · Investigación y diseño (Semanas 1-2: 8 al 21 de septiembre)....29
7.5 Sprint 2 · Desarrollo core (Semanas 3-4: 22 de septiembre al 5 de octubre)....29
7.6 Sprint 3 · Optimización y validación (Semanas 5-6: 6 al 19 de octubre)....30
7.7 Sprint 4 · Finalización y documentación (Semana 7: 20 al 25 de octubre)....31
7.8 Puntos de decisión críticos....32
8. Plan de recursos....32
8.1 Recursos humanos....32
8.2 Recursos técnicos....33
8.3 Recursos financieros....33
8.4 Plan de adquisición y gestión de recursos....34
9. Hitos y entregables....34
9.1 Definición de los ocho hitos....34
9.2 Fechas críticas y dependencias....36
9.3 Procedimientos de revisión y aprobación....36
10. Conclusiones de la fase de planificación y próximos pasos....36
Referencias....37
Anexos....39
Anexo A. Muestra representativa del corpus GENIAL....39
Anexo B. Diccionario de datos del corpus....41
Anexo C. Plantilla del prompt few-shot (v0.1)....41
Anexo D. Estructura del repositorio y contenido del README....42
Anexo E. Matriz de evaluación SMART de los tres problemas....42
Anexo F. Mapa de cumplimiento de la rúbrica....43

Índice de figuras

Figura 1. Flujo del experimento....5
Figura 2. Flujo de operación....5
Figura 3. Corpus GENIAL: distribución por dimensión y por país....12
Figura 4. Cuatro sprints sobre las siete semanas y los ocho hitos....27

Las 36 tablas del documento están numeradas correlativamente y referidas en el texto; el Anexo F las mapea a los componentes de la rúbrica.

Resumen ejecutivo

Este documento presenta la planificación completa del Proyecto Integrador **«Clasificación automática de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe: hacia un Índice de Madurez Normativa (IMN) escalable»**, desarrollado por el Grupo 9 en el marco de la Maestría en Inteligencia Artificial de la UEES y en colaboración con el proyecto GENIAL (Erasmus+). El observatorio regional de GENIAL ha construido un corpus de 813 normas de 27 países, codificadas manualmente en cinco dimensiones conceptuales (Pedagógico, Ética, Administrativo, Protección de Datos y Técnico). Esa codificación es el insumo del IMN y, a la vez, su cuello de botella: no escala al ritmo de la normativa regional, depende del criterio de un único investigador por norma y no cuenta con una medida de fiabilidad intercodificador.

El proyecto propone construir y evaluar un clasificador automático que asigne la dimensión GENIAL a partir del texto de cada norma, comparando dos técnicas de naturaleza contrastante sobre idéntico conjunto de prueba: un modelo clásico (TF-IDF + Regresión Logística) entrenado con unas 700 normas etiquetadas, y un modelo de lenguaje de gran escala en modo *few-shot* que opera con quince ejemplos. La comparación se hará con prueba de McNemar e intervalos de confianza, y el desempeño de ambas ramas se reportará contra el acuerdo humano-humano medido, por primera vez, sobre el mismo conjunto. El resultado se integra en un flujo asistido con umbral de confianza y revisión humana obligatoria para países e idiomas subrepresentados, de modo que el IMN pueda actualizarse sin quedar a merced del modelo.

El documento sigue los ocho componentes exigidos por el módulo: mapa del estado del arte (29 fuentes de 2021-2026 en tres ejes), análisis de tres datasets, definición de métricas con umbrales de aprobación y de excelencia, análisis de nueve categorías de stakeholders, documento de alcance con objetivos SMART, cronograma Scrum en cuatro sprints sobre las siete semanas del calendario del módulo, plan de recursos con contingencia del 20 % y ocho hitos con criterios de aceptación. Los anexos incluyen una muestra real del corpus, el diccionario de datos, la plantilla del *prompt* y la estructura del repositorio de código que acompaña esta entrega.

1. Introducción: del corpus al índice

1.1 Contexto y problema

La regulación de la inteligencia artificial en la educación superior latinoamericana está en plena construcción. Un primer estudio empírico regional sobre 200 instituciones de 19 países encontró que el 73.5 % ya utiliza IA en la docencia, pero solo el 18.5 % dispone de políticas institucionales integrales [1]. Los organismos multilaterales han empezado a responder con modelos de referencia y marcos habilitantes [2], [3], y los índices regionales miden capacidad y preparación en IA [4], [5], pero ninguno publica el procedimiento con el que clasifica documento a documento la normativa que alimenta sus puntajes.

El proyecto GENIAL (*Generación de capacidades de IA en instituciones de educación superior de América Latina*, Erasmus+) construyó para ese vacío un observatorio de normativa: un corpus consolidado de 813 normas —leyes, decretos, estrategias nacionales, reglamentos, resoluciones rectorales, guías éticas y pedagógicas— de 27 países de la región, cada una codificada por un investigador del consorcio en una de las cinco dimensiones activas de su *framework* conceptual. Del conteo de normas por dimensión y por país se deriva el Índice de Madurez Normativa (IMN), que compara la cobertura regulatoria entre países [6].

El problema que este proyecto aborda es operativo y metodológico a la vez. Operativo, porque la codificación es 100 % manual y el IMN solo se recalcula cuando alguien clasifica a mano las normas nuevas; a un ritmo estimado de diez minutos de trabajo experto por norma, una pasada completa del corpus equivale a unas 135 horas-persona, y el corpus crece cada mes. Metodológico, porque cada norma tiene la etiqueta de un único codificador, sin doble codificación ni consenso, y las auditorías internas de calidad ya evidenciaron inconsistencias entre codificadores. El índice hereda ambas debilidades: no se puede actualizar con la frecuencia que exige un marco regulatorio en formación y su reproducibilidad depende de quién codificó cada norma.

1.2 Selección del problema

En la Semana 1 del módulo se propusieron tres problemas reales susceptibles de resolverse con IA y se evaluaron con la matriz SMART ponderada del *workshop* (Específico 20 %, Medible 20 %, Alcanzable 25 %, Relevante 20 %, Temporal 15 %). El problema aquí desarrollado obtuvo 4.20 sobre 5, frente a 3.20 y 2.20 de las alternativas, con ventaja decisiva en los criterios *Alcanzable* y *Temporal*: el corpus existe, está depurado, el equipo tiene acceso operativo a él y la autorización formal del consorcio ya fue concedida, de modo que el proyecto es ejecutable dentro de la ventana de siete semanas del módulo. La matriz completa se adjunta como material complementario (Anexo E).

La retroalimentación docente al foro validó la elección y reubicó el riesgo: no en conseguir datos, sino en el diseño metodológico fino. Señaló cuatro puntos —etiqueta única frente a multi-etiqueta, balance de clases, tratamiento del desacuerdo intercodificador e idioma del corpus— que debían quedar resueltos antes de iniciar el desarrollo. Esos cuatro puntos se resolvieron en un documento de decisiones metodológicas vinculante, cuyo contenido se resume en la Tabla 1 y atraviesa todo este documento.

Tabla 1. Las cuatro condiciones metodológicas del tutor y la decisión adoptada para cada una.

Condición	Riesgo que señala	Decisión adoptada	Dónde se materializa
Etiqueta única vs. multi-etiqueta	Una ley nacional puede pertenecer legítimamente a varias dimensiones; forzar una sola impone un techo al F1 alcanzable.	Se mantiene la tarea *single-label* (es lo único que el gold standard soporta) y se añade un diagnóstico de multi-etiqueta: ambas ramas registran su 1.ª y 2.ª dimensión y cada error se tipifica.	§4.2 (top-2 accuracy), §6.3, Sprint 3, Hito H7
Balance de clases	Razón 4.7:1; con un conjunto de prueba pequeño la diferencia entre técnicas puede no ser significativa.	F1 macro como métrica principal, *class_weight* balanceado, conjunto de prueba de 100-150 casos estratificado, prueba de McNemar e intervalos de confianza [7]–[9].	§4.2, §4.5, Sprint 3
Desacuerdo intercodificador	Ningún clasificador puede superar la fiabilidad de su propio estándar de referencia; hoy esa fiabilidad no está medida.	Doble codificación a ciegas del conjunto de prueba por un segundo investigador de GENIAL, regla de gold standard fijada antes de medir, y κ modelo-humano contrastado con κ humano-humano [10], [11].	§4.3 (KPI 4), §6.6, Sprint 3, Hito H6
Idioma	El corpus incluye portugués (Brasil, 81 normas) e inglés (Caribe anglófono) pero no registra la variable idioma; TF-IDF no transfiere entre idiomas.	Se incorpora la variable *idioma* al corpus, se estratifica el muestreo por dimensión e idioma y todas las métricas se desagregan por idioma y por país.	§3.9, §4.2, Sprint 2, Hito H3

1.3 La solución en dos flujos: el experimento y la operación

El proyecto tiene dos flujos encadenados y conviene no mezclarlos. El primero es un **experimento**: decide, con evidencia, qué técnica clasifica mejor las normas del corpus. El segundo es la **operación**: describe cómo se usa la técnica ganadora sobre cada norma nueva sin que el índice quede a merced del modelo. Las Figuras 1 y 2 representan ambos flujos; el primero ocupa los Sprints 2 y 3 del cronograma, el segundo se especifica en el Sprint 3 y su implementación en el flujo operativo de GENIAL queda fuera del alcance del trabajo de titulación.

1.3.1 El experimento

El corpus de 813 normas se depura (corrección del único valor faltante de la variable objetivo, normalización de la metadata, incorporación de la variable idioma) y se particiona de forma estratificada por dimensión e idioma en tres subconjuntos con funciones distintas. El **conjunto de entrenamiento** (en torno a 700 normas etiquetadas) alimenta al modelo clásico. El **pool few-shot** (15 normas, tres por dimensión) no entrena nada: va dentro del *prompt* del LLM como ejemplos de cómo codifica el equipo GENIAL. El **conjunto de prueba a ciegas** (100-150 normas, con las etiquetas guardadas en un archivo separado que solo se abre después de registrar las predicciones) se entrega, idéntico, a tres clasificadores: el modelo clásico, el LLM y un segundo codificador humano del consorcio.

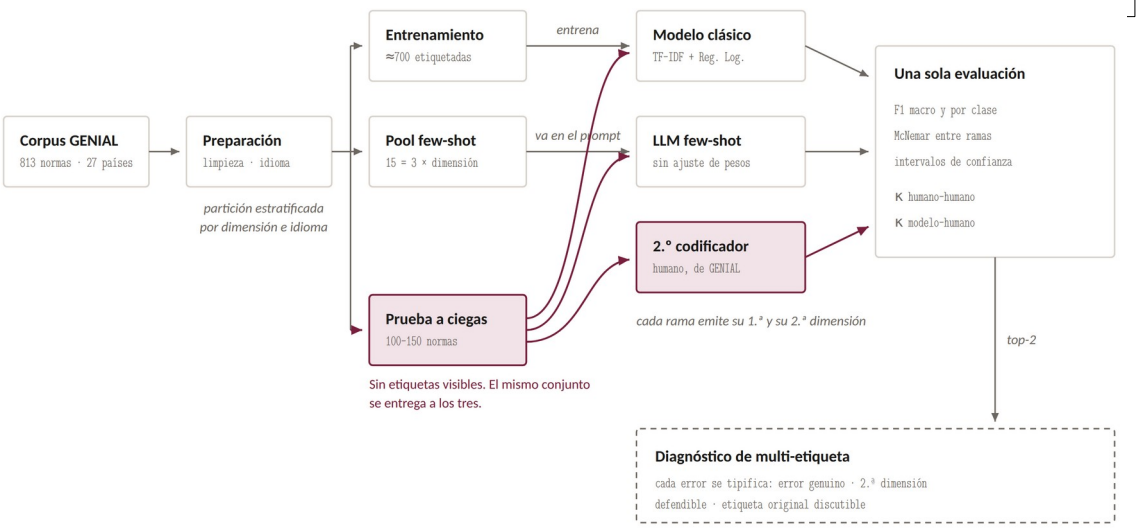


Figura 1. Flujo del experimento. El mismo conjunto de prueba a ciegas se entrega a los dos modelos y a un segundo codificador humano; los tres resultados convergen en una única evaluación, de la que cuelga el diagnóstico de multi-etiqueta.

El experimento entero descansa en esa pieza: el conjunto de prueba a ciegas va a los dos modelos y *también* al segundo codificador humano. De ahí salen las dos respuestas que el proyecto necesita. Comparar las dos ramas sobre idéntico conjunto responde qué técnica es mejor, y el diseño pareado permite usar la prueba de McNemar en lugar de una prueba de proporciones independientes [8]. Comparar el acuerdo modelo-humano con el acuerdo humano-humano responde algo más difícil: cuánto margen queda realmente por encima. Ningún clasificador puede superar la fiabilidad de su propio estándar de referencia [12], [13]; por eso el codificador humano está dentro del diagrama y no fuera.

Cada rama emite su primera y su segunda dimensión. Esa lista ordenada, y no una etiqueta suelta, es lo que permite el diagnóstico de multi-etiqueta que pidió la tutora sin cambiar la tarea: cada error del conjunto de prueba se tipificará como *error genuino* (la segunda dimensión tampoco tiene sentido), *segunda dimensión defendible* (la norma es realmente ambigua y el modelo acertó en segunda posición) o *etiqueta original discutible* (el gold standard es el que falla). Si una fracción alta de los errores cae en las dos últimas categorías, el proyecto tendrá evidencia empírica de que la tarea real de GENIAL no es asignar una dimensión sino proponer una lista corta ordenada para validación humana, y esa evidencia se devolverá al consorcio como recomendación sobre su esquema de codificación.

1.3.2 La operación

Una vez elegida la técnica, cada norma nueva entra al clasificador, que devuelve una dimensión, una alternativa y una probabilidad. La probabilidad decide el camino: si la confianza es alta, la predicción pasa directamente al IMN; si es baja, la norma se enruta a revisión humana, y el codificador recibe las dos candidatas en lugar de una adivinanza. La flecha que baja hacia la revisión humana es el argumento ético completo dibujado en una línea, y **no depende solo de la probabilidad**: toda norma de un país o un idioma subrepresentado en el corpus pasa por revisión aunque el modelo esté seguro, porque el error del modelo no se distribuye de forma uniforme y el índice compara países. Cada versión del IMN distingue, además, qué normas codificó un humano y cuáles el modelo, y publica el margen de error por dimensión.

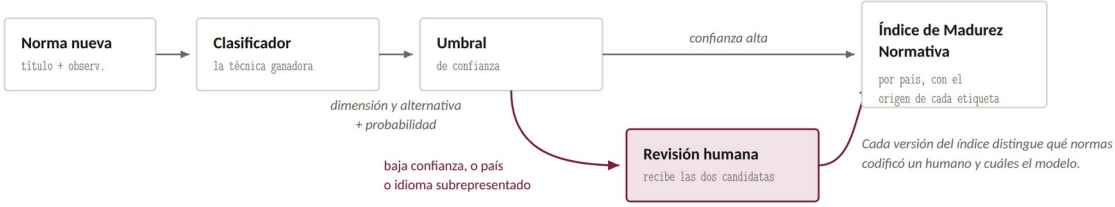


Figura 2. Flujo de operación. La salida del clasificador es una etiqueta con su alternativa y su probabilidad; el umbral de confianza y la regla de país o idioma subrepresentado deciden si la norma entra al índice directamente o a través de revisión humana.

Lo que los dos diagramas hacen visible

El proyecto no promete un clasificador que acierte, sino un procedimiento que sabe cuándo no confiar en sí mismo. Las dos piezas que lo garantizan —el codificador humano dentro del experimento y la revisión obligatoria dentro de la operación— son las mismas que, si se quitaran del diagrama, dejarían un sistema mucho más simple y mucho menos defendible.

1.4 Organización del documento

Las secciones 2 a 9 corresponden, en orden, a los ocho componentes obligatorios del Proyecto Integrador: mapa del estado del arte, análisis de datasets, métricas de éxito, análisis de stakeholders, documento de alcance, cronograma con metodología ágil, plan de recursos, e hitos y entregables. La sección 10 cierra con las conclusiones de la fase de planificación y los próximos pasos inmediatos. Siguen las referencias en formato IEEE y seis anexos: muestra del corpus, diccionario de datos, plantilla del *prompt*, estructura del repositorio, matriz de evaluación SMART y mapa de cumplimiento de la rúbrica. Todo el contenido está redactado en modo de planificación: describe lo que el proyecto hará y cómo lo medirá; ninguna cifra de desempeño se presenta como resultado obtenido.

2. Mapa del estado del arte

Esta sección revisa 29 fuentes del período 2021-2026, todas verificadas contra fuente primaria (Crossref, ACL Anthology, arXiv, NeurIPS Proceedings o el sitio oficial del organismo emisor), compara seis enfoques existentes, traza la línea de tiempo del área e identifica el vacío que el proyecto aborda. La revisión supera el mínimo de 20 fuentes de los últimos cinco años y cubre las cuatro categorías exigidas: revistas de alto impacto (PNAS, Computational Linguistics, TACL, Artificial Intelligence and Law), conferencias reconocidas (NeurIPS, ACL, EMNLP, LREC-COLING), repositorios técnicos (arXiv) y reportes de organismos (BID, CEPAL, UNESCO IESALC, Oxford Insights).

2.1 Método de revisión

Las fuentes se organizaron en tres ejes que corresponden a las tres preguntas que el proyecto necesita responder. El **Eje A** (11 fuentes) cubre la clasificación automática de texto legal y normativo y la evidencia sobre aprendizaje *few-shot* frente a modelos afinados: responde con qué técnicas es razonable atacar la tarea y qué desempeño documenta la literatura. El **Eje B** (9 fuentes) cubre el uso de modelos de lenguaje como anotadores y la fiabilidad intercodificador: responde cómo debe evaluarse un clasificador cuya etiqueta de referencia es un juicio humano. El **Eje C** (9 fuentes) cubre la gobernanza de la IA en la educación superior y los índices de madurez regional: responde en qué vacío de dominio se inserta el proyecto. El Eje B no aparecía en la revisión bibliográfica inicial y es el que sostiene el aporte metodológico central del trabajo.

Criterios de inclusión: publicación entre 2021 y 2026; pertinencia directa a al menos una de las tres preguntas; verificación del DOI, del identificador arXiv o de la referencia institucional. Se excluyeron trabajos anteriores a 2021 salvo las referencias metodológicas clásicas de estadística y fiabilidad (κ de Cohen, prueba de McNemar, intervalo de Wilson), que se citan como fundamento de método y no como estado del arte.

2.2 Registro de fuentes revisadas

Tabla 2. Registro de las 29 fuentes revisadas, por eje. El número entre corchetes remite a la lista de referencias.

Eje	Ref.	Autores y año	Aporte / título abreviado	Fuente	Tipo
A	[14]	Chalkidis, Fergadiotis y Androutsopoulos (2021)	MultiEURLEX: clasificación legal multilingüe y multietiqueta para transferencia *zero-shot* entre idiomas	EMNLP 2021	Conferencia
A	[15]	Chalkidis et al. (2022)	LexGLUE: *benchmark* de comprensión de lenguaje legal en inglés	ACL 2022	Conferencia
A	[16]	Chalkidis (2023)	ChatGPT frente al *benchmark* LexGLUE (47.6 % micro-F1 en *zero-shot*)	arXiv / SSRN	Preprint

Eje	Ref.	Autores y año	Aporte / título abreviado	Fuente	Tipo
A	[17]	Guha et al. (2023)	LegalBench: *benchmark* colaborativo de razonamiento legal con LLM	NeurIPS 2023 D&B	Conferencia
A	[18]	Tang, C. et al. (2023)	PolicyGPT: análisis automatizado de políticas de privacidad con LLM (97 % de exactitud)	arXiv	Preprint
A	[19]	Edwards y Camacho-Collados (2024)	¿Es suficiente el aprendizaje en contexto para clasificar texto? Afinar sigue ganando en 16 conjuntos	LREC-COLING 2024	Conferencia
A	[20]	Sebők et al. (2025)	Babel Machine: clasificación temática multilingüe de política pública con modelos abiertos	Social Science Computer Review	Journal
A	[21]	Gunes y Florczak (2025)	¿Reemplazar o potenciar al codificador humano? Clasificación multiclase de documentos de política con LLM	J. Computational Social Science	Journal
A	[22]	Lee (2025)	Clasificación de texto legal: de ML tradicional a LLM con explicabilidad (TF-IDF 85 % vs. BERT afinado 99 %)	Artificial Intelligence and Law	Journal
A	[23]	Chae y Davidson (2025)	LLM para clasificación de texto: de *zero-shot* a *instruction-tuning*	Sociological Methods & Research	Journal
A	[24]	Tang, Y. et al. (2025)	El dilema *few-shot*: *over-prompting*, óptimo entre 5 y 20 ejemplos	arXiv	Preprint
B	[12]	Plank (2022)	El «problema» de la variación humana en las etiquetas: la verdad de referencia en datos, modelado y evaluación	EMNLP 2022	Conferencia
B	[25]	Davani, Díaz y Prabhakaran (2022)	Más allá del voto de mayoría: el desacuerdo entre anotadores es informativo y modelable	TACL	Journal
B	[26]	Gilardi, Alizadeh y Kubli (2023)	ChatGPT supera a *crowd-workers* en tareas de anotación de texto	PNAS	Journal
B	[13]	Pangakis, Wolken y Fasching (2023)	La anotación automatizada con IA generativa exige validación contra etiquetas humanas	arXiv	Preprint
B	[27]	Chew et al. (2023)	Análisis de contenido asistido por LLM: codificación deductiva con acuerdo medido (AC1 de 0.18 a 0.76 según el código)	arXiv	Preprint
B	[28]	Heseltine y Clemm von Hohenberg (2024)	LLM como sustituto de expertos humanos en anotación de texto político	Research & Politics	Journal
B	[29]	Ziems et al. (2024)	¿Pueden los LLM transformar la ciencia social computacional? (25 *benchmarks*)	Computational Linguistics	Journal
B	[30]	Rathje et al. (2024)	GPT como herramienta multilingüe de análisis psicológico de texto	PNAS	Journal
B	[31]	Schroeder, Roy y Kabbara (2025)	¿Basta con poner un humano en el circuito? Exponer las sugerencias del modelo infla el desempeño medido	Findings of ACL 2025	Conferencia
C	[32]	Wu, Zhang y Carroll (2024)	Gobernanza de IA en educación superior: guías de 14 universidades *Big Ten*	Future Internet	Journal
C	[33]	Jin et al. (2025)	IA generativa en educación superior: perspectiva global de políticas institucionales (40 documentos codificados a mano)	Computers and Education: AI	Journal
C	[34]	Jiang, Xie y Cao (2025)	Efectividad de políticas institucionales sobre IA generativa en educación superior	Higher Education Quarterly	Journal
C	[35]	Kaya-Kasikci et al. (2025)	Posicionamiento universitario en políticas de IA: políticas nacionales y actores no estatales	Higher Education Quarterly	Journal
C	[2]	Levy Yeyati / BID (2025)	Un marco regulatorio habilitante para la IA en América Latina y el Caribe	BID, IDB-TN-3241	Reporte

Eje	Ref.	Autores y año	Aporte / título abreviado	Fuente	Tipo
C	[4]	Oxford Insights (2025)	Government AI Readiness Index 2025 (8.ª edición)	Oxford Insights	Reporte
C	[1]	Valentini (2026)	Adopción y gobernanza de IA en la educación superior de ALC: encuesta a 200 IES de 19 países	Rev. Educación Superior y Sociedad (UNESCO IESALC)	Journal
C	[3]	Martorell y Porrúa / BID (2026)	Modelo de referencia para políticas de IA en el sector público de ALC (tres niveles de madurez)	BID	Reporte
C	[5]	CEPAL y CENIA (2026)	Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025	CEPAL, LC/TS.2026/1	Reporte

Registro completo: 29 fuentes (11 del Eje A, 9 del Eje B y 9 del Eje C), todas de 2021-2026.

2.3 Análisis comparativo de enfoques existentes

Se comparan seis enfoques que abordan problemas análogos —clasificar documentos normativos o de política en categorías definidas por expertos—, uno más de los cinco exigidos. Los dos primeros son las ramas del proyecto; los cuatro restantes fijan los referentes con los que se juzgarán sus resultados y justifican decisiones de diseño concretas: el tamaño del pool *few-shot*, el descarte del *transformer* afinado y el protocolo de doble codificación ciega.

Tabla 3. Tabla comparativa de metodologías existentes y su aplicabilidad al proyecto.

Enfoque / referencias	Técnica o modelo	Fortalezas	Debilidades	Aplicabilidad a este proyecto
Modelos lineales sobre bolsa de palabras [15], [22]	TF-IDF (1-2 gramas) + Regresión Logística multiclase con ponderación de clases	Interpretable: permite inspeccionar qué términos predicen cada dimensión. Reproducible sin dependencias externas. Devuelve una probabilidad calibrable que habilita el umbral de confianza. Costo de inferencia nulo una vez entrenado.	Opera sobre formas superficiales: no hay transferencia entre idiomas. Sensible al desbalance. Techo bajo en clases temáticamente heterogéneas; Lee (2025) lo sitúa en 85 % frente al 99 % de un BERT afinado.	Rama 1 y línea base obligada: sin ella no hay contra qué comparar el LLM. Su límite previsible es estructural en un corpus multilingüe.
***Transformers* preentrenados en dominio legal y afinados [15], [22]**	Legal-BERT, KLUE-BERT u otros *encoders* afinados sobre el corpus objetivo	Mejor desempeño documentado en clasificación legal: superan a los genéricos en las siete tareas de LexGLUE. Capturan contexto y no solo léxico.	Requieren miles de ejemplos etiquetados para afinar de forma robusta y acceso a repositorios de modelos. Poco interpretables.	Descartado en este ciclo: 813 registros con dos clases por debajo de 75 casos. Declarado como trabajo futuro, no como omisión.
LLM en modo *zero-shot* [16], [18]	Modelo de lenguaje de gran escala con la sola definición de la tarea	No requiere dato etiquetado. Multilingüe de forma nativa. PolicyGPT reporta 97 % clasificando fragmentos de políticas de privacidad en 10 categorías.	Resultados extremadamente dispares según el dominio: 47.6 % de micro-F1 en LexGLUE. Sin ejemplos no hay forma de transmitir un criterio de codificación propio.	Insuficiente por sí solo: las dimensiones GENIAL son un esquema construido por el observatorio, no categorías de sentido común.
LLM en modo *few-shot* / aprendizaje en contexto [19], [21], [24]	*Prompt* con definiciones de las dimensiones y un pool reducido de ejemplos etiquetados, sin actualización de pesos	Transmite el criterio de codificación con muy pocos ejemplos y es multilingüe. En este proyecto operará con 15 ejemplos frente a ~700 de la rama clásica: unas 50 veces menos datos etiquetados.	Evidencia contradictoria: afinar modelos pequeños sigue superando al *few-shot* en 16 conjuntos. Costo por llamada. *Over-prompting*: el desempeño se maximiza entre 5 y 20 ejemplos y decae después.	Rama 2 del proyecto. El hallazgo de *over-prompting* justifica el tamaño del pool (15) y advierte contra asumir que ampliarlo mejoraría el F1 macro.
Clasificación temática multilingüe de política pública con modelos abiertos afinados [20]	Modelos abiertos afinados sobre el esquema del Comparative Agendas Project (21 categorías, 9	Antecedente más cercano: clasificación temática multilingüe de documentos de política. F1 macro ponderado > 0.75 en 24 de 41 combinaciones idioma-dominio;	El desempeño cae a 0.55-0.63 en validación externa, fuera del corpus de afinado. Requiere un corpus de entrenamiento de gran escala.	Fija el orden de magnitud de F1 macro razonable en esta familia de tareas y advierte sobre la caída esperable al aplicar el modelo a países no

Enfoque / referencias	Técnica o modelo	Fortalezas	Debilidades	Aplicabilidad a este proyecto
	idiomas)	> 0.90 en seis.		representados.
LLM como segundo codificador con validación humana obligatoria [13], [26], [27], [31]	Codificación deductiva asistida por LLM, evaluada con κ de Cohen o AC1 contra codificadores humanos	Reencuadra el problema: deja de preguntarse si el modelo «acierta» y pasa a medir si su acuerdo con un humano es comparable al acuerdo entre dos humanos. Gilardi et al. reportan acuerdo intercodificador del LLM superior al de anotadores entrenados, a menos de USD 0.003 por anotación.	Chew et al. muestran que el acuerdo se desploma en códigos específicos (AC1 de 0.18 y 0.36 frente a más de 0.76 en códigos bien comprendidos). Schroeder et al. demuestran que exponer las sugerencias del modelo al codificador humano infla el desempeño medido.	Diseño que adopta el proyecto para la evaluación de fiabilidad, y razón por la que la doble codificación debe ser ciega e independiente. La caída por código específico anticipa lo que ocurre con la dimensión Técnico.

2.4 Línea de tiempo de avances en el área (2021-2026)

Tabla 4. Hitos del área en los últimos cinco años y su implicación para el proyecto.

Año	Hito o avance principal	Ref.
2021	MultiEURLEX fija el estándar de clasificación multietiqueta y multilingüe de texto normativo: 65 000 normas de la UE en 23 idiomas, y la primera documentación sistemática del olvido catastrófico del conocimiento multilingüe al afinar en un solo idioma.	[14]
2022	Dos avances en direcciones opuestas que juntos definen el problema: LexGLUE consolida el *benchmark* de comprensión legal y muestra la ventaja de los modelos preentrenados en dominio; Plank formaliza la variación entre anotadores humanos como propiedad estructural del dato y no como ruido eliminable, y Davani et al. muestran que el desacuerdo es informativo y modelable.	[12], [15], [25]
2023	Irrupción del LLM como anotador, con evidencia inmediatamente contradictoria: supera a *crowd-workers* en anotación y PolicyGPT reporta 97 % en políticas de privacidad, mientras Chalkidis mide 47.6 % de micro-F1 en LexGLUE. Pangakis et al. concluyen que la validación contra etiquetas humanas es imprescindible. Queda instalada la dependencia del dominio que obliga a comparar empíricamente en cada corpus.	[13], [16], [18], [26]
2024	Se consolida el contrapeso: afinar modelos pequeños sigue siendo competitivo frente al *few-shot* en 16 conjuntos, y los LLM *zero-shot* no superan a los modelos ajustados en 25 *benchmarks* de ciencia social computacional. Aparece el primer mapeo global de políticas institucionales de IA generativa en educación superior: de 60 universidades muestreadas, solo 41 tenían documentos publicados.	[19], [29], [33]
2025	Madura el uso del LLM como codificador en ciencias sociales, con dos advertencias decisivas: el desempeño depende del número de ejemplos con un óptimo entre 5 y 20, y exponer las sugerencias del modelo al humano contamina el estándar de referencia. Se publican índices de madurez de política de IA con cobertura regional.	[4], [21], [24], [31]
2026	Primer estudio empírico regional sobre adopción y gobernanza de IA en educación superior de ALC (200 IES de 19 países: 73.5 % usa IA en docencia, 18.5 % tiene políticas integrales) y primer modelo de referencia del BID que clasifica a los países en tres niveles de madurez, diagnosticando «mucho plan y poca acción».	[1], [3], [5]

2.5 Matriz de fortalezas y debilidades de los enfoques actuales

La Tabla 5 resume los seis enfoques frente a los seis criterios que importan para un observatorio regional con un corpus pequeño, multilingüe y etiquetado por expertos. La escala es cualitativa (● alto / favorable, ◐ medio, ○ bajo / desfavorable) y sintetiza la evidencia de la Tabla 3.

Tabla 5. Matriz de fortalezas y debilidades: ● favorable · ◐ intermedio · ○ desfavorable.

Enfoque	Pocos datos etiquetados	Multilingüe	Interpretable	Bajo costo de inferencia	Reproducible sin acceso externo	Desempeño documentado en dominio legal
TF-IDF + Reg. Logística	◐	○	●	●	●	◐

Enfoque	Pocos datos etiquetados	Multilingüe	Interpretable	Bajo costo de inferencia	Reproducible sin acceso externo	Desempeño documentado en dominio legal
Transformer legal afinado	○	◐	○	◐	○	●
LLM *zero-shot*	●	●	◐	◐	○	○
LLM *few-shot*	●	●	◐	◐	○	◐
Modelos abiertos afinados (Babel Machine)	○	●	○	◐	◐	●
LLM como 2.° codificador con validación humana	●	●	◐	◐	○	◐

La lectura de la matriz explica el diseño comparativo: ningún enfoque domina en todas las columnas. La rama clásica gana en interpretabilidad, costo y reproducibilidad, y pierde en multilingüismo; la rama *few-shot* gana en eficiencia de datos y multilingüismo, y pierde en reproducibilidad (depende de un proveedor externo y de la estabilidad del modelo entre ejecuciones). Los *transformers* afinados, que dominan en desempeño documentado, exigen un volumen de datos etiquetados del que el proyecto no dispone. La comparación empírica sobre el corpus propio, y no la elección a priori de una técnica, es por tanto la decisión metodológica correcta.

2.6 Identificación del gap

2.6.1 Limitaciones de las soluciones actuales

1. **Los *benchmarks* de clasificación legal son europeos o estadounidenses y sus taxonomías son ajenas al problema.** MultiEURLEX usa conceptos EUROVOC, LexGLUE usa artículos del CEDH y tipos de cláusula contractual, LegalBench usa tareas de razonamiento jurídico anglosajón [14], [15], [17]. Ninguno contiene dimensiones de gobernanza de IA, ninguno se refiere a educación superior y ninguno incluye América Latina.
2. **La evidencia sobre LLM *few-shot* frente a modelos clásicos es contradictoria y fuertemente dependiente del dominio:** 97 % de exactitud en PolicyGPT frente a 47.6 % de micro-F1 en LexGLUE; 72.6 % de GPT-4 *few-shot* frente a 99.3 % de un *encoder* afinado en Lee (2025) [16], [18], [22]. Esa dispersión impide extrapolar y convierte la comparación empírica sobre el corpus propio en un requisito.
3. **La literatura de gobernanza de IA en educación superior es descriptiva y manual.** Jin et al. codifican a mano 40 documentos, Wu et al. analizan 14 universidades y Valentini encuesta 200 instituciones [1], [32], [33]: todos describen qué políticas existen y qué temas cubren, pero ninguno propone un mecanismo para sostener esa codificación a escala ni a lo largo del tiempo.
4. **Los índices regionales miden capacidad y preparación, no cobertura normativa por dimensión.** El Government AI Readiness Index, el ILIA y el modelo de referencia del BID puntúan países en pilares de infraestructura, talento y adopción [3]–[5], pero ninguno publica el procedimiento de clasificación documental que alimenta sus puntajes ni permite auditar cómo se asignó cada documento a cada dimensión.
5. **La literatura sobre anotación asistida por LLM asume corpus con doble codificación previa.** Gilardi et al., Chew et al. y Pangakis et al. comparan el modelo contra un estándar humano ya consolidado [13], [26], [27]; prácticamente ninguna aborda el caso real de un corpus etiquetado por un único codificador por documento, que es la situación de la mayoría de los observatorios en funcionamiento, incluido GENIAL.

2.6.2 Gap específico que aborda el proyecto

No existe, en las 29 fuentes revisadas, una aplicación sistemática de clasificación automática a un corpus de normativa sobre inteligencia artificial en la educación superior latinoamericana. El proyecto aborda ese vacío en tres planos simultáneos: **de dominio**, al aplicar clasificación automática a las dimensiones del *framework* GENIAL sobre 813 normas de 27 países, un objeto que los *benchmarks* existentes no cubren ni por jurisdicción ni

por taxonomía; **metodológico**, al comparar un enfoque clásico y uno *few-shot* sobre idéntico conjunto de prueba con prueba de significancia, en lugar de asumir la superioridad de uno sobre otro; y **de validez**, al reportar el desempeño del modelo contra el acuerdo humano-humano medido sobre el mismo conjunto, atacando directamente la limitación del corpus de un solo codificador que la literatura de anotación con LLM no aborda.

2.7 Posicionamiento de la propuesta

1. **Corpus y dominio inéditos.** Es el primer trabajo conocido que aplica clasificación automática al corpus regional de ALC codificado en las dimensiones del *framework* GENIAL. Donde la literatura de gobernanza describe políticas codificándolas a mano, este proyecto construye el mecanismo que permite sostener esa codificación a escala; donde los *benchmarks* legales ofrecen método, este trabajo aporta el dominio que les falta.
2. **Diseño comparativo en lugar de supuesto.** La contradicción documentada en la literatura (del 97 % de PolicyGPT al 47.6 % de LexGLUE) se convierte en la justificación de un experimento pareado sobre idéntico conjunto de prueba, con prueba de McNemar e intervalos de confianza. El resultado se enunciará además en términos de **eficiencia de datos** —cuánto desempeño se obtiene por ejemplo etiquetado—, que es la métrica que decide si un observatorio puede automatizar sin financiar miles de horas de etiquetado.
3. **La fiabilidad humana como referente explícito.** Siguiendo a Plank sobre la variación entre anotadores y a Pangakis et al. sobre la validación obligatoria [12], [13], el desempeño no se reportará en abstracto sino contra el κ humano-humano medido en el mismo conjunto, con codificación ciega e independiente para evitar la contaminación que documentan Schroeder et al. [31]. Esto responde a la limitación central del corpus en lugar de solo declararla.
4. **El error como diagnóstico del *framework*, no solo del modelo.** El diseño contempla comparar los patrones de error de dos técnicas de naturaleza completamente distinta. Si ambas convergieran en las mismas fronteras conceptuales —Administrativo-Ética es la candidata más probable—, la hipótesis más económica no sería que los dos modelos son deficientes sino que esas fronteras no están bien delimitadas en el *framework*. El clasificador operaría entonces como instrumento de auditoría del constructo, un uso que la literatura revisada no explota y que devolvería a GENIAL un hallazgo que la codificación manual no puede producir.

3. Análisis de datasets disponibles

Esta sección evalúa tres conjuntos de datos potenciales con los mismos cinco criterios que exige el módulo —descripción técnica, procedencia, calidad, idoneidad y accesibilidad—, los compara, fundamenta la recomendación del dataset principal, define el plan B y detalla el plan de adquisición y preprocesamiento. Conviene declarar de entrada una particularidad: este proyecto no parte de la búsqueda de un dataset, sino de un corpus propio ya construido por el equipo de investigación de GENIAL. La variable objetivo —la dimensión conceptual del *framework* GENIAL— es una codificación experta que no existe en ningún corpus público, de modo que los datasets alternativos no son intercambiables con el principal: sirven para transferir método y para validación externa, no para sustituir el objeto de estudio.

3.1 Criterios de evaluación

Cada dataset se evalúa en cinco dimensiones, puntuadas de 1 a 5 para la tabla comparativa: **tamaño y estructura** (registros, columnas, formato, longitud del texto); **procedencia** (fuente, licencia, condiciones de uso y redistribución); **calidad** (completitud, consistencia, representatividad y fiabilidad de la etiqueta); **idoneidad** (correspondencia entre su variable objetivo y las cinco dimensiones GENIAL, cobertura de la jurisdicción de interés); y **accesibilidad** (disponibilidad, costo, restricciones). La idoneidad tiene peso decisivo: un corpus grande y limpio con una taxonomía ajena no permite calcular el IMN.

3.2 Dataset 1: corpus consolidado GENIAL

3.2.1 Descripción técnica

Archivo *consolidado_limpio.xlsx* (hoja «Datos limpios»), 813 normas × 13 columnas, de 27 países de América Latina y el Caribe (28 jurisdicciones si se cuenta Puerto Rico por separado) [6]. Formato XLSX, una hoja de datos y una hoja de estadísticas; lectura con *pandas* + *openpyxl*. Las 13 columnas son: Investigador, País, Título de la Norma, Tipo de norma, Estado, Organismo Emisor/Universidad, Dominio, Vínculo con Educación, Dedicación del Texto, Fecha de Publicación, URL Oficial, Observaciones y Ámbito (el diccionario de datos completo está en el Anexo B). La **variable objetivo** es *Dominio* (cinco clases). El **texto de entrada** del modelo es la concatenación de *Título de la Norma* y *Observaciones*: entre 6 y 274 palabras por norma, con mediana de 44 y media de 51, es decir, textos cortos que resumen el contenido de la norma, no el articulado completo.

La distribución de la variable objetivo es: Pedagógico 294 (36.2 %), Ética 265 (32.6 %), Administrativo 120 (14.8 %), Protección de Datos 71 (8.7 %, incluido el único registro sin etiqueta, corregido con criterio experto) y Técnico 63 (7.7 %). La razón de desbalance entre la clase mayor y la menor es 4.7:1. Por ámbito, 563 normas son institucionales (69 %) y 250 nacionales (31 %); por vínculo con la educación, 604 son directas y 209 indirectas; 719 están vigentes y 91 en proyecto o borrador. La Figura 3 muestra la distribución por dimensión y la concentración geográfica.

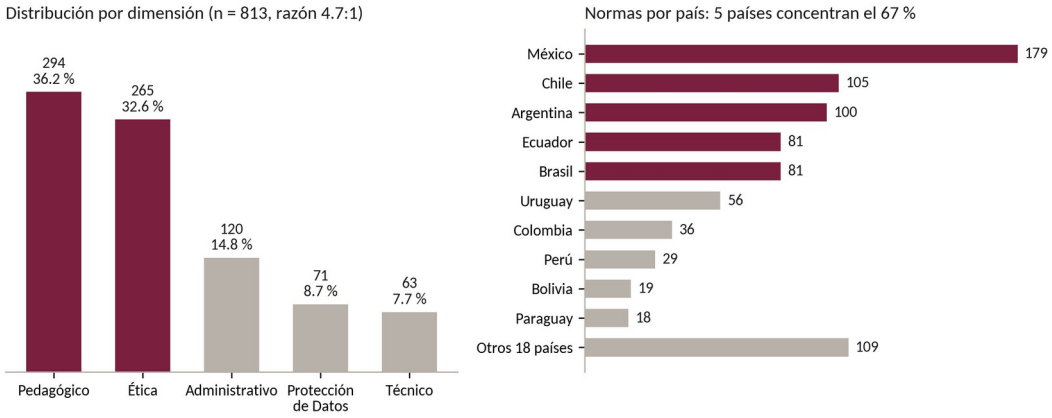


Figura 3. Corpus GENIAL: distribución de las 813 normas por dimensión (izquierda) y por país (derecha). Cinco países concentran el 67 % del corpus; 18 aportan menos de 20 normas cada uno.

3.2.2 Procedencia

Corpus de investigación interno del proyecto GENIAL (Erasmus+), construido entre 2024 y 2026 por diez investigadores del consorcio y no publicado. Las normas originales son documentos públicos y el corpus registra la URL oficial de cada una; la codificación en dimensiones es obra intelectual del equipo investigador y no tiene licencia pública. Su uso en este trabajo cuenta con **autorización formal de la coordinación del consorcio**, con la condición de atribuir al proyecto GENIAL toda publicación derivada y de no redistribuir el archivo completo: solo pueden difundirse estadísticas agregadas y ejemplos puntuales. El repositorio de código que acompaña esta entrega incluye, por ello, una muestra reducida y anonimizada (Anexo A) y no el corpus.

3.2.3 Calidad

Completitud alta en las variables que el modelo usa: un solo valor faltante en *Dominio* (0.12 %), uno en *Observaciones*, dos en *Estado* y dos en *Fecha de Publicación*. **Consistencia media:** *Tipo de norma* presenta 14 categorías nominales que se reducen a 11 al normalizar la capitalización («Estrategia Nacional» / «Estrategia nacional», «Lineamiento Académico» / «Lineamiento académico»); *Fecha de Publicación* es texto libre con formatos mixtos y valores como «N/D», «s/f» o «No indica» en aproximadamente una cuarta parte de los registros, por lo que no se usará como variable; y se detectan 16 URL oficiales repetidas y 22 títulos repetidos, que deben inspeccionarse como posibles duplicados antes de particionar el corpus. **Representatividad parcial:** el corpus documenta bien a los países con mayor producción normativa (México 179, Chile 105, Argentina 100, Ecuador 81, Brasil 81) y de forma escasa al resto (Cuba y Trinidad y Tobago aportan una norma cada uno). **Fiabilidad de la etiqueta no medida:** cada norma fue codificada por un único investigador, sin doble codificación ni consenso.

3.2.4 Idoneidad

Máxima y no sustituible. Es el único corpus conocido que codifica normativa sobre IA en educación superior de ALC en las dimensiones del *framework* GENIAL. El problema de investigación —escalar la codificación del observatorio— solo existe sobre este corpus, y las cinco clases son exactamente las dimensiones cuyo conteo alimenta el IMN, de modo que la salida del clasificador es directamente utilizable.

3.2.5 Accesibilidad

Acceso operativo directo del equipo por su participación en el proyecto, con autorización formal ya concedida. Costo de adquisición USD 0; el costo relevante es de producción: las 813 normas representan aproximadamente 135 horas-persona de codificación experta ya invertidas por el consorcio. Restricción: no redistribuible.

3.3 Dataset 2: MultiEURLEX

Descripción técnica. 65 000 normas de la Unión Europea (55 000 de entrenamiento, 5 000 de validación, 5 000 de prueba) en hasta 23 idiomas, incluidos español y portugués, con etiquetas multietiqueta EUROVOC en cuatro niveles jerárquicos (21 categorías en el nivel 1) [14]. Formato JSON/Parquet distribuido vía Hugging Face (*coastalcph/multi_eurlex*) [36]; textos de longitud completa (articulado). **Procedencia.** Publicado en EMNLP 2021 a partir de EUR-Lex; licencia CC-BY-4.0, acceso público sin registro. **Calidad.** Completitud alta, etiquetado institucional (EUROVOC lo asignan documentalistas del Parlamento Europeo), consistencia alta, representatividad plena de la jurisdicción europea. **Idoneidad.** Baja para el objeto de estudio: la taxonomía EUROVOC no se corresponde con dimensiones de gobernanza de IA, la jurisdicción es europea y no hay cobertura de América Latina; el IMN no sería calculable. Alta, en cambio, como banco de pruebas metodológico: permite ensayar la arquitectura, el protocolo de evaluación y el estudio de transferencia entre idiomas —el artículo documenta precisamente el olvido catastrófico del conocimiento multilingüe al afinar en un solo idioma —. **Accesibilidad.** Inmediata, gratuita, sin restricciones.

3.4 Dataset 3: OECD.AI Policy Navigator

Descripción técnica. Base de datos de políticas nacionales de IA del Observatorio de Políticas de IA de la OCDE: en torno a 2 500 iniciativas de política de más de 80 jurisdicciones, con cobertura confirmada de países de ALC (Brasil, México, Colombia, entre otros), etiquetadas por tipo de instrumento, estado y carácter vinculante o no vinculante [37]. **Procedencia.** OCDE, acceso público sin registro; términos de uso de la OCDE (reutilización con atribución). **Calidad.** Curación institucional y actualización continua, pero sin el texto completo de las normas: solo fichas resumidas en inglés, y sin exportación masiva documentada, lo que obligaría a una extracción automatizada previa. **Idoneidad.** Media-baja: no está codificado en dimensiones GENIAL ni se centra en educación superior; su valor real es servir de **conjunto de validación externa** para el esquema de clasificación por tipo de instrumento y para contrastar la cobertura de normas nacionales del corpus GENIAL contra un inventario independiente. **Accesibilidad.** Pública y gratuita, con la restricción práctica de la ausencia de exportación.

3.5 Tabla comparativa

Tabla 6. Comparación de los tres datasets evaluados (puntaje 1-5 por criterio; la idoneidad tiene peso decisivo).

Criterio	D1 · Corpus GENIAL	D2 · MultiEURLEX	D3 · OECD.AI Policy Navigator
Tamaño y estructura	813 normas × 13 columnas; textos cortos (mediana 44 palabras). Puntaje 3	65 000 normas, articulado completo, 23 idiomas. Puntaje 5	≈2 500 fichas resumidas, sin texto completo. Puntaje 2
Procedencia y licencia	Interno, sin licencia pública; uso autorizado, no redistribuible. Puntaje 3	CC-BY-4.0, EMNLP 2021 / Hugging Face. Puntaje 5	OCDE, acceso público con atribución. Puntaje 4
Calidad de la etiqueta	Experta pero de un único codificador; fiabilidad no medida. Puntaje 3	Institucional (EUROVOC), consistente. Puntaje 5	Curación institucional; etiqueta de tipo de instrumento, no temática. Puntaje 3

Criterio	D1 · Corpus GENIAL	D2 · MultiEURLEX	D3 · OECD.AI Policy Navigator
Idoneidad para el problema	Única fuente de la variable objetivo; cobertura ALC. Puntaje 5	Taxonomía y jurisdicción ajenas; útil solo como banco metodológico. Puntaje 1	Sin dimensiones GENIAL; útil como validación externa. Puntaje 2
Accesibilidad	Acceso operativo directo, USD 0. Puntaje 4	Inmediata y gratuita. Puntaje 5	Pública sin exportación masiva. Puntaje 3
Ventajas principales	Alineación exacta con el IMN; corpus depurado y caracterizado; conocimiento de primera mano de su construcción.	Escala, licencia abierta, multilingüismo, referencia publicada.	Inventario independiente y actualizado de política nacional de IA con cobertura ALC.
Desventajas principales	Tamaño limitado (dos clases < 75 casos); etiqueta de un solo codificador; no público; sin variable idioma registrada.	Objeto de estudio distinto: el IMN dejaría de ser calculable.	Sin texto completo ni exportación; en inglés; no cubre normativa institucional.
Rol en el proyecto	**Dataset principal**	**Plan B principal (transferencia de método)**	**Plan B secundario (validación externa)**

3.6 Recomendación fundamentada

Dataset principal seleccionado: corpus consolidado GENIAL (*consolidado_limpio.xlsx*, 813 normas de 27 países). La selección no es el resultado de comparar alternativas equivalentes, sino de reconocer que la variable objetivo del proyecto solo existe en este corpus: la dimensión GENIAL es un esquema de codificación construido por el propio observatorio, y es precisamente el cuello de botella que el proyecto busca escalar. Sin ese etiquetado experto no hay tarea de aprendizaje supervisado que plantear ni IMN que calcular. A esto se suman tres razones operativas: el corpus está disponible y depurado hoy, lo que hace el proyecto ejecutable dentro de las siete semanas del módulo; su distribución de clases y de países ya está caracterizada, de modo que los sesgos son declarables antes de empezar y no se descubren a mitad del desarrollo; y el equipo conoce de primera mano cómo se construyó, lo que permitirá interpretar los errores del modelo como evidencia sobre el *framework* y no solo como fallos técnicos.

3.7 Plan B ante inaccesibilidad del dataset primario

La autorización del consorcio ya está concedida, de modo que el escenario de inaccesibilidad es de baja probabilidad; se planifica igualmente. **Plan B principal: MultiEURLEX.** Permitiría salvar la arquitectura, el protocolo de evaluación pareada y el estudio de transferencia entre idiomas, con lo que la contribución metodológica del trabajo sobreviviría; no salvaría el objeto de estudio, porque la taxonomía EUROVOC no se corresponde con dimensiones de gobernanza de IA y el IMN dejaría de ser calculable. **Plan B secundario: OECD.AI Policy Navigator**, como conjunto de validación externa del esquema de clasificación por tipo de instrumento, previa extracción automatizada de las fichas. **Contingencia intermedia**, la más probable si el problema fuera de plazos y no de acceso: trabajar solo con estadísticas agregadas del corpus GENIAL y posponer toda publicación de resultados desagregados por país.

3.8 Limitaciones y sesgos identificados

Tabla 7. Sesgos del corpus principal, su gravedad para el IMN y la mitigación planificada.

Sesgo	Evidencia en el corpus	Por qué importa	Mitigación planificada
Geográfico	5 países concentran el 67 % (México 179, Chile 105, Argentina 100, Ecuador 81, Brasil 81); 3 países aportan 1 o 2 normas.	Es el más grave: el error del modelo no se distribuye de forma uniforme y el IMN compara países.	Desempeño desagregado por país; revisión humana obligatoria para países subrepresentados antes de que sus predicciones entren al índice.
De clase	Razón 4.7:1; Técnico (63) y Protección de	Una métrica agregada puede ser alta	F1 macro como métrica principal;

Sesgo	Evidencia en el corpus	Por qué importa	Mitigación planificada
	Datos (71) por debajo de 75 casos.	mientras las clases minoritarias —las que el IMN necesita medir bien— se clasifican mal.	*class_weight* balanceado; umbral mínimo de F1 por clase; muestreo de prueba estratificado.
De codificador	Diez investigadores codificaron el corpus; cada norma tiene una sola etiqueta, sin doble codificación. La columna Investigador permite estudiar la consistencia entre codificadores.	El modelo aprende a imitar juicios individuales; su desempeño carece de referente sin una medida de acuerdo humano-humano.	Doble codificación ciega del conjunto de prueba; κ humano-humano como techo de referencia; exclusión de la columna Investigador como variable predictora.
Lingüístico	Estimación por país: ≈81 normas en portugués (Brasil, 10 %), ≈29 en inglés (Caribe anglófono, 3.6 %), el resto en español; el corpus no registra la variable idioma.	Un modelo de bolsa de palabras entrenado en español no transfiere a esos documentos. Los sesgos geográfico y lingüístico coinciden: los países subrepresentados son los de idioma minoritario.	Variable idioma añadida por detección automática con verificación manual; muestreo estratificado por idioma; métricas desagregadas por idioma.
De fuga de información	*Tipo de norma* está asociado a la dimensión (las «guías pedagógicas» son casi todas Pedagógico) y asignarlo a una norma nueva exige el mismo trabajo experto que se busca evitar. 16 URL repetidas sugieren posibles duplicados.	Un modelo que use la metadata parecería bueno sin haber leído el texto; un duplicado repartido entre entrenamiento y prueba infla las métricas.	Línea base de metadata que cuantifica la señal de *Tipo de norma* y fundamenta su exclusión; deduplicación por URL antes de particionar.

3.9 Plan de adquisición y preprocesamiento

1. **Autorización y congelado de versión (Sprint 1, completado).** Obtenida la autorización del consorcio, se congela una versión fechada del archivo consolidado con su hash SHA-256 registrado en el repositorio, para que todos los resultados sean reproducibles sobre exactamente el mismo corpus aunque el observatorio siga creciendo. El archivo no se versiona en el repositorio público; sí su hash y su ficha de metadatos.
2. **Limpieza y enriquecimiento (Sprint 2).** Corregir el valor faltante de *Dominio* con criterio experto documentado (la norma es una política de privacidad universitaria: Protección de Datos); normalizar la capitalización de *Tipo de norma* (14 → 11 categorías); inspeccionar los 16 pares de URL repetida y resolver duplicados; añadir la variable *idioma* por detección automática sobre el texto, con verificación manual de los registros no hispanohablantes, que son pocos y decisivos; documentar la heterogeneidad de *Fecha de Publicación* y excluirla como variable.
3. **Construcción del campo de texto y línea base de metadata (Sprint 2).** Concatenar *Título de la Norma* + *Observaciones* como texto de entrada; construir la línea base que predice la dimensión únicamente a partir de *Tipo de norma* para cuantificar su señal y fundamentar su exclusión del conjunto de variables predictoras; verificar operativamente que *Dominio* es *single-label* (sin separadores múltiples) y registrar el resultado.
4. **Muestreo del experimento (Sprint 2).** Con muestreo estratificado por dimensión e idioma, extraer el pool *few-shot* (15 normas, 3 por dimensión) y el conjunto de prueba ciego (100-150 normas), garantizando presencia de normas en portugués e inglés; guardar las etiquetas reales del conjunto de prueba en un archivo separado (*test_labels_hidden.csv*) que solo se abre después de registrar las predicciones de ambas ramas y del segundo codificador. El muestreo se valida con criterio de dominio antes de cerrar el sprint.

4. Definición de métricas de éxito

Esta sección define las métricas técnicas, de impacto y de usabilidad con las que se juzgará el proyecto, fija los umbrales de aprobación y de excelencia, y sitúa esos umbrales frente a los *benchmarks* de la literatura. Todas las

métricas se declaran antes de ejecutar el experimento y quedan fijadas en el repositorio; ninguna se ajustará después de ver los resultados.

4.1 Por qué los rangos genéricos de la industria no aplican

Los rangos típicos de las matrices de KPIs para clasificación supervisada (exactitud 70-95 %, F1 75-90 %) suponen tareas con un estándar de referencia fiable y categorías bien separadas. Esta tarea no cumple ninguno de los dos supuestos: la variable objetivo es una codificación conceptual asignada por un único investigador por norma, sin fiabilidad intercodificador medida, y dos de las cinco dimensiones tienen fronteras discutibles dentro del propio *framework*. Los *targets* del proyecto no se fijan, por tanto, contra los rangos genéricos sino contra tres referentes propios: las **líneas base medidas sobre el corpus**, el **acuerdo entre codificadores humanos** y el **esfuerzo humano que el sistema sustituye**. Un F1 macro de 0.70 en esta tarea no es un mal resultado frente al 75-90 % de la industria; es un resultado que hay que leer contra el techo que impone la fiabilidad del propio estándar [11], [12].

Dos referencias numéricas ya se conocen sin entrenar nada, por aritmética sobre la distribución de clases: un predictor que respondiera siempre la clase mayoritaria (Pedagógico, 294 de 813) alcanzaría **36.2 % de exactitud y 0.106 de F1 macro** (F1 de Pedagógico = 0.531, cero en las otras cuatro clases, promediado entre cinco). A ellas se sumará, en el Sprint 2, la línea base de metadata construida sobre *Tipo de norma*. Cualquier modelo que no supere con claridad ambas líneas base no justifica el uso de IA, y el proyecto lo dirá.

4.2 Métricas técnicas

Tabla 8. Métricas técnicas del algoritmo: primarias, secundarias y de eficiencia.

Tipo	Métrica	Definición y cálculo	Por qué se elige	Meta
Primaria	F1 macro sobre el conjunto de prueba pareado	Promedio no ponderado del F1 de las cinco clases; se reporta con IC bootstrap al 95 % y con el valor *p* de McNemar entre ramas [7], [8].	El desbalance 4.7:1 hace que exactitud y F1 *weighted* oculten el desempeño en las clases minoritarias, que son las que el IMN necesita medir bien.	≥ 0.70, y ninguna clase con F1 < 0.50. Piso: 0.106.
Secundaria	F1 por clase (seguimiento de Técnico)	F1 de cada dimensión con su matriz de confusión completa.	Detecta el subajuste de clase: la métrica agregada puede mejorar mientras la clase más pequeña y heterogénea sigue sin aprenderse.	Técnico ≥ 0.50; Protección de Datos, la de vocabulario más distintivo, se anticipa como la mejor.
	Exactitud (accuracy)	Proporción de aciertos, con IC de Wilson al 95 % [9].	Comparable con la literatura; nunca se reporta sola.	≥ 70 %. Piso: 36.2 %.
	Recall por clase	VP / (VP + FN) para cada dimensión; nunca agregado.	Las clases minoritarias que el modelo deja de detectar desaparecen del IMN.	Técnico y Protección de Datos ≥ 60 % cada una.
	Precisión por clase	VP / (VP + FP) para cada dimensión.	Complementa el recall: una clase inflada con falsos positivos distorsiona el índice tanto como una omitida.	Se reporta; sin umbral propio.
	Top-2 accuracy	Proporción de casos en que la etiqueta de referencia está entre las dos dimensiones predichas.	Es la métrica del diagnóstico de multi-etiqueta: si supera con claridad a la exactitud simple, la tarea real es proponer una lista corta ordenada.	Se reporta junto a la tipificación de errores.
	κ de Cohen modelo-humano	Acuerdo corregido por azar entre las predicciones y la etiqueta de referencia, para ambas ramas [10].	Sitúa al modelo dentro del mismo marco de fiabilidad con que GENIAL audita a sus codificadores.	κ modelo-humano ≥ κ humano-humano (véase §4.3).
Eficiencia	Ejemplos etiquetados requeridos	Número de normas etiquetadas que consume cada rama para alcanzar su desempeño (≈700 frente a 15).	Es la variable que decide si un observatorio puede automatizar sin financiar miles de horas de etiquetado.	Se reporta como razón de eficiencia de datos.

Tipo	Métrica	Definición y cálculo	Por qué se elige	Meta
	Tiempo por pasada completa	Tiempo de pared para clasificar las 813 normas, medido en el Sprint 3.	El IMN debe poder recalcularse el mismo día en que se incorporan normas nuevas.	≤ 1 jornada de trabajo.
	Costo de inferencia por pasada	Consumo de la API del LLM para una pasada completa, en USD; USD 0 para la rama clásica.	Se contrapone al costo de oportunidad de las horas de investigador.	< USD 5 por pasada.
	Estabilidad entre ejecuciones	Variación del F1 macro del LLM en tres ejecuciones repetidas con temperatura fija.	Un clasificador que cambia de opinión entre ejecuciones no es auditable.	Se reporta como limitación medida, no como supuesto.

4.3 Métricas de impacto

Tabla 9. KPIs de negocio, de adopción y de satisfacción (o sus sustitutos verificables).

Categoría	KPI	Baseline actual	Target	Frecuencia y método
Negocio	Horas-persona de codificación ahorradas por pasada completa del corpus	100 % manual. Supuesto declarado: 10 min de trabajo experto por norma → ≈135 h-persona por pasada; a validar con el equipo GENIAL antes de reportar cifras.	≥ 100 h-persona ahorradas (reducción ≥ 75 % del esfuerzo).	Una vez por pasada; se calcula a partir de la proporción de normas que no requieren revisión humana.
	Costo de inferencia frente a costo de oportunidad	USD 0 de inferencia y ≈135 h de investigador por pasada.	< USD 5 de inferencia por pasada.	Por pasada; consumo real de la API.
	Frecuencia de actualización del IMN	Esporádica: solo cuando alguien codifica a mano las normas nuevas.	Recalculable el mismo día de la incorporación de normas.	Por versión del IMN; tiempo entre incorporación y publicación.
Adopción	Proporción de normas enrutadas a revisión humana por baja confianza	100 %: hoy toda norma se codifica manualmente.	≤ 30 % del corpus enrutado, manteniendo la exactitud del 70 % restante ≥ 85 %. Revisión obligatoria, al margen del umbral, para países e idiomas subrepresentados.	Por pasada, desagregada por dimensión, país e idioma.
	Tasa de aceptación de la sugerencia por el codificador humano	No aplica (no hay sugerencias hoy).	≥ 80 % de los casos revisados aceptan la 1.ª o la 2.ª candidata del modelo.	En el ejercicio de revisión del Sprint 3; conteo directo.
Satisfacción (sustituto)	κ de Cohen modelo-humano contrastado con κ humano-humano sobre el mismo conjunto	NO MEDIDO: el corpus tiene un único codificador por norma. Establecer este baseline es un entregable del proyecto.	κ modelo-humano ≥ κ humano-humano: el modelo es un codificador tan consistente como un investigador del equipo.	Una vez por ciclo de auditoría, con el protocolo de fiabilidad intercodificador v1.0 de GENIAL (κ de Cohen, κ de Fleiss, α de Krippendorff [38]).
	Valoración cualitativa de los codificadores de GENIAL	No aplica.	Los codificadores juzgan útil la lista corta ordenada en el taller de cierre (registro cualitativo, sin escala numérica).	Taller de cierre del Sprint 4.

No se definen NPS, CSAT, usuarios activos diarios ni incremento de ingresos: el proyecto es de investigación, sin finalidad comercial y sin servicio en producción dentro del alcance. Declararlo evita comprometer indicadores que el proyecto no puede medir; los sustitutos elegidos (κ y tasa de aceptación) son verificables por un tercero.

4.4 Métricas de usabilidad para la implementación

El entregable técnico es un *pipeline* reproducible, no una aplicación con interfaz, de modo que las métricas de usabilidad se refieren al flujo asistido de la Figura 2 y a la reproducibilidad del propio *pipeline*: **(a) carga humana residual**, horas-persona necesarias para revisar las normas enrutadas en una pasada, estimada por simulación en el Sprint 3 y contrastada con el supuesto de 10 minutos por norma; **(b) tiempo por norma revisada** cuando el codificador recibe las dos candidatas frente a codificar desde cero, medido con los codificadores de GENIAL sobre una submuestra; **(c) trazabilidad**, el 100 % de las etiquetas del IMN debe llevar registrado su origen (humano o modelo, con la probabilidad); y **(d) reproducibilidad**, el *notebook* debe ejecutarse de extremo a extremo con semilla fija y versiones declaradas, regenerando los cinco KPIs, la matriz de confusión, las métricas desagregadas y la tabla del IMN, verificado por el integrante del equipo que no lo escribió.

4.5 Umbrales de éxito

Tabla 10. Umbrales de aprobación y de excelencia por métrica.

Métrica	Mínimo aceptable (aprobación)	Objetivo de excelencia	Comparación con *benchmarks*
F1 macro (mejor rama)	≥ 0.60 y superior a ambas líneas base con McNemar $p < 0.05$	≥ 0.70 con IC cuyo límite inferior supere 0.60	Babel Machine cae a 0.55-0.63 en validación externa [20]; 0.70 sobre un corpus pequeño y multilingüe sería un resultado alto para la familia de tareas.
F1 por clase	Ninguna clase con F1 < 0.40	Ninguna clase con F1 < 0.50; Técnico ≥ 0.50	Chew et al. documentan caídas a AC1 0.18-0.36 en códigos específicos [27]: el umbral por clase evita que una media aceptable esconda una dimensión no aprendida.
Recall de clases minoritarias	≥ 50 % en Técnico y Protección de Datos	≥ 60 % en ambas	Sin referente directo en la literatura; se fija por el uso del IMN, que compara cobertura por dimensión.
κ modelo-humano	≥ 0.60 (acuerdo «sustancial» según Landis y Koch [11])	≥ κ humano-humano medido sobre el mismo conjunto	Gilardi et al. reportan acuerdo del LLM superior al de anotadores entrenados [26]; el referente propio es el κ humano-humano.
Comparación entre ramas	Diferencia reportada con IC y valor *p*, cualquiera sea el signo	Diferencia significativa, o desempeño equivalente con ~50 veces menos ejemplos etiquetados	Edwards y Camacho-Collados muestran que afinar sigue ganando en 16 conjuntos [19]; equivalencia con 15 ejemplos ya sería un resultado de eficiencia de datos relevante.
Enrutamiento a revisión humana	≤ 40 % del corpus	≤ 30 %, con exactitud ≥ 85 % en el tramo automático	Sin *benchmark* externo; se deriva del KPI de ahorro de horas-persona.
Reproducibilidad	El *notebook* se ejecuta de extremo a extremo	Ejecutado por el integrante que no lo escribió, con resultados idénticos	Práctica estándar de ciencia abierta; requisito para publicar el código con el trabajo.

4.6 Benchmarks contra soluciones existentes

No existe una solución desplegada para esta tarea con la que compararse directamente; los *benchmarks* pertinentes son los resultados publicados sobre tareas análogas (Tabla 11), que fijan el orden de magnitud esperable y, sobre todo, advierten sobre la dispersión entre dominios. La comparación honesta del proyecto es doble: **interna**, contra las dos líneas base sin IA (clase mayoritaria y metadata) y entre las dos ramas; y **externa**, situando el F1 macro obtenido frente a los valores de la Tabla 11 con las cautelas que impone la diferencia de corpus, idioma y tamaño.

Tabla 11. Resultados publicados en tareas análogas, como referentes de orden de magnitud.

Trabajo	Tarea y corpus	Técnica	Resultado reportado	Lectura para este proyecto
Lee (2025) [22]	Clasificación de texto legal coreano	TF-IDF + ML clásico vs. BERT afinado vs. GPT-4 *few-shot*	≈85 % · 99.3 % · 72.6 %	El clásico no es despreciable; el LLM *few-shot* puede quedar por debajo

Trabajo	Tarea y corpus	Técnica	Resultado reportado	Lectura para este proyecto
				en dominios muy especializados.
Chalkidis (2023) [16]	LexGLUE, 7 tareas legales en inglés	ChatGPT *zero-shot*	47.6 % micro-F1 promedio	Sin ejemplos, el LLM no transmite un criterio de codificación propio.
Tang, C. et al. (2023) [18]	Políticas de privacidad, 10 categorías	LLM *zero-shot*	97 % de exactitud	Extremo superior de la dispersión: categorías de sentido común, textos homogéneos.
Sebők et al. (2025) [20]	Política pública, 21 temas, 9 idiomas	Modelos abiertos afinados	F1 macro ponderado > 0.75 en 24 de 41 combinaciones; 0.55-0.63 en validación externa	Orden de magnitud realista para clasificación temática multilingüe de política; caída esperable fuera del corpus de afinado.
Gunes y Florczak (2025) [21]	Documentos de política, multiclase	LLM como codificador	Desempeño dependiente del número de ejemplos y de la claridad de las categorías	Refuerza el pool de 15 ejemplos y la tipificación de errores por categoría.
Gilardi et al. (2023) [26]	Anotación de *tweets*, varias tareas	ChatGPT vs. *crowd-workers*	Acuerdo intercodificador del LLM superior al de anotadores; < USD 0.003 por anotación	Referente de costo y del encuadre «modelo como segundo codificador».

4.7 Protocolo de medición

Las métricas técnicas se calculan en cada corrida de evaluación —al cierre de los Sprints 2, 3 y 4— sobre el conjunto de prueba pareado, con *scikit-learn* [39] para F1, exactitud, recall, precisión, matriz de confusión y κ, e implementaciones propias documentadas para McNemar, el IC de Wilson y el *bootstrap* del F1 macro (2 000 remuestreos, semilla fija). Toda métrica se acompaña de su intervalo de confianza y, cuando compara ramas, del valor *p*; se desagrega por idioma y por país; y se registra en un archivo de resultados versionado junto al *prompt* y a la configuración del modelo que la produjo. No se implementa un *dashboard* en vivo: el sistema no opera en producción dentro del alcance y el equivalente funcional es el *notebook* reproducible, que regenera las tablas de KPIs al ejecutarse.

5. Análisis de stakeholders

Se identifican los actores involucrados en las nueve categorías que exige el módulo, se describe para cada uno su rol, influencia, necesidades, resistencias previsibles y estrategia de involucramiento, se construye la matriz de influencia/interés y se define un plan de comunicación diferenciado. Dos stakeholders condicionan hoy el cronograma: la coordinación de GENIAL, que autoriza el corpus y designó al segundo codificador, y el docente-tutor del módulo, que fijó las cuatro condiciones metodológicas que rigen el diseño.

5.1 Identificación completa

Tabla 12. Mapa de las nueve categorías de stakeholders del módulo a los actores concretos del proyecto.

Grupo	Categoría	Actor concreto en este proyecto	Influencia	Interés
Primarios	Usuarios finales directos	Investigadores codificadores del proyecto GENIAL (diez personas codificaron el corpus)	Media	Alto
	Beneficiarios del sistema	Instituciones de educación superior de los 27 países del corpus, que consultan el IMN para situar su marco normativo	Baja	Medio
	Decisores de implementación	Coordinación general del proyecto GENIAL (Université de Toulouse y socios), que decide si el flujo asistido entra al observatorio	Alta	Alto
Secundarios	Reguladores y entes de control	Organismos de política pública y agencias de aseguramiento de la calidad	Alta	Medio

Grupo	Categoría	Actor concreto en este proyecto	Influencia	Interés
		de ALC, potenciales consumidores de comparaciones entre países		
	Proveedores de datos y tecnología	Consorcio GENIAL como proveedor del corpus; proveedor de la API del LLM (Anthropic, o modelo abierto Qwen como alternativa) como proveedor tecnológico	Media	Bajo
	Competidores indirectos	Índices y observatorios existentes: Government AI Readiness Index, ILIA (CEPAL-CENIA), modelo de referencia del BID, OECD.AI [3]–[5], [37]	Baja	Bajo
Clave	Sponsors o financiadores	Proyecto GENIAL (Erasmus+) como sponsor del problema; docente-tutor del Proyecto Integrador (UEES) como evaluador del trabajo	Alta	Alto
	Expertos del dominio	Segundo y tercer codificador de GENIAL (doble codificación ciega y adjudicación de discrepancias); comunidad académica de IA en educación y de IA y derecho como revisora	Media	Alto
	Implementadores técnicos	Equipo del proyecto: Jorge Maldonado Mahauad y Melissa Figallo	Alta	Alto

5.2 Análisis por stakeholder

Tabla 13. Rol e influencia, necesidades, resistencias previsibles y estrategia de involucramiento.

Stakeholder	Rol e influencia	Necesidades y expectativas	Resistencias o barreras previsibles	Estrategia de involucramiento
Investigadores codificadores de GENIAL (usuarios finales)	Codifican hoy cada norma a mano; su criterio es el estándar contra el que se mide el modelo. Influencia media: no deciden, pero sin su adhesión el flujo asistido no se adopta.	Reducir la carga de codificación sin perder el control del criterio experto. Que el sistema explique por qué propone cada dimensión, no solo qué propone.	Desconfianza ante una máquina que replica un juicio propio. Temor a que el modelo se use para evaluar su desempeño individual, dado que el corpus registra qué investigador codificó cada norma.	Presentarlo desde el inicio como *triage* y segundo codificador, nunca como reemplazo. Mostrarles los errores del modelo antes que sus aciertos. Involucrarlos en la tipificación cualitativa de errores, de modo que sean ellos quienes juzguen al modelo y no al revés. La columna Investigador no se usa como variable ni se reporta por persona.
Coordinación general de GENIAL (decisor y sponsor)	Autoriza el uso del corpus (concedido), designó al segundo codificador y decide si el flujo asistido se integra al observatorio. Influencia alta.	Que el IMN sea actualizable al ritmo de la normativa regional y defendible ante terceros; trazabilidad de cada etiqueta.	Riesgo reputacional si el observatorio se percibe como un índice automatizado. Reticencia a que un trabajo académico externo al consorcio publique resultados desagregados por país.	Compromiso explícito de trazabilidad: toda versión del IMN distingue qué normas codificó un humano y cuáles el modelo, y publica el margen de error por dimensión. Reporte al cierre de cada sprint. Resultados por país solo con margen de error y previa revisión del consorcio.
Docente-tutor del Proyecto Integrador (evaluador)	Evalúa el trabajo con la rúbrica del módulo. Fijó cuatro condiciones metodológicas. Influencia alta.	Rigor metodológico demostrable y cumplimiento de los entregables en la ventana de siete semanas.	Ya señaló que el riesgo está en el diseño fino: etiqueta única frente a multi-etiqueta, balance de clases, desacuerdo intercodificador e idioma.	Documento de decisiones metodológicas entregado antes de iniciar el desarrollo; anticipar las objeciones en lugar de esperarlas; reportar las limitaciones con la misma prominencia que los resultados.
Instituciones de educación superior de los 27 países (beneficiarias)	Consumidoras del IMN; no participan en su construcción. Influencia baja, interés medio.	Situar su propio marco normativo y orientar sus políticas institucionales de IA [40].	Desacuerdo con la clasificación asignada a sus propias normas, sobre todo en fronteras ambiguas como Administrativo-Ética, donde	Publicar el método de clasificación junto con el índice y habilitar un mecanismo de corrección: una institución debe poder señalar una

Stakeholder	Rol e influencia	Necesidades y expectativas	Resistencias o barreras previsibles	Estrategia de involucramiento
			es previsible que discrepen tanto el modelo como los codificadores humanos.	clasificación errónea y que esa corrección alimente el corpus.
Organismos de política pública y agencias de calidad (reguladores)	Potenciales usuarios de comparaciones entre países. Influencia alta sobre la legitimidad del observatorio; interés medio hoy.	Comparaciones entre países confiables para orientar decisiones de política de IA en educación.	Rechazo a ser posicionados en un *ranking* calculado parcialmente con IA, en especial los países subrepresentados, donde el error del modelo es mayor y no se distribuye de forma uniforme.	No publicar comparaciones entre países sin margen de error ni sin la proporción de normas codificadas automáticamente. Revisión humana obligatoria de toda predicción sobre países e idiomas subrepresentados antes de que entre al índice.
Proveedores de datos y tecnología	El consorcio provee el corpus; el proveedor de la API provee el modelo de la rama LLM. Influencia media (una interrupción del servicio detendría la rama LLM).	Uso conforme a los términos: atribución y no redistribución del corpus; términos de servicio de la API.	Cambios de versión del modelo entre ejecuciones; cuota o disponibilidad insuficiente; costo.	Fijar y registrar la versión del modelo y la temperatura; *prompt* versionado; alternativa con modelo abierto (Qwen) documentada; presupuesto de API con contingencia.
Competidores indirectos (índices y observatorios existentes)	Miden capacidad y preparación en IA a escala de país; no clasifican normativa por dimensión ni se centran en educación superior. Influencia baja.	No aplica directamente; son referentes de posicionamiento.	Ninguna activa; riesgo de que el IMN se compare con ellos sin considerar que mide otra cosa.	Posicionar el IMN como complementario: cobertura normativa por dimensión con procedimiento de clasificación publicado y auditable, algo que ninguno de ellos ofrece.
Expertos del dominio: 2.° y 3.er codificador de GENIAL; comunidad académica	El segundo codificador produce el referente humano-humano; el tercero adjudica discrepancias. La comunidad académica revisa el trabajo. Influencia media, interés alto.	Protocolo de codificación claro y ciego; validez metodológica, replicabilidad y contribución original frente al estado del arte.	Carga de trabajo adicional (100-150 normas); crítica previsible al tamaño del conjunto de prueba, a la ausencia de κ en el corpus base y a la comparación con una sola ejecución del LLM.	Cuadernillo de codificación y regla de gold standard fijada antes de medir; ejecuciones repetidas del LLM; publicar el código, los *prompts* versionados, el conjunto de prueba y el protocolo de fiabilidad; reportar IC y McNemar en lugar de diferencias puntuales.
Equipo del proyecto (implementadores)	Diseña, ejecuta y documenta. Influencia alta, interés alto.	Reparto claro de roles, acceso al corpus y a la API, tiempo protegido (8 h/semana por persona).	Cronograma sin holgura; dependencia de terceros en el Sprint 3.	Roles Scrum definidos (§7.1), bitácora de decisiones, revisión cruzada de todo entregable.

5.3 Matriz de influencia / interés

Tabla 14. Matriz de influencia/interés y estrategia genérica por cuadrante.

	Interés bajo o medio	Interés alto
Influencia alta	Mantener satisfechos: organismos de política pública y agencias de aseguramiento de la calidad. Hoy no siguen el proyecto, pero si el IMN se usa para comparar países su reacción puede condicionar la legitimidad del observatorio entero.	Gestionar de cerca: coordinación general de GENIAL, docente-tutor y equipo del proyecto. Son quienes pueden detener el proyecto —uno por la vía de la autorización del corpus, otro por la vía de la evaluación— y ambos ya expresaron condiciones concretas.
Influencia media o baja	Monitorear: instituciones de educación superior de los países del corpus, proveedores tecnológicos y competidores indirectos. Consumidores finales o referentes sin participación en la construcción; basta con seguirlos y habilitar un canal de corrección.	Mantener informados: investigadores codificadores de GENIAL, segundo y tercer codificador, y comunidad académica. Su interés es alto y su adhesión determina que la solución se adopte y que el trabajo resista revisión por pares.

5.4 Plan de comunicación diferenciado

Tabla 15. Plan de comunicación por stakeholder: canal, frecuencia y mensaje clave.

Stakeholder	Canal	Frecuencia	Mensaje clave
Coordinación general de GENIAL	Correo formal (autorización, ya concedida); reunión en línea para los avances	Reporte al cierre de cada sprint	«El modelo asiste, no sustituye: toda predicción de baja confianza vuelve a revisión humana y el IMN distingue el origen de cada etiqueta.»
Docente-tutor del Proyecto Integrador	Entregables del módulo y foro del curso; *sprint review*	Semanal, según el calendario de entregas; revisión al cierre de cada sprint	«Cada decisión metodológica está documentada, justificada con evidencia y acompañada de sus límites; los cuatro puntos señalados quedaron resueltos antes de iniciar el desarrollo.»
Investigadores codificadores de GENIAL	Taller de trabajo (presencial o en línea) e informe de errores del modelo	Al inicio de la doble codificación (Sprint 3) y al cierre, con los resultados	«Tu criterio es el estándar contra el que se mide el modelo, no al revés: si el modelo y tú discrepan, el caso vuelve a revisión humana.»
2.° y 3.er codificador	Cuadernillo de codificación y sesión de calibración de 30 minutos	Una sesión previa; adjudicación al cierre del Sprint 3	«Codifica a ciegas, sin ver las predicciones del modelo ni la etiqueta original: de eso depende que el κ sea válido.»
Organismos de política pública y agencias de calidad	Reporte técnico del IMN con anexo metodológico	En cada publicación de una versión del IMN	«El índice se publica con su margen de error por dimensión y con la proporción de normas codificadas automáticamente; los países subrepresentados llevan revisión humana obligatoria.»
Instituciones de educación superior	Publicación del método junto al índice; canal de corrección	Con cada versión del IMN	«Toda institución puede señalar una clasificación errónea de su norma y esa corrección alimenta el corpus.»
Comunidad académica	Artículo y repositorio público con *notebook*, *prompts* y protocolo	Al cierre del proyecto	«Resultado reproducible: código, *prompts* versionados, conjunto de prueba y protocolo de fiabilidad disponibles; las limitaciones se reportan con el mismo detalle que los resultados.»
Proveedor de la API	Consola del proveedor; registro de versión y consumo	En cada lote de inferencia	No aplica (relación transaccional); se documenta la versión del modelo usada.

6. Documento de alcance del proyecto

Esta sección fija el objetivo general y los objetivos específicos con la metodología SMART, delimita el alcance incluido y excluido, define los entregables con sus criterios de aceptación, y declara los supuestos, limitaciones y restricciones del proyecto. Es el documento de referencia contra el que se juzgará si el proyecto está completo; cualquier cambio de alcance durante los sprints se registra en la bitácora de decisiones y se somete al *sprint review*.

6.1 Objetivo general (SMART)

> Construir y evaluar, entre el 8 de septiembre y el 25 de octubre de 2026, un clasificador automático que asigne a cada una de las 813 normas del corpus GENIAL una de las cinco dimensiones activas del *framework* (Pedagógico, Ética, Administrativo, Protección de Datos y Técnico) a partir de su texto, comparando sobre idéntico conjunto de prueba a ciegas un modelo clásico (TF-IDF + Regresión Logística) y un LLM en modo *few-shot*, con la meta de alcanzar un F1 macro ≥ 0.70 sin ninguna clase por debajo de 0.50, un κ modelo-humano no inferior al κ humano-humano medido sobre el mismo conjunto, y una reducción estimada de al menos el 75 % del esfuerzo humano de codificación por pasada del corpus, integrando el resultado en una propuesta de agregación al Índice de Madurez Normativa con trazabilidad del origen de cada etiqueta.

Tabla 16. Verificación del objetivo general contra los cinco criterios SMART.

Criterio	Cómo lo cumple el objetivo
Específico	Define qué se construye (un clasificador de cinco clases sobre texto), con qué técnicas (dos ramas nombradas), sobre qué datos (813 normas) y qué queda fuera (despliegue, sexta dimensión, recolección de normas nuevas).
Medible	Tres metas cuantificadas (F1 macro, κ relativo, reducción de esfuerzo) con piso aritmético conocido (36.2 % / 0.106) y con el procedimiento estadístico declarado (McNemar, IC).
Alcanzable	Corpus disponible y autorizado, técnicas estándar, equipo con acceso operativo, segundo codificador confirmado, costo de API marginal.
Relevante	Ataca el cuello de botella del observatorio GENIAL (codificación manual sin fiabilidad medida) y devuelve al consorcio un diagnóstico del *framework* que la codificación manual no puede producir.
Temporal	Siete semanas con fechas de inicio y fin, cuatro sprints y ocho hitos fechados; sin holgura, con contingencias declaradas.

6.2 Objetivos específicos

Tabla 17. Objetivos específicos, métrica de éxito asociada y sprint en que se cumplen.

#	Objetivo específico	Métrica de éxito (§4)	Sprint
OE1	Depurar y caracterizar el corpus GENIAL (813 × 13), incorporando la variable idioma, resolviendo duplicados y construyendo la línea base de metadata que fundamenta la exclusión de *Tipo de norma*, y cerrar el muestreo estratificado del experimento (pool *few-shot* de 15 y conjunto de prueba ciego de 100-150).	Reporte de calidad completo; línea base de metadata reportada; *test_blind.csv* y *fewshot_examples.csv* validados con criterio de dominio.	2
OE2	Entrenar y evaluar la rama clásica (TF-IDF 1-2 gramas, 5 000 *features*, Regresión Logística con *class_weight* balanceado, validación cruzada estratificada de 5 particiones), registrando probabilidades y top-2 por norma.	F1 macro y F1 por clase con IC; matriz de confusión; términos más predictivos por dimensión.	2
OE3	Diseñar el *prompt* versionado con las definiciones de las cinco dimensiones y 15 ejemplos, clasificar a ciegas el conjunto de prueba con el LLM registrando 1.ª y 2.ª dimensión, y comparar ambas ramas de forma pareada con McNemar e intervalos de confianza, desagregando por idioma y por país.	Tabla comparativa con valor *p*, IC de exactitud (Wilson) y de F1 macro (*bootstrap*); reporte de estabilidad entre ejecuciones; métricas por idioma y país.	3
OE4	Medir la fiabilidad del estándar de referencia mediante doble codificación ciega del conjunto de prueba por un segundo codificador de GENIAL con adjudicación de un tercero, calcular κ humano-humano y κ modelo-humano, y tipificar cualitativamente los errores.	κ h-h y κ m-h reportados; conteo de errores en genuino / 2.ª dimensión defendible / etiqueta original discutible; nota conceptual sobre la frontera Administrativo-Ética.	3
OE5	Especificar el flujo asistido (umbral de confianza calibrado, regla de revisión obligatoria para países e idiomas subrepresentados, estimación de carga humana residual) y la propuesta de agregación al IMN con trazabilidad del origen de cada etiqueta, junto con la reflexión ética y la documentación reproducible.	Umbral fijado y % de enrutamiento; h-persona ahorradas estimadas; tabla IMN con origen de etiqueta; *notebook* ejecutado por el integrante que no lo escribió.	3-4

6.3 Alcance incluido

6.3.1 Funcionalidades técnicas

1. Depuración y caracterización del corpus (813 normas × 13 columnas), incorporando la variable idioma y la deduplicación por URL.
2. Línea base de metadata: cuantifica cuánta señal aporta *Tipo de norma* por sí sola y fundamenta su exclusión como variable predictora.
3. Rama clásica: TF-IDF (1-2 gramas, 5 000 *features*) + Regresión Logística multiclase con *class_weight* balanceado y validación cruzada estratificada de 5 particiones; comparación contra la variante sin ponderación.

4. Rama LLM: *prompt* con las definiciones de las cinco dimensiones y 15 ejemplos etiquetados; clasificación a ciegas con registro de primera y segunda dimensión predicha; política de idioma declarada (definiciones en español, normas en su idioma original, sin traducción previa).
5. Evaluación comparativa sobre idéntico conjunto de prueba: F1 macro, prueba de McNemar, intervalos de confianza y κ de Cohen frente a doble codificación humana; métricas desagregadas por idioma y por país.
6. Enrutamiento por umbral de confianza: las predicciones de baja probabilidad, y todas las de países o idiomas subrepresentados, se derivan a revisión humana en lugar de aceptarse automáticamente.
7. Propuesta de agregación de las predicciones al IMN por país, distinguiendo qué normas codificó un humano y cuáles el modelo, con margen de error por dimensión.

6.3.2 Tipos de datos a procesar

Texto corto en español, portugués e inglés (título y observaciones de cada norma, entre 6 y 274 palabras); metadata categórica (país, tipo de norma, estado, ámbito, vínculo con la educación) usada solo para caracterización, estratificación y análisis desagregado, nunca como variable predictora; una variable objetivo categórica de cinco clases. No se procesan documentos completos ni PDF: el corpus contiene resúmenes elaborados por los codificadores.

6.3.3 Usuarios y casos de uso cubiertos

- **Codificador de GENIAL** que recibe, para cada norma nueva, dos dimensiones candidatas con su probabilidad y decide (caso de uso: *triage* asistido).
- **Coordinación del observatorio** que recalcula el IMN con la tabla de agregación y publica el origen de cada etiqueta y el margen de error (caso de uso: actualización trazable del índice).
- **Auditor metodológico** —el propio consorcio o un revisor externo— que reproduce el experimento de extremo a extremo desde el repositorio (caso de uso: auditoría y replicación).

6.4 Alcance excluido

Tabla 18. Elementos fuera del alcance, su motivo y su destino.

Elemento excluido	Motivo	Destino
Despliegue del clasificador en el flujo operativo de GENIAL (contenedores, API, interfaz de usuario, monitoreo)	El entregable de titulación es un *pipeline* reproducible y una especificación del flujo asistido, no un servicio en producción; el despliegue depende de decisiones del consorcio.	Próximos pasos; propuesta de piloto para el consorcio.
Sexta dimensión del *framework* GENIAL	Sin definición operativa ni representación en el corpus actual.	Se incorporará cuando el consorcio la defina y codifique.
Recolección o codificación de normas nuevas	El proyecto trabaja exclusivamente sobre normas ya identificadas y codificadas.	Flujo operativo futuro.
***Transformers* afinados en dominio legal**	813 registros con dos clases por debajo de 75 casos; acceso a repositorios de modelos no garantizado.	Trabajo futuro, declarado como tal en el estado del arte.
Reformulación multi-etiqueta de la tarea	El gold standard actual soporta solo etiqueta única; re-anotar el corpus excede las siete semanas.	Diagnóstico de multi-etiqueta incluido; re-anotación como recomendación al consorcio.
Uso de *Fecha de Publicación*, *Investigador* y *Tipo de norma* como variables predictoras	Fecha heterogénea; investigador por razones éticas; tipo de norma por fuga de información.	Solo para caracterización y análisis desagregado.
Publicación del corpus completo	Restricción de redistribución del consorcio.	Muestra anonimizada en el repositorio; hash del archivo congelado.

6.5 Entregables y criterios de aceptación

Tabla 19. Entregables del proyecto con formato y criterios de aceptación.

Entregable	Formato	Criterios de aceptación
E1 · Corpus depurado y caracterizado	CSV/Parquet + reporte de calidad (Markdown en el repositorio)	Sin faltantes en *Dominio* y *texto*; variable idioma en el 100 % de las filas con verificación manual de las no hispanohablantes; duplicados resueltos y documentados; hash del archivo original registrado.
E2 · Muestreo del experimento	*fewshot_examples.csv*, *test_blind.csv*, *test_labels_hidden.csv*	15 ejemplos (3 por dimensión); 100-150 casos de prueba estratificados por dimensión e idioma con ≥ 20 normas no hispanohablantes; etiquetas separadas del conjunto ciego; muestreo aprobado por el enlace con GENIAL.
E3 · Línea base de metadata y línea base de clase mayoritaria	Sección del *notebook* + tabla de resultados	Ambas líneas base reportadas con la misma métrica y el mismo conjunto que los modelos.
E4 · Modelo clásico entrenado	Artefacto serializado + *notebook* + tabla de métricas	Validación cruzada estratificada de 5 particiones ejecutada; F1 por clase y matriz de confusión; *predict_proba* y top-2 almacenados por norma; términos más predictivos por dimensión.
E5 · Rama LLM y comparación pareada	*prompt* versionado, *llm_predictions.csv*, tabla comparativa	Predicciones con 1.ª y 2.ª dimensión para el 100 % del conjunto de prueba; tres ejecuciones con temperatura fija; McNemar con valor *p*; IC de Wilson y *bootstrap*; métricas por idioma y país.
E6 · Reporte de fiabilidad	Cuadernillo de codificación, regla de gold standard, tabla de κ	Regla fijada por escrito antes de medir; κ h-h y κ m-h para ambas ramas; número de casos adjudicados; errores tipificados en tres categorías con conteos.
E7 · Especificación del flujo asistido y propuesta de IMN	Documento + tabla IMN	Umbral calibrado con % de enrutamiento; carga humana residual en h-persona; tabla IMN por país con origen de cada etiqueta y margen de error por dimensión.
E8 · Documento técnico final, *notebook* reproducible y pitch	PDF, repositorio GitHub, video de 3 minutos	*Notebook* ejecutado de extremo a extremo por el integrante que no lo escribió; reflexión ética y limitaciones con la misma prominencia que los resultados; pitch dentro de los 180 segundos.

6.6 Criterios de aceptación del proyecto y procedimientos de validación

El proyecto se considera **completado** cuando los ocho entregables cumplen sus criterios, el objetivo general alcanza al menos los umbrales mínimos de la Tabla 10 y el documento final reporta explícitamente qué metas se alcanzaron y cuáles no. Los **estándares mínimos de calidad** son: toda métrica con intervalo de confianza; toda comparación entre ramas con valor *p*; toda cifra desagregada por idioma y por país; ninguna métrica reportada sin declarar contra qué etiqueta de referencia se mide, cuál es la fiabilidad de esa etiqueta y sobre qué distribución de datos. Los **procedimientos de validación** son cuatro: (1) *sprint review* con el docente-tutor al cierre de cada sprint; (2) revisión cruzada de cada entregable por el integrante del equipo que no lo produjo; (3) validación de dominio del muestreo y de la tipificación de errores por el enlace con GENIAL; y (4) reproducción independiente del *notebook* antes de la entrega final.

6.7 Supuestos fundamentales

- **S1.** La autorización del consorcio GENIAL para usar el corpus se mantiene durante todo el proyecto (concedida por escrito en el Sprint 1).
- **S2.** El segundo codificador designado por GENIAL dispone de dos jornadas en el Sprint 3 para codificar a ciegas 100-150 normas (confirmado; contingencia en §7.6).
- **S3.** Diez minutos de trabajo experto por norma es una estimación razonable del costo actual de codificación; se validará con el equipo GENIAL antes de reportar cifras de ahorro.

- **S4.** La API del LLM permanece disponible con la misma versión del modelo durante el Sprint 3; en caso contrario, se documenta el cambio de versión y se repite la ejecución.
- **S5.** La etiqueta *Dominio* es operativamente *single-label* en el archivo (a verificar en el Sprint 2); el diagnóstico de multi-etiqueta no presupone lo contrario.
- **S6.** Los textos de *Observaciones*, aunque redactados por los codificadores, describen el contenido de la norma y no contienen la etiqueta de forma literal (a verificar con la línea base de metadata y una inspección de fuga léxica).

6.8 Limitaciones y restricciones explícitas

- **Tamaño del corpus:** 813 registros con dos clases por debajo de 75 casos limitan las técnicas aplicables y la potencia estadística; el conjunto de prueba de 100-150 casos produce intervalos de confianza de aproximadamente ±0.08 en exactitud.
- **Estándar de referencia de un solo codificador:** el desempeño se interpreta contra el κ humano-humano medido sobre el conjunto de prueba, no sobre el corpus entero.
- **Corpus multilingüe con idioma minoritario escaso:** ≈29 normas en inglés impiden conclusiones firmes por idioma; el análisis por idioma se reporta como exploratorio si el conjunto de prueba contiene menos de 20 normas no hispanohablantes.
- **Textos cortos:** el modelo clasifica resúmenes de la norma, no su articulado; el desempeño no es extrapolable a la clasificación de documentos completos.
- **Dependencia de un proveedor externo** para la rama LLM; la reproducibilidad exacta de esa rama depende de la estabilidad de la versión del modelo.
- **Restricciones:** ventana de siete semanas sin holgura; dedicación parcial de 8 h/semana por integrante; no redistribución del corpus; presupuesto de API acotado (§8.3); resultados desagregados por país publicables solo con margen de error y revisión del consorcio.

6.9 Validación SMART del objetivo

El objetivo fue sometido al *Checklist de validación de objetivos SMART* del módulo, con autoevaluación estricta (las casillas que no aplican a un proyecto de investigación se contabilizan como no cumplidas para no inflar el resultado). Resultado: **27 sobre 31 puntos, semáforo verde** (Específico 5/5, Medible 5/7, Alcanzable 7/7, Relevante 6/7, Temporal 4/5). Las casillas pendientes corresponden a métricas de negocio con retorno monetario y a la holgura del cronograma, ambas tratadas explícitamente en las secciones 4 y 7.

7. Cronograma con metodología ágil

El módulo pide seis semanas divididas en cuatro sprints con metodología Scrum. El calendario efectivo del proyecto —fijado por el Caso de Negocio y ya aprobado en el cronograma detallado entregado con las plantillas — va del 8 de septiembre al 25 de octubre de 2026: siete semanas. Se conservan esas fechas y se agrupan las cinco fases del cronograma detallado en **cuatro sprints**: dos de dos semanas, uno de dos semanas y uno final de una semana, respetando el contenido que el módulo asigna a cada sprint (investigación y diseño; desarrollo *core*; optimización y validación; finalización y documentación). La Figura 4 muestra la correspondencia.

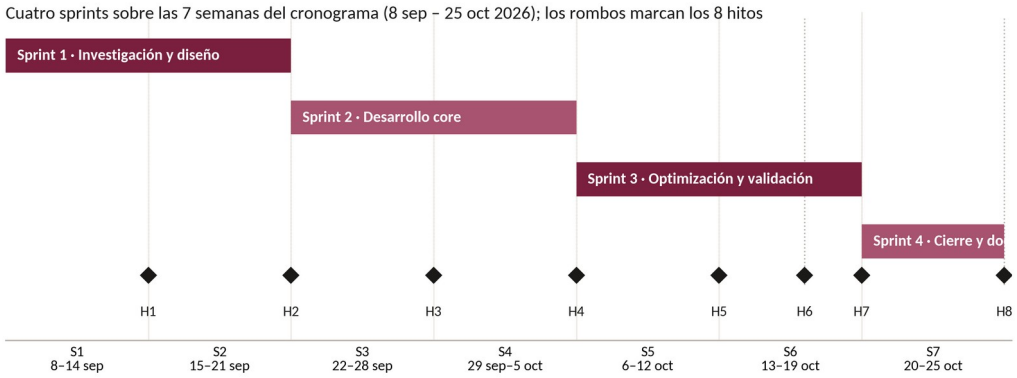


Figura 4. Cuatro sprints sobre las siete semanas del proyecto y posición de los ocho hitos (§9).

7.1 Adaptación de Scrum a un equipo de dos personas

Scrum está diseñado para equipos de tres a nueve personas [41]; aplicarlo a un equipo de dos con dedicación parcial exige adaptar roles y ceremonias sin perder lo que los hace útiles: un objetivo por sprint, un *backlog* priorizado y visible, una revisión con el *stakeholder* al cierre y una retrospectiva que ajuste el proceso. La Tabla 20 fija roles y ceremonias; la cadencia de reuniones coincide con la ya declarada en el cronograma detallado (dos sincronizaciones semanales de 30 minutos y reporte a GENIAL al cierre de cada bloque).

Tabla 20. Roles Scrum y ceremonias adaptadas al proyecto.

Elemento	Asignación en este proyecto	Responsabilidad concreta
Product Owner	Melissa Figallo	Prioriza el *backlog* en función del valor para el observatorio; acepta o rechaza cada historia contra su *Definition of Done*; representa las metas del Canvas SMART.
Tech Lead y enlace con GENIAL	Jorge Maldonado Mahauad	Decisiones de arquitectura y de método estadístico; gestiona la dependencia externa (2.° y 3.er codificador); valida el muestreo y la tipificación de errores con criterio de dominio.
Scrum Master (rotativo por sprint)	Sprints 1 y 3: Melissa · Sprints 2 y 4: Jorge	Convoca las ceremonias, mantiene la bitácora de decisiones, vigila el *burndown* del sprint y escala los bloqueos.
Development Team	Ambos integrantes	Ejecutan las historias; toda historia tiene un autor y un revisor cruzado distinto.
Stakeholders en la revisión	Docente-tutor (UEES); coordinación de GENIAL	Reciben el *sprint review*; el tutor evalúa los entregables del módulo, la coordinación valida el uso del corpus y recibe el reporte de cierre de cada sprint.
Sprint Planning	Lunes de inicio de sprint, 60 min	Se fija el Sprint Goal, se seleccionan historias hasta la capacidad (16 h-persona/semana) y se descomponen en tareas de ≤ 1 día.
Daily Scrum (adaptado)	Dos sincronizaciones semanales de 30 min + bitácora asíncrona	Qué se hizo, qué sigue, qué bloquea; la bitácora registra cada decisión metodológica en el momento en que se toma.
Backlog Refinement	A mitad de sprint, 30 min	Se re-estiman las historias del sprint siguiente con la información nueva (por ejemplo, el tamaño real del conjunto no hispanohablante).
Sprint Review	Último día del sprint, 45 min	Demostración de los entregables ejecutables (*notebook*, tablas) al tutor; registro de observaciones que entran al *backlog*.
Sprint Retrospective	Tras la revisión, 30 min	Qué conservar, qué cambiar; una acción de mejora concreta por sprint.

7.2 Product Backlog priorizado

El *backlog* se compone de 21 historias técnicas estimadas en puntos de historia (escala de Fibonacci: 1, 2, 3, 5, 8, donde 8 equivale a unas 12-16 h-persona) y priorizadas con MoSCoW. Las historias del Sprint 1 ya están hechas: corresponden a los entregables previos del módulo (foro, matriz SMART, estado del arte, Canvas, checklist,

decisiones metodológicas, autorización). Total planificado: 95 puntos; capacidad estimada: 16 h-persona por semana (8 h por integrante), más las horas externas de los codificadores de GENIAL en el Sprint 3.

Tabla 21. Product Backlog: historias técnicas, puntos de historia, prioridad MoSCoW y sprint asignado.

ID	Historia de usuario técnica	Pts	Prioridad	Sprint	Estado
US-01	Como equipo, queremos formular tres problemas reales resolubles con IA y clasificarlos por dominio, para seleccionar el problema del proyecto con evidencia.	3	Must	1	Hecha
US-02	Como equipo, queremos evaluar los tres problemas con la matriz SMART ponderada, para justificar la selección ante el tutor.	3	Must	1	Hecha
US-03	Como investigadores, queremos revisar ≥ 20 fuentes de 2021-2026 en tres ejes y comparar ≥ 5 enfoques, para posicionar la propuesta e identificar el gap.	8	Must	1	Hecha
US-04	Como equipo, queremos completar el Canvas SMART y validar el objetivo con el checklist, para fijar alcance, métricas y riesgos.	5	Must	1	Hecha
US-05	Como equipo, queremos resolver por escrito las cuatro condiciones metodológicas del tutor, para que rijan el diseño antes de desarrollar.	3	Must	1	Hecha
US-06	Como enlace con GENIAL, quiero obtener la autorización de uso del corpus y la designación del 2.° codificador, para eliminar la dependencia externa del cronograma.	2	Must	1	Hecha
US-07	Como desarrolladores, queremos definir la arquitectura técnica, inicializar el repositorio y preparar el entorno (Python 3.12, scikit-learn, API), para que el Sprint 2 empiece a codificar el primer día.	3	Must	1	En curso
US-08	Como analista, quiero cargar el corpus congelado, corregir el faltante de *Dominio*, normalizar *Tipo de norma*, resolver duplicados y añadir la variable idioma, para disponer de un corpus depurado y caracterizado.	5	Must	2	Planificada
US-09	Como analista, quiero construir la línea base de metadata y verificar operativamente que *Dominio* es *single-label*, para fundamentar la exclusión de *Tipo de norma* y registrar el punto de partida.	3	Must	2	Planificada
US-10	Como analista, quiero extraer el pool *few-shot* (15) y el conjunto de prueba ciego (100-150) con muestreo estratificado por dimensión e idioma, guardando las etiquetas aparte, para que el experimento sea pareado y ciego.	5	Must	2	Planificada
US-11	Como desarrolladora, quiero entrenar TF-IDF + Regresión Logística con *class_weight* balanceado y validación cruzada estratificada de 5 particiones, para obtener la rama clásica con métricas por clase.	5	Must	2	Planificada
US-12	Como desarrolladora, quiero almacenar *predict_proba* y el top-2 por norma y extraer los términos más predictivos por dimensión, para habilitar el umbral de confianza y la interpretabilidad.	3	Should	2	Planificada
US-13	Como desarrolladora, quiero diseñar el *prompt* versionado con las definiciones de las cinco dimensiones, 15 ejemplos y política de idioma declarada, para que la rama LLM transmita el criterio de GENIAL.	3	Must	3	Planificada
US-14	Como desarrolladora, quiero clasificar a ciegas el conjunto de prueba con el LLM registrando 1.ª y 2.ª dimensión, en tres ejecuciones con temperatura fija, para medir desempeño y estabilidad.	5	Must	3	Planificada
US-15	Como analista, quiero comparar ambas ramas sobre idéntico conjunto con McNemar, IC de Wilson y *bootstrap*, desagregando por idioma y país, para responder con significancia qué técnica es mejor.	5	Must	3	Planificada
US-16	Como enlace con GENIAL, quiero que un 2.° codificador codifique a ciegas el conjunto de prueba con regla de gold standard fijada antes, y un 3.° adjudique discrepancias, para calcular κ humano-humano y κ modelo-humano.	8	Must	3	Planificada
US-17	Como analista, quiero tipificar cada error en genuino / 2.ª dimensión defendible / etiqueta original discutible y redactar la nota sobre la frontera Administrativo-Ética, para convertir el error en diagnóstico del *framework*.	5	Must	3	Planificada
US-18	Como equipo, queremos calibrar el umbral de confianza, simular la carga humana residual y construir la tabla IMN con origen de cada etiqueta, para especificar el flujo asistido.	5	Should	3	Planificada

ID	Historia de usuario técnica	Pts	Prioridad	Sprint	Estado
US-19	Como equipo, queremos redactar la reflexión ética (sesgo por país, idioma y codificador) y las recomendaciones de gobernanza del IMN, para reportar limitaciones con la misma prominencia que los resultados.	3	Must	4	Planificada
US-20	Como desarrolladores, queremos que el *notebook*, los *prompts* y el *requirements* estén versionados y que el integrante que no los escribió los ejecute de extremo a extremo, para garantizar reproducibilidad.	5	Must	4	Planificada
US-21	Como equipo, queremos entregar el documento final, actualizar el Caso de Negocio y la Guía Técnica, y grabar el pitch de 3 minutos, para cerrar el módulo.	8	Must	4	Planificada

7.3 Definition of Done

Toda historia comparte una *Definition of Done* general, y las historias técnicas añaden criterios propios que se detallan en cada sprint. **DoD general:** (1) el artefacto está en el repositorio, versionado, con *commit* descriptivo; (2) fue revisado por el integrante que no lo produjo; (3) la decisión metodológica que implica está registrada en la bitácora con su justificación; (4) las cifras que produce llevan intervalo de confianza o, si son descriptivas, su denominador; (5) el Product Owner la aceptó contra el criterio de aceptación del entregable al que pertenece (§6.5).

7.4 Sprint 1 · Investigación y diseño (Semanas 1-2: 8 al 21 de septiembre)

> **Sprint Goal**
>
> Cerrar la fase de definición con el problema seleccionado y validado, el estado del arte mapeado con ≥ 20 fuentes, el objetivo SMART validado, las cuatro condiciones metodológicas resueltas por escrito, la autorización del corpus y el 2.° codificador confirmados, y el entorno de desarrollo y el repositorio listos.

Historias comprometidas: US-01 a US-07 (27 puntos). Historias de investigación y análisis (US-01 a US-05), definición de la arquitectura técnica (US-07) y preparación del entorno (US-07).

Definition of Done específica:

- Estado del arte con 29 fuentes verificadas contra fuente primaria y seis enfoques comparados.
- Canvas SMART y checklist (27/31) entregados; decisiones metodológicas v1.0 vinculantes.
- Autorización escrita del consorcio y 2.° codificador designado (obtenidos).
- Repositorio inicializado con README, estructura de carpetas, *requirements* fijado, muestra anonimizada y *hash* del corpus congelado; arquitectura del *pipeline* descrita en el README.

Tabla 22. Riesgos del sprint y plan de mitigación.

Riesgo	Prob.	Impacto	Mitigación / contingencia
La autorización del corpus se demora	Baja	Muy alto	Gestionada desde la Semana 1; obtenida. Si se revocara: estadísticas agregadas solo, sin resultados por país (§3.7).
El estado del arte no alcanza 20 fuentes verificables	Baja	Alto	Verificación por DOI/arXiv; 29 fuentes registradas.
El entorno no accede a la API del LLM	Baja	Medio	Alternativa con modelo abierto (Qwen) documentada; prueba de conexión en el Sprint 1.

7.5 Sprint 2 · Desarrollo core (Semanas 3-4: 22 de septiembre al 5 de octubre)

> **Sprint Goal**
>
> Disponer de un corpus depurado con variable idioma, el muestreo ciego del experimento cerrado y validado, las dos líneas base sin IA reportadas y la rama clásica entrenada con validación cruzada, probabilidades y top-2 almacenados.

Historias comprometidas: US-08 a US-12 (21 puntos). Implementación del algoritmo principal de la rama clásica, integración con el dataset seleccionado y pruebas unitarias del *pipeline* de datos.

Definition of Done específica:

- Reporte de calidad con distribución por dimensión, país e idioma, duplicados resueltos y faltantes corregidos con criterio documentado.
- *test_blind.csv* y *test_labels_hidden.csv* separados; ≥ 20 normas no hispanohablantes en el conjunto de prueba, o decisión documentada de reportar el idioma solo como limitación.
- Línea base de clase mayoritaria y línea base de metadata reportadas con F1 macro y exactitud sobre el mismo conjunto.
- Modelo clásico con F1 por clase, matriz de confusión, *predict_proba* y top-2 por norma; comparación con la variante sin *class_weight*; pruebas unitarias de carga, partición y ausencia de fuga (ninguna norma del conjunto de prueba en entrenamiento; duplicados por URL en la misma partición).

Tabla 23. Riesgos del sprint y plan de mitigación.

Riesgo	Prob.	Impacto	Mitigación / contingencia
El corpus no sostiene un análisis desagregado por idioma (< 20 normas no hispanohablantes en prueba)	Media	Medio	Punto de decisión de la Semana 3: reportar el idioma solo como limitación declarada, sin desagregar métricas.
La línea base de metadata resulta muy alta (*Tipo de norma* casi determina la dimensión)	Media	Medio	Es un hallazgo, no un problema: refuerza la exclusión de la columna y se reporta como techo de la señal de metadata.
Duplicados o fuga léxica entre entrenamiento y prueba	Media	Alto	Deduplicación por URL antes de particionar; inspección de coincidencias literales de la etiqueta en *Observaciones*.
La clase Técnico no se aprende (F1 muy bajo en validación cruzada)	Alta	Medio	Se anticipa; se documenta como evidencia de subajuste por tamaño y heterogeneidad y se eleva a GENIAL como posible revisión conceptual.

7.6 Sprint 3 · Optimización y validación (Semanas 5-6: 6 al 19 de octubre)

> **Sprint Goal**
>
> Completar la comparación pareada de ambas ramas con significancia estadística y métricas desagregadas, medir la fiabilidad humano-humano y modelo-humano sobre el mismo conjunto, tipificar los errores y especificar el flujo asistido con su propuesta de agregación al IMN.

Historias comprometidas: US-13 a US-18 (31 puntos, de los cuales US-16 consume principalmente horas externas de los codificadores de GENIAL). El «tuning» del módulo se traduce aquí en la calibración del *prompt* (versión, política de idioma, temperatura) y del umbral de confianza; la «interfaz de usuario» se sustituye, por alcance, por la especificación del flujo asistido.

Definition of Done específica:

- *Prompt* versionado con política de idioma escrita; tres ejecuciones con temperatura fija y reporte de variabilidad.
- Tabla comparativa con McNemar (valor *p*), IC de Wilson para exactitud y *bootstrap* para F1 macro; métricas por idioma y país; términos más predictivos por dimensión.
- Regla de gold standard fijada por escrito **antes** de medir; 2.° codificador codifica a ciegas sin ver predicciones ni etiqueta original; κ h-h y κ m-h para ambas ramas; número de casos adjudicados.
- Errores tipificados en tres categorías con conteos; nota conceptual Administrativo-Ética; umbral calibrado con % de enrutamiento y carga humana residual en h-persona; tabla IMN con origen de cada etiqueta.

Tabla 24. Riesgos del sprint y plan de mitigación.

Riesgo	Prob.	Impacto	Mitigación / contingencia
El 2.° codificador no completa la codificación a tiempo	Media	Alto	Confirmado y agendado en la Semana 6. Contingencia: doble codificación intraequipo sobre 30 normas, reportada explícitamente como acuerdo intraequipo y no como fiabilidad intercodificador de GENIAL.
La diferencia entre técnicas no alcanza significancia	Alta	Medio	Reencuadrar el resultado principal como eficiencia de datos (desempeño equivalente con ~50 veces menos ejemplos etiquetados); ampliar el conjunto de prueba a 150 casos.
El LLM resulta inestable entre ejecuciones	Media	Medio	Temperatura fija, *prompt* versionado; reportar la variabilidad como limitación medida (+2 días).
Cuota o disponibilidad de la API insuficiente	Baja	Medio	Reducir el conjunto a 100 casos o usar un modelo más económico para los lotes grandes; alternativa abierta documentada (+1 día).
Contaminación del gold standard (el codificador ve las sugerencias del modelo)	Baja	Muy alto	Protocolo ciego por diseño: cuadernillo sin predicciones; archivos de predicciones no compartidos hasta cerrar la codificación [31].

7.7 Sprint 4 · Finalización y documentación (Semana 7: 20 al 25 de octubre)

> **Sprint Goal**
>
> Entregar el proyecto completo: reflexión ética y recomendaciones de gobernanza, *notebook* reproducido de forma independiente, documentación técnica y de usuario del *pipeline*, documento final y pitch de tres minutos, con las limitaciones reportadas con la misma prominencia que los resultados.

Historias comprometidas: US-19 a US-21 (16 puntos). Testing integral del *pipeline* (ejecución de extremo a extremo por el integrante que no lo escribió), documentación técnica (README, diccionario de datos, *prompts*) y de usuario (guía de uso del flujo asistido), y preparación de la presentación final.

Definition of Done específica:

- Reflexión ética con sesgo por país, idioma y codificador, y recomendación de revisión humana obligatoria para países e idiomas subrepresentados.
- *Notebook*, *prompts* y *requirements* versionados; ejecución independiente con resultados idénticos registrada en el README.
- Documento final con las Unidades 1 a 4 actualizadas, referencias IEEE y anexos; sección de trabajo futuro con las líneas identificadas.
- Pitch grabado dentro de los 180 segundos según la estructura del *workshop*; checklist de revisión cruzada completado.

Tabla 25. Riesgos del sprint y plan de mitigación.

Riesgo	Prob.	Impacto	Mitigación / contingencia
El *notebook* no reproduce resultados idénticos en la segunda máquina	Media	Alto	Semilla fija y versiones declaradas desde el Sprint 2; ejecución de prueba a mitad del Sprint 3 para detectar diferencias con margen.
El documento excede o no alcanza la extensión requerida	Media	Bajo	Control de extensión en cada *sprint review*; los anexos absorben el material de detalle.
Semana sin holgura: cualquier retraso del Sprint 3 impacta la entrega	Alta	Alto	Historias *Should* del Sprint 3 (US-12, US-18) son las primeras candidatas a recorte; el documento final se redacta de forma incremental desde el Sprint 2.

7.8 Puntos de decisión críticos

Tabla 26. Decisiones que condicionan el resto del cronograma, con su criterio y su alternativa.

Semana	Decisión	Criterio	Alternativa si no se cumple
3	¿El corpus sostiene un análisis desagregado por idioma?	≥ 20 normas no hispanohablantes en el conjunto de prueba	Reportar el idioma solo como limitación declarada, sin desagregar métricas.
5	¿La comparación entre técnicas es concluyente?	McNemar con $p < 0.05$	Reencuadrar el aporte como resultado de eficiencia de datos, no de superioridad.
6	¿La doble codificación externa se completó?	Conjunto codificado por el 2.° codificador antes del jueves de la Semana 6	Activar la contingencia intraequipo sobre 30 normas, declarada como tal.
7	¿El modelo alcanza el criterio mínimo de éxito?	F1 macro ≥ 0.60 y superior a ambas líneas base	Reportar el resultado alcanzado y situar el aporte en el diagnóstico conceptual del *framework*.

8. Plan de recursos

El proyecto es intensivo en criterio experto y ligero en cómputo: un modelo lineal sobre 813 textos cortos entrena en segundos en un portátil, y la rama LLM se consume por API. El recurso escaso no es el hardware sino el tiempo de investigador —del equipo y de los codificadores de GENIAL—, y así se refleja en el presupuesto, que se expresa en horas-persona valorizadas a costo de oportunidad, sin desembolso real salvo el consumo de la API. Este plan refina la estimación del Canvas SMART (≈100 h-persona del equipo y USD 20-50 de API) al incorporar las horas externas de los codificadores y una contingencia del 20 %.

8.1 Recursos humanos

8.1.1 Equipo core

El módulo pide tres perfiles —desarrollador, analista y *project manager*— que el equipo de dos personas cubre con dedicación parcial (8 h/semana cada uno, 16 h-persona/semana): **Jorge Maldonado Mahauad** asume principalmente el rol de analista de datos y método (depuración, muestreo, estadística, fiabilidad) y el enlace con GENIAL; **Melissa Figallo** asume principalmente el de desarrolladora del *pipeline* (rama clásica, rama LLM, comparación, agregación) y el rol de Product Owner; la gestión del proyecto (Scrum Master) rota por sprint. La Tabla 27 distribuye las 112 horas del equipo por rol y sprint.

Tabla 27. Horas-persona del equipo core por rol y sprint (capacidad: 16 h/semana).

Rol	Sprint 1 (2 sem.)	Sprint 2 (2 sem.)	Sprint 3 (2 sem.)	Sprint 4 (1 sem.)	Total
Analista de datos y método (depuración, muestreo, estadística, κ)	10	12	12	4	38
Desarrollador ML / *pipeline* (rama clásica, rama LLM, comparación, IMN)	6	14	12	4	36
Gestión del proyecto (Scrum, bitácora, riesgos, coordinación con GENIAL)	6	4	4	2	16
Documentación, comunicación con stakeholders y pitch	10	2	4	6	22
Total del equipo	**32**	**32**	**32**	**16**	**112**

8.1.2 Consultoría especializada externa

La única consultoría externa es la de los expertos de dominio del consorcio GENIAL, sin costo monetario para el proyecto pero con un costo de oportunidad que se contabiliza: un **segundo codificador** (codificación ciega de 100-150 normas: ≈16 h en el Sprint 3), un **tercer codificador** (adjudicación de discrepancias: ≈4 h), la **validación de dominio del muestreo** por la coordinación (≈2 h en el Sprint 2) y el **taller de cierre con los codificadores** (≈6

h-persona en el Sprint 4). Total: 28 h-persona externas. No se contrata consultoría estadística ni de ingeniería: ambas técnicas son estándar y el equipo tiene la competencia.

8.2 Recursos técnicos

Tabla 28. Infraestructura técnica requerida y disponible.

Categoría	Recurso	Requerimiento	Disponibilidad y costo
Hardware	Dos equipos portátiles de trabajo	CPU de propósito general, ≥ 16 GB RAM; sin GPU (TF-IDF + Regresión Logística sobre 813 documentos entrena en segundos; el LLM se consume por API)	Equipamiento propio de los integrantes. USD 0.
Hardware	Almacenamiento	< 1 GB: corpus congelado (≈1 MB), artefactos, resultados	Repositorio GitHub para código y muestra; almacenamiento institucional cifrado para el corpus completo, que no se sube al repositorio. USD 0.
Software	Entorno de análisis	Python 3.12; scikit-learn 1.8 [39], pandas, numpy, scipy/statsmodels (McNemar), matplotlib, openpyxl, langdetect o equivalente; Jupyter	Código abierto. USD 0.
Software	Control de versiones y colaboración	Git y GitHub (repositorio público del proyecto); *prompts* y configuraciones versionados junto al código	Plan gratuito. USD 0.
Software	Modelo de lenguaje (rama LLM)	API de un LLM de propósito general con *prompt* de ≈4 000 tokens (definiciones + 15 ejemplos + norma); registro de versión del modelo y temperatura fija	API de Anthropic (Claude) con clave del equipo; alternativa: modelo abierto Qwen 3.5. Consumo estimado: conjunto de prueba (150 normas × 3 ejecuciones) + una pasada completa (813) ≈ 1 300 llamadas; USD 20-50.
Datos	Corpus consolidado GENIAL	813 normas × 13 columnas; autorización de uso	Concedida. Costo de adquisición USD 0 (≈135 h de codificación ya invertidas por el consorcio).
Datos	Datasets alternativos (plan B)	MultiEURLEX (Hugging Face), OECD.AI	Públicos y gratuitos; solo se descargan si se activa el plan B.

8.3 Recursos financieros

El presupuesto se valoriza a un costo de oportunidad uniforme de USD 20 por hora-persona (supuesto declarado, coherente con el Canvas SMART) tanto para el equipo como para los codificadores externos. El único desembolso real es el consumo de la API. La contingencia se fija en el **20 % del subtotal**, en el extremo superior del rango que pide el módulo (15-20 %), porque el cronograma no tiene holgura y el riesgo de mayor probabilidad —una comparación no concluyente que obligue a ampliar el conjunto de prueba— se traduce directamente en horas adicionales de codificación externa y de inferencia.

Tabla 29. Presupuesto estimado por categoría, con contingencia del 20 %.

Categoría	Concepto	Cantidad	Costo unitario	Subtotal (USD)	% del total
Recursos humanos	Equipo core (costo de oportunidad)	112 h	USD 20/h	2 240	65.5 %
Recursos humanos	Codificadores externos de GENIAL (costo de oportunidad)	28 h	USD 20/h	560	16.4 %
Recursos técnicos	API del LLM (conjunto de prueba × 3 ejecuciones + pasada completa)	≈1 300 llamadas	≈USD 0.04/llamada	50	1.5 %
Recursos técnicos	Hardware, almacenamiento, software, licencias	—	Propios / código abierto	0	0 %
Datos	Adquisición del corpus y datasets alternativos	—	Autorizado / público	0	0 %

Categoría	Concepto	Cantidad	Costo unitario	Subtotal (USD)	% del total
Subtotal				**2 850**	**83.3 %**
Contingencia	20 % del subtotal (ampliación del conjunto de prueba, horas externas adicionales, llamadas repetidas a la API)			570	16.7 %
Total estimado				**3 420**	**100 %**

Desembolso real previsto: USD 50 (API), con contingencia de USD 20 adicionales dentro de la partida de contingencia; el resto del presupuesto es costo de oportunidad. Si se activara el plan B con MultiEURLEX, el costo de inferencia crecería con el tamaño del conjunto de prueba, pero seguiría por debajo de la contingencia prevista.

8.4 Plan de adquisición y gestión de recursos

Tabla 30. Adquisición y gestión de cada recurso: cuándo, cómo, quién y estado.

Recurso	Cómo se adquiere o asegura	Cuándo	Responsable	Estado
Autorización del corpus	Solicitud escrita a la coordinación de GENIAL con compromiso de atribución y no redistribución	Sprint 1	Jorge (enlace GENIAL)	Obtenida
2.° y 3.er codificador	Designación por la coordinación; agenda de dos jornadas en la Semana 6 y media jornada de adjudicación	Sprint 1 (designación), Sprint 3 (ejecución)	Jorge	Confirmados
Tiempo del equipo	Bloques protegidos de 8 h/semana por integrante, agendados al inicio de cada sprint	Cada sprint	Scrum Master del sprint	En curso
Clave y cuota de la API	Clave del equipo; prueba de conexión y estimación de consumo en el Sprint 1; tope de gasto configurado	Sprint 1	Melissa	En curso
Entorno reproducible	*requirements.txt* con versiones fijadas; semilla global; verificación en las dos máquinas	Sprint 1	Melissa	En curso
Repositorio GitHub	Repositorio público con README, licencia, muestra anonimizada, *hash* del corpus y *notebook*	Sprint 1	Ambos	Inicializado
Corpus congelado	Copia fechada con SHA-256 registrado; almacenamiento institucional cifrado, fuera del repositorio	Sprint 1	Jorge	En curso
Contingencia	Se libera solo por decisión del *sprint review*; su uso se registra en la bitácora con el riesgo que la activó	Sprints 3-4	Product Owner	Reservada

9. Hitos y entregables

Se definen ocho hitos distribuidos en las siete semanas del proyecto, uno por semana y dos en la Semana 6, que es la de mayor densidad. Cada hito tiene un entregable con formato definido, criterios de aceptación medibles, un responsable, un procedimiento de revisión y aprobación, y un riesgo asociado con su contingencia. Los hitos H1 y H2 corresponden al Sprint 1 y están cumplidos; H3 y H4 al Sprint 2; H5, H6 y H7 al Sprint 3; H8 al Sprint 4.

9.1 Definición de los ocho hitos

Tabla 31. Hitos del proyecto: entregable, criterios de aceptación, responsable, procedimiento de aprobación y riesgo asociado.

Hito y fecha	Entregable (formato)	Criterios de aceptación medibles	Responsable · Revisión y aprobación	Riesgo asociado · Contingencia
H1 · Problema seleccionado y validado	Post del foro con tres problemas clasificados por dominio (texto) y	Tres problemas de 100-150 palabras; matriz con pesos que suman 100 %,	Ambos · Publicación en el foro; retroalimentación del	El tutor no valida el problema · Reformular con el segundo

Hito y fecha	Entregable (formato)	Criterios de aceptación medibles	Responsable · Revisión y aprobación	Riesgo asociado · Contingencia
Semana 1 · 14 sep 2026 (cumplido)	matriz de evaluación SMART ponderada (XLSX)	justificaciones de 50-80 palabras y un problema con puntaje ≥ 4.0 de 5.	tutor recibida e incorporada como condiciones metodológicas.	problema de la matriz (3.20).
H2 · Plan aprobado y corpus asegurado Semana 2 · 21 sep 2026 (cumplido)	Mapa del estado del arte, Canvas SMART, checklist, análisis de datasets y stakeholders, matriz de KPIs, cronograma (DOCX/PDF con plantilla UEES); decisiones metodológicas v1.0 (MD); autorización escrita del consorcio	≥ 20 fuentes verificadas (29); checklist ≥ 26/31 (27); cuatro condiciones metodológicas resueltas; autorización y 2.° codificador confirmados por escrito.	Ambos · *Sprint review* con el tutor; acuse de la coordinación de GENIAL.	Autorización demorada · Estadísticas agregadas solo; sin resultados por país hasta obtenerla.
H3 · Corpus depurado y muestreo cerrado Semana 3 · 28 sep 2026	Corpus depurado con variable idioma (CSV/Parquet + reporte de calidad MD); *fewshot_examples.csv*; *test_blind.csv* y *test_labels_hidden.csv*; línea base de metadata (tabla)	0 faltantes en *Dominio* y *texto*; idioma en el 100 % de las filas con verificación manual de las no hispanohablantes; duplicados por URL resueltos; 15 ejemplos (3 por dimensión); 100-150 casos de prueba estratificados por dimensión e idioma; línea base de metadata reportada con F1 macro y exactitud.	Jorge · Revisión cruzada de Melissa; validación de dominio del muestreo por la coordinación de GENIAL (2 h); aceptación del Product Owner.	Menos de 20 normas no hispanohablantes en prueba · Decisión de la Semana 3: idioma solo como limitación declarada.
H4 · Rama clásica entrenada Semana 4 · 5 oct 2026	Modelo TF-IDF + Regresión Logística serializado; *notebook* con validación cruzada; tabla de métricas por clase y matriz de confusión; archivo de *predict_proba* y top-2 por norma	Validación cruzada estratificada de 5 particiones ejecutada con semilla fija; F1 por clase e IC; comparación con la variante sin *class_weight*; pruebas unitarias de ausencia de fuga aprobadas; términos más predictivos por dimensión listados.	Melissa · Revisión cruzada de Jorge; *sprint review* del Sprint 2 con el tutor.	Técnico no se aprende · Documentar como subajuste por tamaño y heterogeneidad; elevar a GENIAL como posible revisión conceptual.
H5 · Comparación pareada completa Semana 5 · 12 oct 2026	*Prompt* versionado (TXT/MD); *llm_predictions.csv* con 1.ª y 2.ª dimensión; tabla comparativa con McNemar, IC y métricas por idioma y país; reporte de estabilidad	100 % del conjunto de prueba clasificado por el LLM en tres ejecuciones con temperatura fija; valor *p* de McNemar; IC de Wilson (exactitud) y *bootstrap* (F1 macro) para ambas ramas; métricas desagregadas por idioma y país.	Melissa · Revisión cruzada de Jorge; punto de decisión de la Semana 5 (¿comparación concluyente?).	Diferencia no significativa · Reencuadre como eficiencia de datos; ampliar a 150 casos.
H6 · Fiabilidad medida Semana 6 · 16 oct 2026	Cuadernillo de codificación y regla de gold standard (PDF); conjunto codificado por el 2.° codificador (CSV); adjudicaciones del 3.°; reporte de fiabilidad con κ h-h y κ m-h (tabla)	Regla fijada por escrito antes de medir; codificación ciega (sin predicciones ni etiqueta original); κ h-h y κ m-h para ambas ramas con IC; número y lista de casos adjudicados.	Jorge · Ejecución por el 2.° y 3.er codificador de GENIAL; verificación del protocolo ciego por Melissa; aceptación del Product Owner.	2.° codificador no completa · Contingencia intraequipo sobre 30 normas, declarada como acuerdo intraequipo.
H7 · Flujo asistido especificado Semana 6 · 19 oct 2026	Tipificación de errores (tabla con conteos por categoría); nota conceptual Administrativo-Ética (MD); umbral de confianza calibrado y simulación de carga humana (tabla); propuesta de agregación al IMN con origen de cada etiqueta (XLSX/CSV)	100 % de los errores del conjunto de prueba tipificados en tres categorías; umbral fijado con % de enrutamiento ≤ 30 % y exactitud del tramo automático reportada; h-persona residuales estimadas; tabla IMN por país con margen de error por dimensión.	Ambos · Revisión cruzada; *sprint review* del Sprint 3 con el tutor; nota conceptual enviada a la coordinación de GENIAL.	Umbral que enruta casi todo o casi nada · Reportar la curva completa enrutamiento-exactitud y dejar la elección del punto de operación al consorcio.
H8 · Entrega final Semana 7 · 25 oct 2026	Documento técnico final (PDF); repositorio GitHub con *notebook* reproducible, *prompts*, README y muestra; Caso de Negocio y Guía Técnica actualizados (DOCX/PDF);	*Notebook* ejecutado de extremo a extremo por el integrante que no lo escribió con resultados idénticos; reflexión ética y limitaciones con la misma prominencia que los resultados; ≥	Ambos · Revisión cruzada final; entrega en la plataforma del módulo; evaluación del tutor con la rúbrica.	Retraso acumulado del Sprint 3 · Recorte de las historias *Should* (US-12, US-18); redacción incremental del documento desde el Sprint 2.

Hito y fecha	Entregable (formato)	Criterios de aceptación medibles	Responsable · Revisión y aprobación	Riesgo asociado · Contingencia
	pitch de 3 minutos (video)	20 referencias IEEE; pitch ≤ 180 s; checklist de revisión cruzada completado.		

9.2 Fechas críticas y dependencias

La ruta crítica del proyecto pasa por H3 → H4 → H5 → H6 → H8: el muestreo ciego (H3) es prerrequisito de ambas ramas y de la doble codificación; la rama clásica (H4) debe reentrenarse excluyendo el conjunto de prueba antes de la comparación (H5); la doble codificación (H6) necesita el conjunto de prueba cerrado pero **no** las predicciones de los modelos —debe ejecutarse a ciegas—, por lo que puede correr en paralelo con H5 desde la Semana 5; y la tipificación de errores (H7) necesita tanto las predicciones (H5) como las etiquetas adjudicadas (H6). La única dependencia externa es la disponibilidad de los codificadores de GENIAL en la Semana 6, ya confirmada.

Tabla 32. Dependencias entre hitos y fechas críticas.

Hito	Depende de	Habilita	Fecha crítica	Holgura
H3	H2 (autorización, corpus congelado)	H4, H5, H6	28 sep: si el muestreo no cierra, las dos ramas y la doble codificación se desplazan	0 días
H4	H3	H5	5 oct: el reentrenamiento sin el conjunto de prueba debe estar listo antes de la comparación	2 días (la rama LLM puede arrancar con el *prompt* en paralelo)
H5	H3, H4	H7	12 oct: punto de decisión sobre significancia	0 días
H6	H3 y agenda del 2.° codificador (externa)	H7	16 oct: última fecha para recibir la codificación externa sin activar la contingencia	0 días
H7	H5, H6	H8	19 oct: cierre del Sprint 3	0 días
H8	H7 y reproducción independiente del *notebook*	—	25 oct: entrega del módulo	0 días

9.3 Procedimientos de revisión y aprobación

Todo hito sigue el mismo procedimiento en cuatro pasos. **(1) Autoverificación** del responsable contra los criterios de aceptación de la Tabla 31, con evidencia adjunta (archivos, tablas, *commit*). **(2) Revisión cruzada** por el integrante que no produjo el entregable, que ejecuta el código o relee el documento y registra observaciones en el repositorio (*issues*). **(3) Aceptación del Product Owner**, que marca el hito como cumplido solo si todos los criterios se verifican; un hito parcialmente cumplido se registra como tal, con la lista de criterios pendientes y la fecha de recuperación. **(4) Aprobación externa** cuando corresponde: el docente-tutor en los *sprint reviews* (H2, H4, H7, H8) y la coordinación de GENIAL en los hitos que tocan el corpus o a sus codificadores (H2, H3, H6, H7). Las aprobaciones quedan registradas en la bitácora con fecha y firmante; ninguna aprobación se da por supuesta.

10. Conclusiones de la fase de planificación y próximos pasos

La fase de planificación deja un proyecto ejecutable dentro de las siete semanas del módulo y defendible ante revisión externa. Tres decisiones lo distinguen de una aplicación rutinaria de clasificación de texto. La primera es **comparar en lugar de suponer**: la literatura muestra que el desempeño relativo del LLM *few-shot* frente a un modelo clásico depende del dominio hasta el punto de invertirse, de modo que la única respuesta honesta es un experimento pareado sobre el corpus propio con prueba de significancia. La segunda es **poner al codificador humano dentro del experimento**: sin una medida del acuerdo humano-humano, cualquier F1 carece de referente; el proyecto la produce por primera vez sobre este corpus y la usa como techo interpretativo. La

tercera es **diseñar la operación para desconfiar del modelo donde debe hacerlo**: el umbral de confianza y la revisión obligatoria para países e idiomas subrepresentados convierten el sesgo geográfico, el más grave para un índice que compara países, en una regla de gobernanza y no en una nota al pie.

Las cuatro condiciones metodológicas planteadas por la tutora quedaron resueltas por diseño y no por declaración: el diagnóstico de multi-etiqueta se ejecuta con el top-2 y la tipificación de errores; el balance de clases se ataca con F1 macro, ponderación y un conjunto de prueba dimensionado para McNemar; el desacuerdo intercodificador se mide con doble codificación ciega y adjudicación; y el idioma entra como variable de primera clase en el muestreo y en el reporte. Los riesgos residuales están identificados con su contingencia, y el único de alta probabilidad —una comparación no concluyente— tiene un reencuadre honesto y más útil para GENIAL: desempeño equivalente con unas cincuenta veces menos ejemplos etiquetados.

Próximos pasos inmediatos (Sprint 2, desde el 22 de septiembre):

1. Cargar el corpus congelado (SHA-256 registrado en el repositorio), corregir el valor faltante de *Dominio*, normalizar *Tipo de norma*, resolver los 16 pares de URL repetida e incorporar la variable idioma con verificación manual.
2. Construir la línea base de metadata y verificar operativamente que *Dominio* es *single-label*.
3. Cerrar el muestreo estratificado por dimensión e idioma (pool de 15, conjunto de prueba de 100-150) y someterlo a validación de dominio antes del 28 de septiembre.
4. Entrenar la rama clásica con validación cruzada estratificada, almacenar *predict_proba* y top-2, y ejecutar las pruebas unitarias de ausencia de fuga.
5. Fijar por escrito, antes de la Semana 6, la regla de gold standard ante discrepancia y preparar el cuadernillo de codificación ciega.

Referencias

Formato IEEE, numeradas por orden de primera cita en el texto. Las 29 fuentes revisadas en el estado del arte (Tabla 2) corresponden al período 2021-2026; las referencias metodológicas clásicas, las herramientas y las fuentes de datos se citan como fundamento de método.

[1] A. Valentini, “AI adoption and governance in Latin American and Caribbean higher education: Findings from a regional survey,” Revista Educación Superior y Sociedad (UNESCO IESALC), vol. 37, no. 2, pp. 288–307, 2026, doi: 10.54674/ess.v37i2.1278.

[2] E. Levy Yeyati, “An enabling regulatory framework for artificial intelligence in Latin America and the Caribbean,” Inter-American Development Bank, Washington, DC, USA, Tech. Note IDB-TN-3241, 2025. [Online]. Available: https://publications.iadb.org

[3] P. Martorell and M. Porrúa, “Modelo de referencia para políticas de IA en el sector público de América Latina y el Caribe,” Banco Interamericano de Desarrollo, Washington, DC, USA, 2026, doi: 10.18235/0014418.

[4] Oxford Insights, “Government AI Readiness Index 2025,” 8th ed., Oxford Insights, Oxford, U.K., 2025. [Online]. Available: https://oxfordinsights.com

[5] CEPAL and CENIA, “Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025: Hallazgos principales, IA aplicada y talento humano,” Comisión Económica para América Latina y el Caribe, Santiago, Chile, Rep. LC/TS.2026/1, 2026. [Online]. Available: https://repositorio.cepal.org/handle/11362/86007

[6] Proyecto GENIAL (Erasmus+), “Corpus consolidado de normativa sobre inteligencia artificial en educación superior de América Latina y el Caribe (consolidado_limpio.xlsx, versión congelada de septiembre de 2026),” conjunto de datos de investigación, no publicado, 2026. Uso autorizado por la coordinación del consorcio.

[7] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” Psychometrika, vol. 12, no. 2, pp. 153–157, 1947, doi: 10.1007/BF02295996.

[8] T. G. Dietterich, “Approximate statistical tests for comparing supervised classification learning algorithms,” Neural Computation, vol. 10, no. 7, pp. 1895–1923, 1998, doi: 10.1162/089976698300017197.

[9] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” Journal of the American Statistical Association, vol. 22, no. 158, pp. 209–212, 1927, doi: 10.1080/01621459.1927.10502953.

[10] J. Cohen, “A coefficient of agreement for nominal scales,” Educational and Psychological Measurement, vol. 20, no. 1, pp. 37–46, 1960, doi: 10.1177/001316446002000104.

[11] J. R. Landis and G. G. Koch, “The measurement of observer agreement for categorical data,” Biometrics, vol. 33, no. 1, pp. 159–174, 1977, doi: 10.2307/2529310.

[12] B. Plank, “The ‘problem’ of human label variation: On ground truth in data, modeling and evaluation,” in Proc. 2022 Conf. on Empirical Methods in Natural Language Processing (EMNLP), Abu Dhabi, UAE, Dec. 2022, pp. 10671–10682, doi: 10.18653/v1/2022.emnlp-main.731.

[13] N. Pangakis, S. Wolken, and N. Fasching, “Automated annotation with generative AI requires validation,” arXiv:2306.00176 [cs.CL], Jun. 2023.

[14] I. Chalkidis, M. Fergadiotis, and I. Androutsopoulos, “MultiEURLEX – A multi-lingual and multi-label legal document classification dataset for zero-shot cross-lingual transfer,” in Proc. 2021 Conf. on Empirical Methods in Natural Language Processing (EMNLP), Punta Cana, Dominican Republic, Nov. 2021, pp. 6974–6996, doi: 10.18653/v1/2021.emnlp-main.559.

[15] I. Chalkidis, A. Jana, D. Hartung, M. Bommarito, I. Androutsopoulos, D. Katz, and N. Aletras, “LexGLUE: A benchmark dataset for legal language understanding in English,” in Proc. 60th Annu. Meeting of the Association for Computational Linguistics (ACL), vol. 1, Dublin, Ireland, May 2022, pp. 4310–4330, doi: 10.18653/v1/2022.acl-long.297.

[16] I. Chalkidis, “ChatGPT may pass the bar exam soon, but has a long way to go for the LexGLUE benchmark,” arXiv:2304.12202 [cs.CL], Apr. 2023, doi: 10.2139/ssrn.4385460.

[17] N. Guha, J. Nyarko, D. E. Ho, C. Ré, A. Chilton, et al., “LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models,” in Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track, New Orleans, LA, USA, Dec. 2023. arXiv:2308.11462.

[18] C. Tang, Z. Liu, C. Ma, Z. Wu, Y. Li, W. Liu, D. Zhu, Q. Li, X. Li, T. Liu, and L. Fan, “PolicyGPT: Automated analysis of privacy policies with large language models,” arXiv:2309.10238 [cs.CL], Sep. 2023.

[19] A. Edwards and J. Camacho-Collados, “Language models for text classification: Is in-context learning enough?,” in Proc. 2024 Joint Int. Conf. on Computational Linguistics, Language Resources and Evaluation (LREC-COLING), Torino, Italy, May 2024. arXiv:2403.17661.

[20] M. Sebők, Á. Máté, O. Ring, V. Kovács, and R. Lehoczki, “Leveraging open large language models for multilingual policy topic classification: The Babel Machine approach,” Social Science Computer Review, vol. 43, no. 2, 2025, doi: 10.1177/08944393241259434.

[21] E. Gunes and C. K. Florczak, “Replacing or enhancing the human coder? Multiclass classification of policy documents with large language models,” Journal of Computational Social Science, vol. 8, no. 2, art. 31, 2025, doi: 10.1007/s42001-025-00362-2.

[22] J. Lee, “Legal text classification in Korean sexual offense cases: From traditional machine learning to large language models with XAI insights,” Artificial Intelligence and Law, 2025, doi: 10.1007/s10506-025-09454-w.

[23] Y. Chae and T. Davidson, “Large language models for text classification: From zero-shot learning to instruction-tuning,” Sociological Methods & Research, vol. 55, no. 2, 2025, doi: 10.1177/00491241251325243.

[24] Y. Tang, D. Tuncel, C. Koerner, and T. Runkler, “The few-shot dilemma: Over-prompting large language models,” arXiv:2509.13196 [cs.CL], Sep. 2025.

[25] A. M. Davani, M. Díaz, and V. Prabhakaran, “Dealing with disagreements: Looking beyond the majority vote in subjective annotations,” Transactions of the Association for Computational Linguistics, vol. 10, pp. 92–110, 2022, doi: 10.1162/tacl_a_00449.

[26] F. Gilardi, M. Alizadeh, and M. Kubli, “ChatGPT outperforms crowd workers for text-annotation tasks,” Proceedings of the National Academy of Sciences, vol. 120, no. 30, art. e2305016120, 2023, doi: 10.1073/pnas.2305016120.

[27] R. Chew, J. Bollenbacher, M. Wenger, J. Speer, and A. Kim, “LLM-assisted content analysis: Using large language models to support deductive coding,” arXiv:2306.14924 [cs.CL], Jun. 2023.

[28] M. Heseltine and B. Clemm von Hohenberg, “Large language models as a substitute for human experts in annotating political text,” Research & Politics, vol. 11, no. 1, 2024, doi: 10.1177/20531680241236239.

[29] C. Ziems, W. Held, O. Shaikh, J. Chen, Z. Zhang, and D. Yang, "Can large language models transform computational social science?," Computational Linguistics, vol. 50, no. 1, pp. 237–291, 2024, doi: 10.1162/coli_a_00502.

[30] S. Rathje, D.-M. Mirea, I. Sucholutsky, R. Marjieh, C. E. Robertson, and J. J. Van Bavel, "GPT is an effective tool for multilingual psychological text analysis," Proceedings of the National Academy of Sciences, vol. 121, no. 34, 2024, doi: 10.1073/pnas.2308950121.

[31] H. Schroeder, D. Roy, and J. Kabbara, "Just put a human in the loop? Investigating LLM-assisted annotation for subjective tasks," in Findings of the Association for Computational Linguistics: ACL 2025, Vienna, Austria, Jul. 2025, pp. 25771–25795, doi: 10.18653/v1/2025.findings-acl.1323.

[32] C. Wu, H. Zhang, and J. M. Carroll, "AI governance in higher education: Case studies of guidance at Big Ten universities," Future Internet, vol. 16, no. 10, art. 354, 2024, doi: 10.3390/fi16100354.

[33] Y. Jin, L. Yan, V. Echeverria, D. Gašević, and R. Martinez-Maldonado, "Generative AI in higher education: A global perspective of institutional adoption policies and guidelines," Computers and Education: Artificial Intelligence, vol. 8, art. 100348, 2025, doi: 10.1016/j.caeai.2024.100348.

[34] Y. Jiang, L. Xie, and X. Cao, "Exploring the effectiveness of institutional policies and regulations for generative AI usage in higher education," Higher Education Quarterly, vol. 79, no. 4, art. e70054, 2025, doi: 10.1111/hequ.70054.

[35] S. Kaya-Kasikci, C. R. Glass, E. Chacon Camero, and E. Minaeva, "University positioning in AI policies: Comparative insights from national policies and non-state actor influences," Higher Education Quarterly, vol. 79, no. 4, 2025, doi: 10.1111/hequ.70062.

[36] coastalcph, "multi_eurlex," conjunto de datos, Hugging Face Hub, 2021. [Online]. Available: https://huggingface.co/datasets/coastalcph/multi_eurlex (accedido: 19 sep. 2026).

[37] OECD, "OECD.AI Policy Navigator: National AI policies, strategies and initiatives," OECD.AI Policy Observatory, 2026. [Online]. Available: https://oecd.ai/en/dashboards/policy-initiatives (accedido: 19 sep. 2026).

[38] K. Krippendorff, Content Analysis: An Introduction to Its Methodology, 4th ed. Thousand Oaks, CA, USA: SAGE, 2018.

[39] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[40] UNESCO, Guidance for Generative AI in Education and Research. Paris, France: UNESCO, 2023, doi: 10.54675/EWZM9535.

[41] K. Schwaber and J. Sutherland, The Scrum Guide: The Definitive Guide to Scrum: The Rules of the Game. Scrum.org, Nov. 2020. [Online]. Available: https://scrumguides.org

Anexos

Anexo A. Muestra representativa del corpus GENIAL

Quince normas reales del corpus, tres por dimensión, seleccionadas por muestreo aleatorio con semilla fija entre los registros de longitud media, con presencia de portugués (Brasil) e inglés (Guyana). Se omiten las columnas *Investigador* (anonimizada por razones éticas), *Estado*, *Organismo Emisor*, *Vínculo*, *Dedicación*, *Fecha* y *URL Oficial* por espacio; el repositorio incluye una muestra de 40 normas con las 13 columnas (*data/samples/sample_corpus_40.csv*). Versión congelada del archivo: SHA-256 f9797147e7026f79… (completo en el repositorio) [6].

Tabla 33. Muestra de 15 normas del corpus GENIAL (texto de entrada del modelo = Título + Observaciones).

País	Tipo de norma	Título de la norma	Ámbito	Dominio (etiqueta)	Observaciones (extracto)
Argentina	Guía Pedagógica	Guía: Herramientas IA para docentes	Institucional	Pedagógico	UNLP presenta herramientas de IA para docentes mediante guía, para apoyar planificación, creación de materiales y evaluación.

País	Tipo de norma	Título de la norma	Ámbito	Dominio (etiqueta)	Observaciones (extracto)
Brasil	Resolución rectoral	Dispõe sobre a Política do Uso de Inteligência Artificial no âmbito	Institucional	Pedagógico	la resolución busca que la UFDPar adopte la IA de forma ética, transparente, inclusiva y segura, equilibrando innovación con protección de derechos y valores humanos.
Brasil	Guía Pedagógica	Recomendações para o avanço da inteligência artificial no Brasil	Nacional	Pedagógico	Consta de una publicación con el objetivo de expresar los diversos beneficios de herramientas de IA de diversos dominios incluyendo la educación.
México	Ley	Iniciativa con Proyecto de Decreto por el que se expide la Ley Nacional para Regular el Uso de la Inteligencia	Nacional	Ética	Iniciativa legislativa relevante para la gobernanza general de IA en México; menciona coordinación con SEP, pero no constituye regulación educativa específica ni norma vigente.
El Salvador	Guía ética	Desafíos Éticos y Académicos en un Mundo Impulsado por la IA (Política de la Revista Diá-logos)	Institucional	Ética	Exige la declaración obligatoria del uso de IA en los artículos y prohíbe considerar a la IA como autora de contenidos. Es tomada en cuenta dentro de la Universidad Don Bosco
México	Guía Pedagógica	Recomendaciones éticas sobre el uso de la inteligencia artificial (IA) en educación superior: una revisión sis	Institucional	Ética	Se establecen los siguientes segmentos: recomendaciones para instituciones, recomendaciones para profesorado y para alumnado.
Argentina	Lineamiento Académico	Resolución 4/2025 - Directrices de uso de Inteligencia Artificial Generativa en la Administración Pública bona	Nacional	Administrativo	Emitida por Buenos Aires, ordena el uso de IA generativa en la administración pública, con pautas para transparencia y control.
México	Libro blanco	Inteligencia Artificial en la Educación Superior: Diagnóstico, propuestas y política pública.	Nacional	Administrativo	Propone la creación de un Consejo Nacional para la Ética de la IA en IES (CONEIAUIES)
Argentina	Resolución rectoral	Ordenanza N° 014/2025 - Diplomatura Universitaria en Inteligencia Artificial Aplicada a la Educación	Institucional	Administrativo	UNCUYO crea diplomatura en IA aplicada a educación mediante ordenanza, para fortalecer formación universitaria y competencias docentes.
Uruguay	Ley	Ley de Protección de Datos Personales	Nacional	Protección de Datos	El Estado uruguayo regula datos personales mediante ley, para proteger la privacidad de las personas y ordenar tratamientos responsables.
Guyana	Ley	Data Protection Act 2023	Nacional	Protección de Datos	Contradicción lógica: un texto de vínculo Indirecto no puede dedicar su articulado completo a la IA
Bolivia	Reglamento	Politica de Privacidad - Universidad Franz Tamayo (UNIFRANZ)	Institucional	Protección de Datos	Politica de privacidad institucional. Sin referencia a IA. Intenta regular datos de navegacion; insuficiente para entornos de aprendizaje mediados por IA.
Argentina	Ley	Observatorio Federal sobre Inteligencia artificial	Nacional	Técnico	Diputados argentinos crean un observatorio federal de IA mediante ley, para monitorear avances, riesgos y políticas públicas del país.
El Salvador	Reglamento	Disposiciones Relativas a la Implementación de IA (Resolución 0001-2025)	Nacional	Técnico	Reglamento operativo emitido por la ANIA para dar cumplimiento a la ley de fomento
Argentina	Ley	Responsabilidad algorítmica y promoción de la robótica, algoritmos verdes e inteligencia artificial	Nacional	Técnico	Diputados argentinos regulan responsabilidad algorítmica e IA verde mediante ley, para promover innovación con control y sostenibilidad.

Anexo B. Diccionario de datos del corpus

Tabla 34. Las 13 columnas del archivo consolidado, su tipo, contenido y uso en el proyecto.

Columna	Tipo	Contenido	Uso en el proyecto
Investigador	Categórica (10 valores)	Investigador del consorcio que codificó la norma.	Solo para el análisis de sesgo de codificador (agregado). Excluida como variable predictora; anonimizada en la muestra pública.
País	Categórica (28 valores)	País o jurisdicción de la norma.	Estratificación, análisis desagregado y regla de revisión obligatoria. No predictora.
Título de la Norma	Texto libre	Título oficial o descriptivo de la norma.	Parte del texto de entrada del modelo.
Tipo de norma	Categórica (14 → 11 tras normalizar)	Ley, Decreto, Estrategia Nacional, Reglamento, Resolución rectoral, Lineamiento Académico, Guía ética, Guía Pedagógica, Libro blanco, Otro…	Línea base de metadata. Excluida como variable predictora por fuga de información.
Estado	Categórica (3)	Vigente (719), En proyecto/borrador (91), Derogada (1); 2 faltantes.	Caracterización.
Organismo Emisor/Universidad	Texto libre	Entidad que emite la norma.	Caracterización.
Dominio	Categórica (5)	Dimensión GENIAL: Pedagógico, Ética, Administrativo, Protección de Datos, Técnico. 1 faltante corregido.	Variable objetivo.
Vínculo con Educación	Categórica (2)	Directo (604) / Indirecto (209).	Caracterización y análisis de errores.
Dedicación del Texto	Categórica (5)	Articulado completo (533), Sección/Capítulo (175), Mención breve (91), Otro (7), Sección/Capítulo propuesto (7).	Caracterización; posible covariable del análisis de errores.
Fecha de Publicación	Texto libre heterogéneo	Fechas en formatos mixtos; ≈25 % con «N/D», «s/f», «No indica».	Excluida; heterogeneidad documentada como hallazgo de calidad.
URL Oficial	Texto (URL)	Enlace a la fuente pública de la norma; 16 valores repetidos.	Deduplicación antes de particionar; trazabilidad.
Observaciones	Texto libre (6-274 palabras junto al título)	Resumen del contenido de la norma redactado por el codificador; 1 faltante.	Parte del texto de entrada del modelo. Verificar ausencia de fuga léxica de la etiqueta.
Ámbito	Categórica (2)	Institucional (563) / Nacional (250).	Caracterización y análisis de errores.

Anexo C. Plantilla del prompt few-shot (v0.1)

Versión inicial del *prompt* de la rama LLM, a fijar y versionar en el Sprint 3 (*prompts/clasificador_v0.1.md* en el repositorio). Política de idioma: definiciones en español; la norma se presenta en su idioma original, sin traducción previa. Temperatura 0; se solicita explícitamente una primera y una segunda dimensión.

```
SISTEMA: Eres un codificador experto del observatorio GENIAL de normativa sobre inteligencia artificial en la educación superior de América Latina y el Caribe. Clasificas cada norma en UNA de cinco dimensiones, siguiendo estrictamente las definiciones del equipo. No inventes dimensiones. Responde en el formato indicado.
DEFINICIONES DE LAS DIMENSIONES:
- Pedagógico: la norma regula u orienta el uso de la IA en procesos de enseñanza, aprendizaje, evaluación o formación docente.
- Ética: la norma establece principios, valores, límites o responsabilidades para un uso responsable de la IA (integridad académica, transparencia, equidad, rendición de cuentas).
- Administrativo: la norma organiza la gobernanza institucional o estatal de la IA (estrategias, estructuras, competencias, procedimientos, planes).
- Protección de Datos: la norma regula el tratamiento de datos personales, la privacidad o la seguridad de la información en relación con la IA.
```

```
- Técnico: la norma regula aspectos tecnológicos, de infraestructura, ciberseguridad,
interoperabilidad o desarrollo de sistemas de IA.
EJEMPLOS CODIFICADOS POR EL EQUIPO (15, tres por dimensión):
[Ejemplo 1] Texto: «…» → Dimensión: Pedagógico
[…] (se insertan los 15 ejemplos de fewshot_examples.csv, en su idioma original)
NORMA A CLASIFICAR:
Título: {titulo}
Observaciones: {observaciones}
INSTRUCCIONES DE SALIDA: Devuelve exactamente dos líneas: «Primera: <dimensión>» y «Segunda:
<dimensión>», donde la segunda es la dimensión alternativa más plausible si la primera fuera
incorrecta. No añadas explicaciones.
```

Anexo D. Estructura del repositorio y contenido del README

El repositorio *genial-clasificador-normativa* acompaña esta entrega y está publicado en GitHub: https://github.com/jorgemaldonadom-cmd/genial-clasificador-normativa. Contiene el código inicial del *pipeline*, la muestra anonimizada, los *prompts*, la documentación y las licencias. El corpus completo no se incluye: se registra su *hash* y sus metadatos.

```
genial-clasificador-normativa/
├── README.md                 · descripción, arquitectura, instalación, uso, métricas, licencias,
cita
├── LICENSE                   · MIT (código)
├── DATA_LICENSE.md           · condiciones de uso de los datos (muestra: uso académico con
atribución; corpus: no redistribuible)
├── CITATION.cff              · cómo citar el proyecto
├── requirements.txt          · versiones fijadas (Python 3.12, scikit-learn 1.8, pandas, …)
├── config.yaml               · rutas, semilla, tamaños de partición, umbral, versión del modelo LLM
├── data/
│   ├── README.md             · procedencia, hash SHA-256 del corpus congelado, diccionario de datos
│   ├── samples/sample_corpus_40.csv   · 40 normas reales anonimizadas (8 por dimensión, 13
columnas)
│   ├── samples/fewshot_examples_template.csv · esquema del pool few-shot
│   └── raw/ processed/ splits/        · vacíos en el repo (.gitkeep); el corpus se coloca
localmente
├── src/genial_clf/
│   ├── data.py               · carga, limpieza, idioma, deduplicación, campo de texto
│   ├── split.py              · muestreo estratificado por dimensión e idioma; archivos ciegos
│   ├── baselines.py          · clase mayoritaria y línea base de metadata
│   ├── classic.py            · TF-IDF + Regresión Logística, validación cruzada, top-2
│   ├── llm.py                · construcción del prompt, llamada a la API, parseo top-2,
repeticiones
│   ├── evaluate.py           · F1, matriz de confusión, McNemar, IC de Wilson y bootstrap, κ
│   ├── reliability.py        · κ humano-humano, adjudicación, tipificación de errores
│   └── imn.py                · umbral de confianza, enrutamiento, agregación al IMN con
trazabilidad
├── scripts/run_pipeline.py   · ejecución de extremo a extremo por etapas
├── notebooks/01_eda.ipynb …  · exploración y reporte de calidad (a completar en el Sprint 2)
├── prompts/clasificador_v0.1.md  · prompt versionado con política de idioma
├── docs/                     · documento técnico (PDF), decisiones metodológicas, protocolo de
codificación ciega
└── tests/                    · pruebas unitarias: partición sin fuga, duplicados, métricas
```

El README documenta: propósito y contexto GENIAL; los dos flujos (experimento y operación) con las figuras de este documento; instalación reproducible; cómo colocar el corpus autorizado y verificar su *hash*; ejecución por etapas; definición de las métricas y umbrales; estructura de los archivos de salida; licencias y permisos verificados (código MIT; muestra con uso académico y atribución a GENIAL; corpus no redistribuible; dependencias de código abierto con licencias BSD/MIT/Apache); y la forma de citar el trabajo.

Anexo E. Matriz de evaluación SMART de los tres problemas

Resumen de la matriz ponderada del *workshop* (archivo XLSX completo entregado con el Workshop de la Semana 1). Escala 1-5 por criterio; puntaje total = suma ponderada.

Tabla 35. Puntajes SMART de los tres problemas propuestos.

Criterio (peso)	P1 · Clasificación de normativa GENIAL / IMN	P2 · Segundo problema propuesto	P3 · Tercer problema propuesto
Específico (20 %)	5	3	2
Medible (20 %)	4	4	2
Alcanzable (25 %)	4	2	1
Relevante (20 %)	4	5	5
Temporal (15 %)	4	2	1
Puntaje ponderado	**4.20 · seleccionado**	**3.20**	**2.20**

Anexo F. Mapa de cumplimiento de la rúbrica

Tabla 36. Correspondencia entre los requisitos del módulo y las secciones de este documento.

Componente (peso)	Requisito	Dónde se cumple
Mapa del estado del arte (17 %)	≥ 20 papers de los últimos 5 años; 5 enfoques; tabla comparativa; timeline; matriz fortalezas/debilidades; gap; posicionamiento	§2: 29 fuentes (Tabla 2), 6 enfoques (Tabla 3), timeline (Tabla 4), matriz (Tabla 5), gap (§2.6), posicionamiento (§2.7)
Análisis de datasets (12 %)	≥ 3 datasets con descripción, procedencia, calidad, idoneidad, accesibilidad; tabla ventajas/desventajas; recomendación; plan B; sesgos; plan de preprocesamiento	§3: D1-D3 (§3.2-3.4), Tabla 6, §3.6, §3.7, Tabla 7, §3.9
Métricas de éxito (12 %)	Técnicas (primarias, secundarias, eficiencia); impacto (KPIs, adopción, satisfacción); usabilidad; umbrales mínimo/excelencia; benchmarks	§4: Tablas 8-11, §4.4, §4.7
Análisis de stakeholders (8 %)	Identificación completa (9 categorías); matriz influencia/interés; necesidades; plan de comunicación	§5: Tablas 12-15
Documento de alcance (17 %)	Objetivo general SMART; 3-5 específicos; alcance incluido/excluido; criterios de aceptación; supuestos; limitaciones	§6: §6.1-6.9, Tablas 16-19
Cronograma ágil (12 %)	4 sprints; Scrum con roles y ceremonias; backlog con user stories y story points; DoD; riesgos por sprint	§7: Figura 4, Tablas 20-26
Plan de recursos (8 %)	Humanos (core, externos, horas por rol y sprint); técnicos; financieros con contingencia 15-20 %	§8: Tablas 27-30
Hitos y entregables (12 %)	8 hitos; entregables con formato y criterios; responsable; revisión y aprobación; riesgos; dependencias	§9: Tablas 31-32, §9.3
Formato	Portada; tabla de contenidos numerada; ≥ 20 referencias IEEE; anexos; repositorio GitHub con README, samples, código y licencias	Portada UEES; índice con paginación; 41 referencias IEEE, de ellas 29 fuentes del estado del arte (2021-2026); Anexos A-F; repositorio github.com/jorgemaldonadom-cmd/genial-clasificador-normativa