Proyecto Integrador en Inteligencia Artificial · MIAR0545 · Presentación final

Clasificación automática de normativa sobre IA en la educación superior de América Latina y el Caribe

Hacia un Índice de Madurez Normativa (IMN) escalable · corpus GENIAL (Erasmus+)

Grupo 9
Jorge Javier Maldonado Mahauad · Melissa Figallo
Tutora: Gladys María Villegas Rugel
Maestría en Inteligencia Artificial · UEES · octubre de 2026

github.com/jorgemaldonadom-cmd/genial-clasificador-normativa

Estructura de la presentación

15 minutos · del problema a la recomendación operativa

1 **Problema y objetivos** — min 1:00
el observatorio GENIAL, la codificación manual y el IMN

2 **Datos y EDA** — min 2:50
813 normas · desbalance 4.7:1 · idioma y pista léxica

3 **Diseño experimental y decisión técnica** — min 4:35
dos ramas, dos líneas base, un conjunto ciego

4 **Resultados** — min 6:35
validación cruzada, por clase, ablaciones, prueba ciega, multi-etiqueta, codificación humana

5 **Operación** — min 12:25
umbral de confianza, enrutamiento, IMN con trazabilidad

6 **Impacto social, umbrales y conclusiones** — min 13:10
equidad por jurisdicción, lo que se cumplió y lo que no

1 El problema: codificar normativa a mano no escala

Observatorio regional del proyecto GENIAL (Erasmus+) · Índice de Madurez Normativa por país

Norma pública (ley, estrategia, reglamento) → Lectura por un investigador → **Una dimensión: Pedagógico · Ética · Administrativo · Protección de Datos · Técnico** → Conteo por país → IMN

No escala

Cada norma exige lectura completa y criterio experto (≈ 10 min/norma). El corpus crece con cada actualización del observatorio y con cada país que se incorpora.

Un solo codificador por norma

No hay fiabilidad intercodificador medida: no sabemos cuánto acordarían dos expertos sobre la misma norma. El estándar de referencia tiene un techo desconocido.

Etiqueta única forzada

Muchas normas tocan dos dimensiones a la vez (pedagógica con componente ético). La codificación las obliga a una sola casilla; el error del modelo y el desacuerdo humano se confunden.

Pregunta: ¿puede un clasificador automático asignar la dimensión con la calidad y la trazabilidad que exige un índice comparativo entre países?

2 Pregunta de investigación y objetivos

Umbrales de éxito fijados por escrito antes de ejecutar (documento técnico, §4)

¿Con qué exactitud puede un clasificador automático asignar la dimensión de una norma a partir de su texto, y cómo se compara esa exactitud con el acuerdo entre codificadores humanos?

O1 Construir y evaluar dos técnicas —clásica supervisada y LLM few-shot— sobre un mismo conjunto de prueba a ciegas.

O2 Medir con intervalos de confianza, pruebas pareadas (McNemar) y κ frente al acuerdo humano-humano.

O3 Diagnosticar la multi-etiqueta a partir de los errores (top-2 y tipificación).

O4 Especificar la integración operativa: umbral de confianza, enrutamiento a revisión humana, IMN trazable.

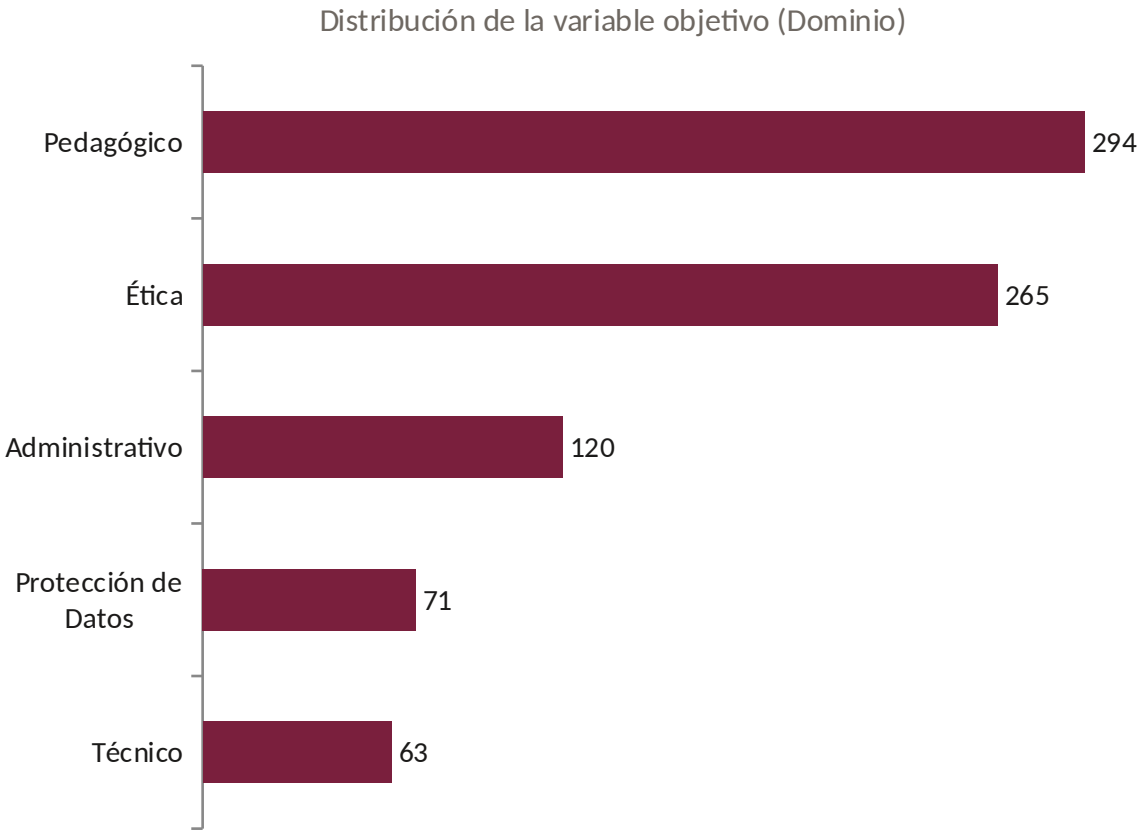
Métrica	Mínimo	Excelencia
F1 macro (mejor rama)	≥ 0.60 y > líneas base (McNemar $p < 0.05$)	≥ 0.70; IC inferior > 0.60
F1 por clase	ninguna < 0.40	ninguna < 0.50
κ modelo-humano	≥ 0.60	≥ κ humano-humano
Normas a revisión humana	≤ 40 %	≤ 30 % con ≥ 85 % de exactitud automática

Piso aritmético (clase mayoritaria): exactitud 0.365 · F1 macro 0.107

3

El corpus GENIAL: 813 normas, 28 jurisdicciones

Versión congelada (SHA-256 verificado al cargar) · 13 columnas · texto = título + observaciones



4.7 : 1

desbalance entre la clase mayor y la menor

44

palabras por norma (mediana); máximo 274

712 · 76 · 25

títulos en español · portugués · inglés

66 %

del corpus en 5 países: MX, CL, AR, BR, EC

Implicación de diseño

813 ejemplos y dos clases con menos de 75 casos: suficiente para un modelo lineal regularizado con clases ponderadas; insuficiente para afinar un transformer sin alta varianza. La clase mayoritaria fija el piso en 36.5 % de exactitud.

4 Lo que el EDA cambió en el diseño

pandas · matplotlib · seaborn · cuaderno ejecutado en el repositorio (Semana 2)

1 · El idioma es de segundo orden

101 títulos en portugués o inglés, pero las observaciones están en español en 798 de 813 normas: las redactan los codificadores.

→ la variable idioma se deriva del título; se desagrega por idioma pero no se espera que domine el error.

2 · Pista léxica de la etiqueta

La palabra que nombra la dimensión aparece en el texto en el 63 % de las normas éticas y el 73 % de las de protección de datos (23 % fuera de su clase).

→ el desempeño se mide con y sin la pista.

3 · Metadata asociada, pero excluida

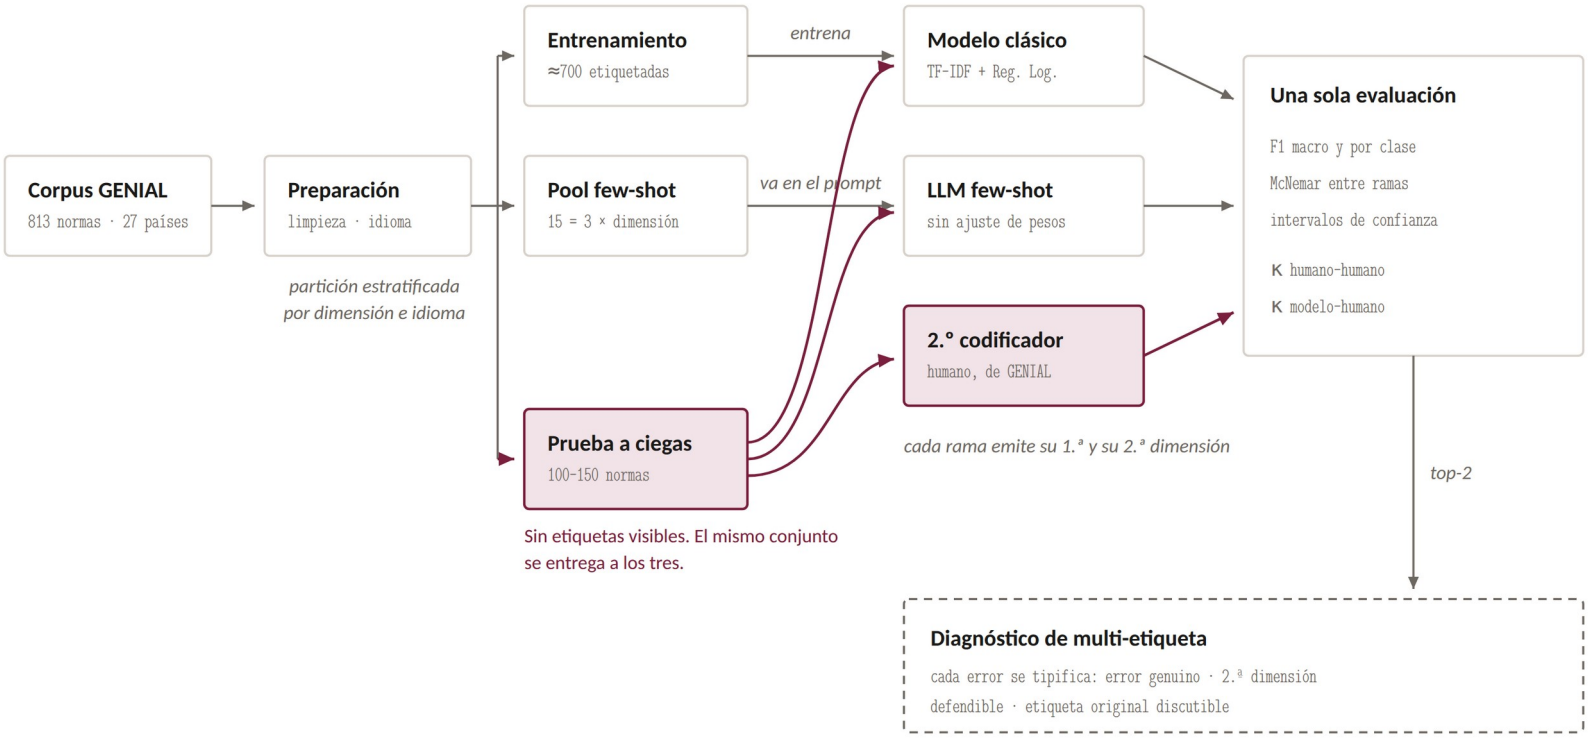
V de Cramér con Dominio: Vínculo 0.41 · Tipo de norma 0.36 · País 0.32. País ↔ Investigador 0.99.

→ Tipo de norma no entra como predictor (fuga); se convierte en línea base que el modelo debe superar.

Hallazgo de calidad	Decisión
1 valor faltante en Dominio (UNESUM, «Políticas de Privacidad»)	corrección experta documentada → Protección de Datos
14 grupos de URL repetida (30 normas; 8 con dimensiones distintas)	mismo grupo ⇒ misma partición y mismo pliegue (StratifiedGroupKFold)
Tipo de norma: 14 categorías → 11 tras normalizar capitalización	normalizada; excluida como predictor
Fecha de publicación parseable solo en 58 %	no se usa

5 Diseño experimental: del corpus al índice

Dos ramas · dos líneas base sin IA · un mismo conjunto de prueba a ciegas · una sola evaluación



Regla de ceguera: las etiquetas del conjunto de prueba se leen una sola vez, en la evaluación, después de registrar todas las predicciones.

Rama clásica

TF-IDF 1-2 gramas (5 000 feat.) + Regresión Logística, class_weight balanceado · entrena con 669 normas

Rama LLM few-shot

Definiciones + 15 ejemplos (3/dimensión) en el prompt · sin ajuste de pesos · T = 0 · 3 ejecuciones

Evaluación

F1 macro y por clase con IC95 (Wilson, bootstrap) · McNemar entre ramas (pareado) · κ modelo-humano vs κ humano-humano · top-2 → tipificación de errores · CV 5 pliegues por grupo

6 Decisión técnica: lineal interpretable vs. LLM few-shot

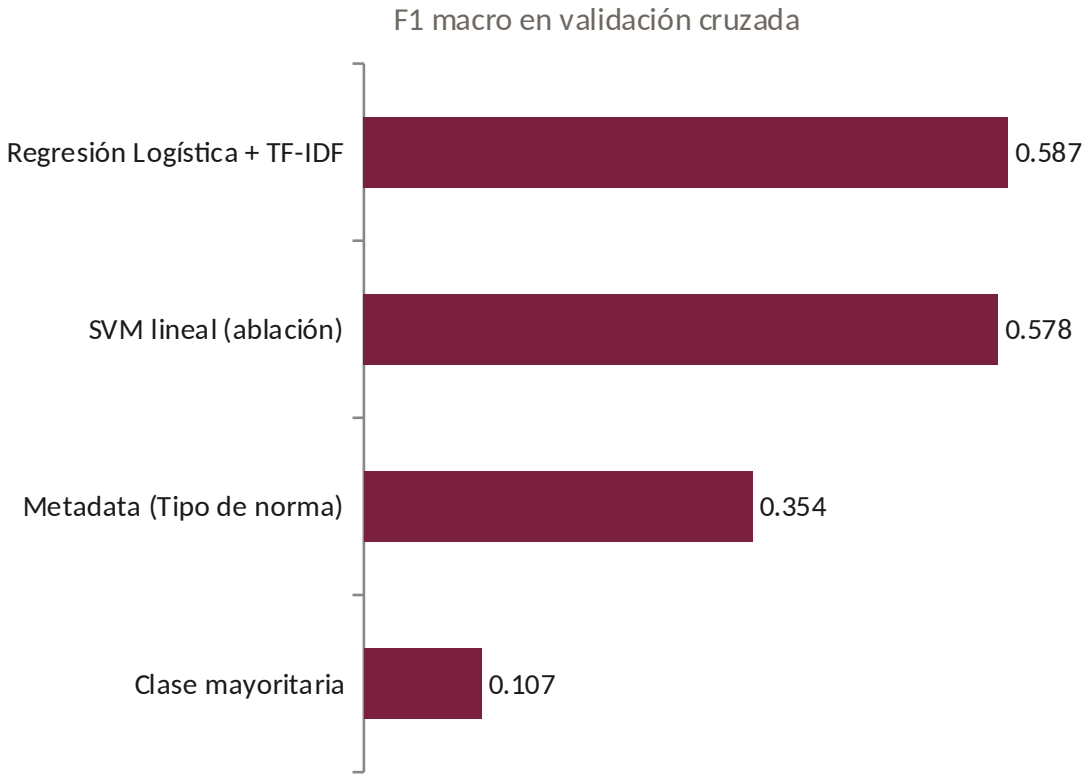
Análisis comparativo de ocho técnicas con matriz de decisión ponderada (Semana 2)

Técnica	Datos que necesita	Interpretabilidad	Costo / recursos	Decisión
Regresión Logística + TF-IDF	≈ 700 etiquetadas	pesos por término y clase; probabilidad calibrada	segundos, sin GPU, sin costo	**rama clásica ✓**
LLM few-shot	15 ejemplos	justificación en lenguaje natural; alternativa	< USD 5 por pasada; API	**rama de comparación ✓**
SVM lineal	≈ 700	pesos, sin probabilidad nativa	segundos	ablación
Random Forest / Gradient Boosting	tabulares	media	bajo	descartadas: no hay variables numéricas nativas
Transformer afinado (BETO, XLM-R)	miles por clase	baja	GPU, horas	trabajo futuro: alta varianza con 63-71 casos
Agentes / RAG	corpus + herramientas	trazas	alto	trabajo futuro

La comparación mide eficiencia de datos: si 15 ejemplos en un prompt rinden como 700 etiquetadas, el observatorio puede automatizar sin financiar horas de etiquetado. La literatura muestra que la respuesta depende del corpus (97 % en PolicyGPT frente a 47.6 % en LexGLUE): la única respuesta honesta es medirlo aquí.

7 Resultados: el modelo aprende y supera a las líneas base

Validación cruzada de 5 pliegues estratificados por grupo · n = 813 · IC95 Wilson / bootstrap (2 000)



umbral mínimo 0.60 · excelencia 0.70

0.587
F1 macro · IC95 [0.549, 0.623]

0.635
exactitud · IC95 [0.601, 0.667]

0.852
top-2: la etiqueta correcta está entre las dos propuestas

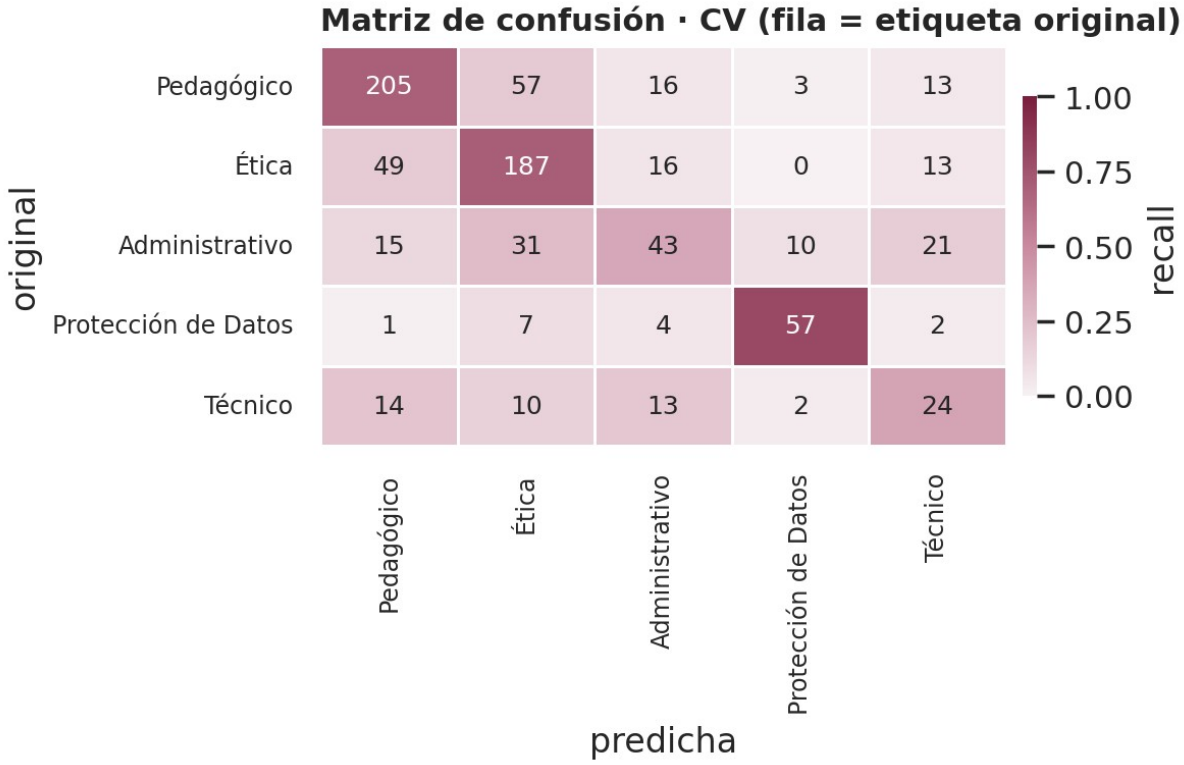
0.50
κ frente a la referencia (acuerdo moderado)

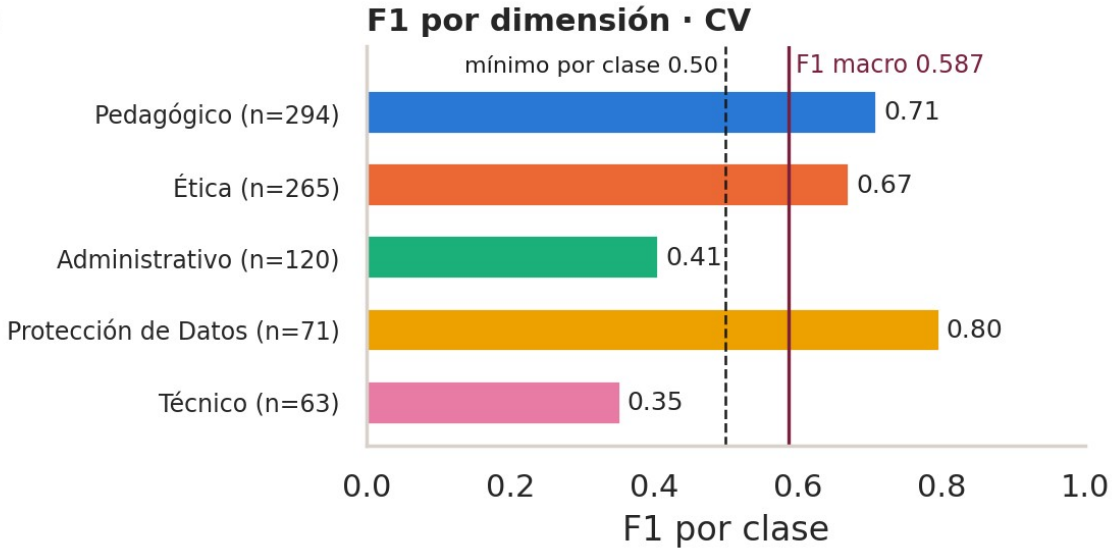
Lectura

Casi duplica el F1 de la mejor línea base sin IA; en el conjunto ciego McNemar rechaza la igualdad frente a ambas ($p < 0.001$ y $p = 0.012$). Pero el IC incluye el mínimo 0.60 y excluye la excelencia 0.70: el umbral prefijado no se alcanza.

8 Resultados por dimensión: las clases minoritarias son el límite

Matriz de confusión y F1 por clase en validación cruzada (n = 813)





Protección de Datos 0.80

vocabulario específico y estable; la mejor clase pese a 71 casos

Pedagógico 0.71 ↔ Ética 0.67

57 + 49 confusiones cruzadas: normas pedagógicas con componente ético explícito

Administrativo 0.41 · Técnico 0.35

bajo el nivel de excelencia 0.50; Técnico incumple el mínimo 0.40 y se dispersa hacia las otras cuatro

9 Ablaciones y desempeño desagregado

Una decisión a la vez · desagregación por idioma, ámbito y pista léxica (decisión metodológica 4)

Variante (CV, n = 813)	Exactitud	F1 macro	F1 Técnico
RL balanceada (elegida)	0.635	**0.587**	0.353
RL sin ponderar clases	0.622	**0.475**	**0.031**
RL balanceada, C = 3	0.637	0.581	0.327
SVM lineal balanceada, C = 0.5	0.645	0.578	0.328
RL, solo unigramas	0.620	0.576	0.366
RL, caracteres 3-5	0.609	0.573	0.350

La ponderación de clases es la única decisión que cambia el resultado: sin ella Técnico desaparece. Las demás variantes se mueven entre 0.57 y 0.59: el límite es el corpus, no un hiperparámetro.

Segmento	n	Exactitud	F1 macro
Español (título)	712	0.662	0.613
Portugués	76	0.474	0.392
Inglés	25	0.360	0.268
Ámbito institucional	563	0.671	0.592
Ámbito nacional	250	0.552	0.561
Con la pista léxica en el texto	287	**0.808**	0.687
Sin la pista léxica	526	**0.540**	0.441

El modelo generaliza más allá de la palabra que nombra la dimensión (0.54 sin ella, frente a 0.36 de la clase mayoritaria), pero menos de lo que sugiere la cifra global. Portugués e inglés se enrutan a revisión obligatoria.

10 Conjunto de prueba a ciegas: comparación pareada

n = 125 · las normas que el investigador de GENIAL codificó a ciegas · etiquetas leídas una sola vez · McNemar sobre las mismas normas

Rama	Exactitud [IC95]	F1 macro [IC95]	Top-2	κ vs referencia
Clase mayoritaria	0.360 [0.281, 0.447]	0.106 [0.087, 0.124]	—	0.00
Metadata (Tipo de norma)	0.544 [0.457, 0.629]	0.322 [0.251, 0.394]	0.608	0.32
Regresión Logística + TF-IDF	**0.688 [0.602, 0.763]**	**0.617 [0.505, 0.712]**	**0.872**	**0.56**
SVM lineal (ablación)	0.720 [0.636, 0.791]	0.646 [0.535, 0.741]	0.880	0.60
LLM few-shot	*pendiente: requiere clave de API (ejecución local)*			

McNemar (pareado)	A acierta, B falla	A falla, B acierta	valor p
RL vs clase mayoritaria	49	8	**< 0.001**
RL vs metadata	32	14	**0.012**
RL vs SVM lineal	0	4	0.13 (n. s.)

Lectura

F1 macro 0.617 en el conjunto ciego frente a 0.587 en CV: compatibles (los IC se solapan); la muestra del investigador está dominada por normas de confianza alta. Solo 10 normas técnicas (F1 0.50). SVM y RL no difieren significativamente; se mantiene la RL por sus probabilidades calibradas, necesarias para el umbral de confianza.

11

Multi-etiqueta: el top-2 rescata 6 de cada 10 errores

Observación de la tutora incorporada al diseño sin cambiar la tarea ni el índice

39
errores del modelo en las 125 normas ciegas

23
en los que la 2.ª dimensión propuesta es la referencia

59 %
de los errores rescatados por el top-2 (85 % en CV: 0.852 top-2)

Una parte sustantiva de los errores no son confusiones arbitrarias: son normas en la frontera entre dos dimensiones, sobre todo Pedagógico ↔ Ética.

Hoja de tipificación (results/hoja_tipificacion_errores_clasico.csv)	Quién la completa	Qué informa
Error genuino	codificadores GENIAL	límite real del modelo → revisión humana
Segunda dimensión defendible	codificadores GENIAL	norma de frontera → candidata a multi-etiqueta
Etiqueta original discutible	codificadores GENIAL + adjudicación	ruido en el estándar de referencia → recodificación

Cada fila de la hoja lleva la referencia, la predicción, la alternativa y —cuando existe— la etiqueta del segundo codificador. Los errores del modelo se convierten en evidencia empírica sobre la definición de las dimensiones del framework.

12

Codificación ciega: el modelo falla donde el humano dudó

Instrumento del Framework Dimensional GENIAL (D1-D6, etiquetas secundarias, confianza) sobre las 119 normas emparejadas

76 %
exactitud del modelo cuando el codificador declaró confianza ALTA (n = 91)

41 %
cuando declaró confianza MEDIA (n = 22)

0.89 vs 0.65
exactitud en normas unidimensionales (19) vs con etiquetas secundarias (100)

35 / 37
errores del modelo que caen en normas multidimensionales

Qué aporta el instrumento

- Define el conjunto de prueba: exactamente las normas que el investigador leyó a ciegas (142; 119 en la versión congelada).
- Confianza humana y etiquetas secundarias: los errores del modelo se concentran donde el humano también dudó y donde la norma toca más de una dimensión → evidencia empírica de multi-etiqueta.
- Dominio vs. framework de seis dimensiones: asociación moderada (V de Cramér 0.34 con D3, 0.28 con D4); el de seis no es una partición del de cinco.
- No recodifica Dominio: el κ humano-humano sigue pendiente (plantilla generada, 125 normas).

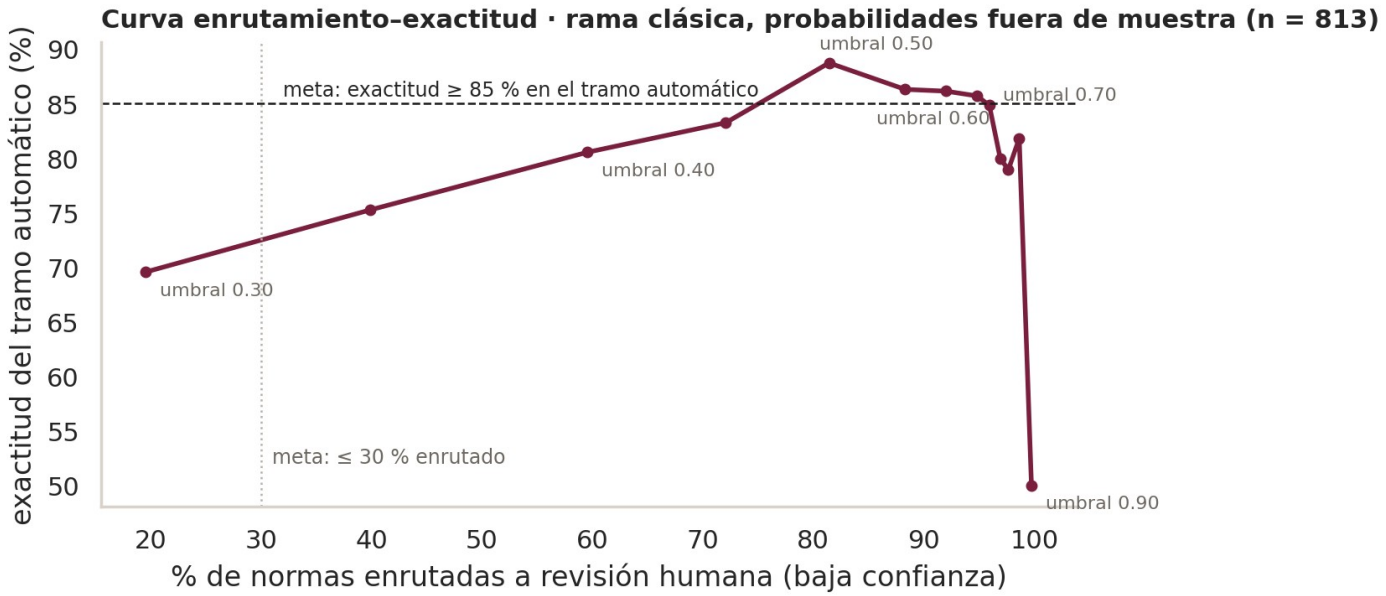
Robustez fuera de la versión congelada

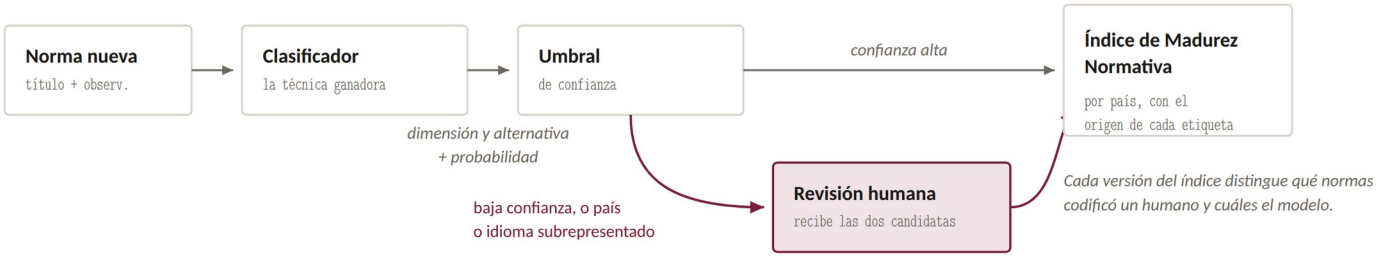
- 23 normas incorporadas a GENIAL después del corte (11 países, Caribe anglófono en su mayoría, 7 técnicas).
- Exactitud 0.39 [IC95 0.22, 0.59] · top-2 0.57 · confianza media del modelo 0.33.
- Fuera de la distribución de entrenamiento —otro idioma, otra región, la clase más débil— el modelo no es fiable: la revisión obligatoria para países < 20 normas e idiomas minoritarios queda justificada con datos.

13

Operación: codificación asistida, no automatización

Curva enrutamiento–exactitud con probabilidades fuera de muestra (n = 813) · regla de gobernanza · IMN trazable





0.50
umbral para ≥ 85 % de exactitud automática

84 %
de normas a revisión humana (meta ≤ 30 %)

21 / 136
horas-persona ahorradas por pasada (10 min/norma)

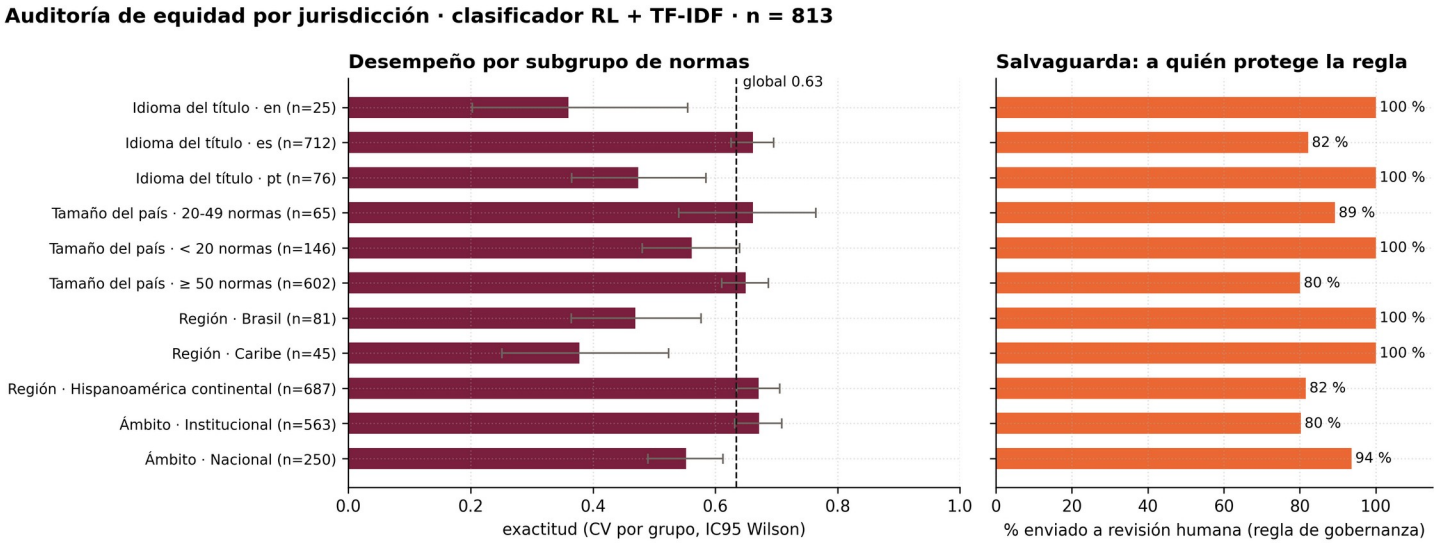
5 → 2
opciones por norma con top-2 en el 85 % de los casos

Recomendación para el observatorio

El modelo propone dos candidatas con su probabilidad; el codificador decide. Revisión obligatoria para países con < 20 normas e idiomas minoritarios. La tabla del IMN registra por país cuántas normas tienen respaldo humano y cuántas solo del modelo, con margen.

14 Impacto social y responsabilidad: escalar sin invisibilizar

Auditoría de equidad por jurisdicción (CV por grupo, n = 813) · regla de gobernanza · cadena de responsabilidad



Lo que muestra la auditoría

- El modelo rinde peor donde hay menos datos: Caribe 0.38 y Brasil 0.47 frente a 0.67 en Hispanoamérica continental; inglés 0.36 frente a español 0.66 (razón < 0.8).
- La regla de gobernanza envía a revisión humana el 100 % de esas normas; tras la auditoría se añadió el portugués (Brasil pasaba al tramo automático con exactitud 0.33).
- Los costos del sesgo se trasladan al presupuesto del observatorio, no a los países.

Stakeholders y riesgos

- Codificadores (sesgo de automatización) · coordinación GENIAL (índice con error) · países comparados (uso reputacional del ranking) · jurisdicciones pequeñas y no hispanohablantes (invisibilización) · comunidad (reutilización).
- Privacidad: el nombre del codificador es dato personal; se excluye del modelo y se anonimiza. Ley de IA de la UE: riesgo mínimo (no decide sobre personas).

Compromisos

- Auditoría de equidad en cada versión; ningún valor del IMN sin revisión humana en los grupos en riesgo.
- Cada cifra del IMN con su margen y su porcentaje de respaldo humano; model card y datasheet actualizadas.
- El modelo nunca evalúa a codificadores individuales; canal de apelación para países e IES.

15

Contraste con los umbrales prefijados y limitaciones

Los criterios se fijaron antes de ejecutar; se reportan también los que no se cumplen

Criterio prefijado	Resultado	Estado
Superar ambas líneas base con McNemar $p < 0.05$	$p < 0.001$ y $p = 0.012$	cumplido
F1 macro mínimo ≥ 0.60	CV 0.587 [0.549, 0.623] · ciego 0.617 [0.505, 0.712]	en el borde
F1 macro excelencia ≥ 0.70	IC excluye 0.70	no alcanzado
Ninguna clase con F1 < 0.40	Técnico 0.35 (Administrativo 0.41)	incumplido
κ modelo-humano ≥ 0.60	CV 0.50 · ciego 0.56 (moderado)	no alcanzado
≤ 30 % enrutado con ≥ 85 % de exactitud automática	84 % enrutado	no viable

Limitaciones

- Estándar de referencia con un solo codificador por norma: parte del error puede ser desacuerdo legítimo. El instrumento del investigador codifica seis dimensiones nuevas, no Dominio; el κ humano-humano requiere la recodificación de Dominio (plantilla lista, ≈ 30 min).
- Texto corto (mediana 44 palabras) y en parte redactado por el codificador, no por el legislador.
- Conjunto ciego pequeño (125; 10 normas técnicas) y dominado por normas de confianza alta: intervalos anchos. 23 normas nuevas del Caribe: exactitud 0.39.
- Rama LLM few-shot pendiente de ejecución (clave de API): la comparación TF-IDF vs LLM sigue abierta.
- Corpus no redistribuible: se publican hash, estadísticas agregadas y una muestra anonimizada de 40 normas.

16 Conclusiones y trabajo futuro

1 Aprende, pero no sustituye

Con 813 normas y texto corto, un lineal interpretable aprende la estructura del framework GENIAL y supera con significancia a toda heurística sin IA; no alcanza la calidad para reemplazar al codificador.

2 Asistencia y diagnóstico

Dos candidatas correctas en el 85 % de los casos, y errores que señalan normas de frontera y dimensiones cuya definición conviene revisar.

3 Rigor antes que cifra

Umbrales prefijados, intervalos de confianza y pruebas pareadas permiten decir esto con precisión, incluidos los criterios que no se cumplen.

Trabajo futuro

- **Cerrar la comparación** • ejecutar la rama LLM few-shot (3 pasadas, T = 0) y recalcular McNemar y κ
- **Más texto por norma** • incorporar el cuerpo de la norma, no solo título + observaciones
- **Medir el techo humano** • doble codificación ciega → κ humano-humano sobre el mismo conjunto
- **Multi-etiqueta explícita** • si la tipificación de errores lo justifica, tarea multi-etiqueta y ajuste del IMN

Gracias

Clasificación automática de normativa sobre IA en la educación superior de ALC · hacia un IMN escalable

Repositorio

github.com/jorgemaldonadom-cmd/genial-clasificador-normativa
código MIT · cuaderno ejecutado · síntesis de resultados · muestra anonimizada

Reproducibilidad

semilla fija · versiones fijadas · SHA-256 del corpus verificado · etiquetas de prueba leídas una sola vez · 8 pruebas unitarias

Agradecimientos

Proyecto GENIAL (Erasmus+) por el acceso al corpus
Prof. Gladys María Villegas Rugel, tutora
UEES · Maestría en Inteligencia Artificial

Jorge Javier Maldonado Mahauad · Melissa Figallo · Grupo 9 · octubre de 2026