Proyecto Integrador en IA · MIAR0545 · Video pitch · Grupo 9

Clasificación automática de normativa sobre IA en la educación superior de América Latina y el Caribe

Hacia un Índice de Madurez Normativa escalable · codificación asistida con revisión humana · corpus GENIAL (Erasmus+)

Jorge Javier Maldonado Mahauad · Melissa Figallo

Tutora: Gladys María Villegas Rugel

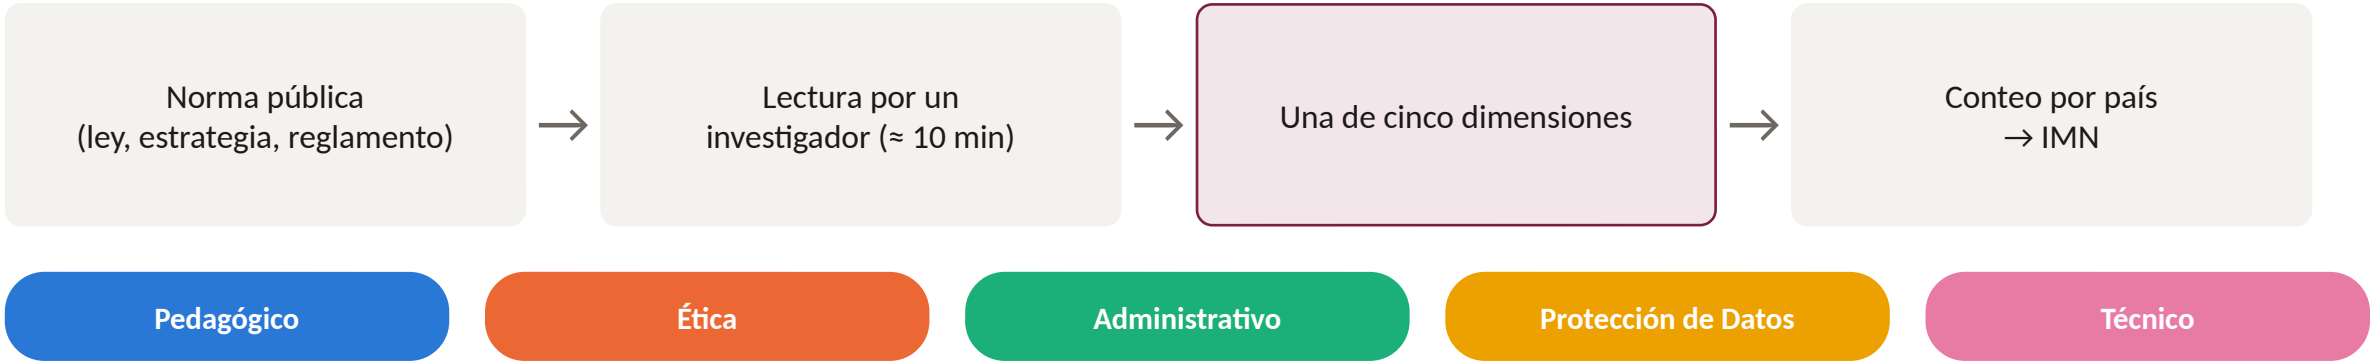
Maestría en Inteligencia Artificial · UEES · octubre de 2026

Repositorio en GitHub

github.com/jorgemaldonadom-cmd/genial-clasificador-normativa

Codificar normativa a mano no escala

Observatorio regional del proyecto GENIAL · Índice de Madurez Normativa (IMN) por país



10 min

por norma, lectura completa y criterio experto

1

codificador por norma: sin fiabilidad intercodificador

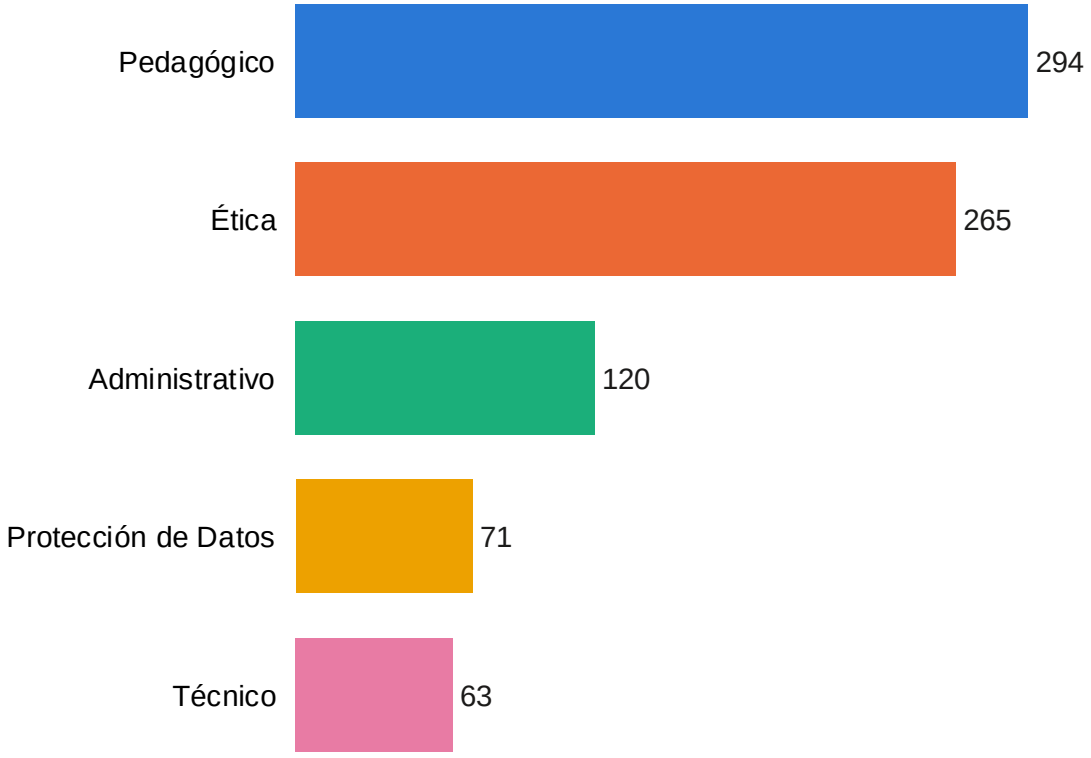
813 →

el corpus crece con cada actualización y cada país

¿Puede un modelo proponer la dimensión con calidad y trazabilidad suficientes para asistir —no sustituir— al codificador?

Los datos: 813 normas, 28 jurisdicciones, 5 clases desbalanceadas

Corpus consolidado GENIAL · versión congelada (SHA-256 verificado) · entrada = título + observaciones



Distribución de la variable objetivo (desbalance 4.7 : 1)

44

palabras de mediana por norma (texto corto)

88 %

en español · pt 76 · en 25

67 %

de las normas en 5 países (MX, CL, AR, EC, BR)

0.99

V de Cramér País ↔ Investigador

Decisiones de datos

Columna del codificador excluida y anonimizada (dato personal) · duplicados por URL agrupados · prueba ciega = 125 normas codificadas por un investigador de GENIAL, etiquetas leídas solo en la evaluación

Metodología: un modelo lineal, interpretable, validado por grupo

Elegido frente a ocho técnicas (Semana 2): con 673 ejemplos nada no lineal lo superó

1 Preprocesamiento

hash · normalización · idioma (lingua) · grupo_url · texto = título. observaciones

→

2 Representación

TF-IDF 1-2 gramas · sublinear_tf · 2 000-5 000 features

→

3 Clasificador

Regresión logística multinomial · class_weight = balanced · L2

→

4 Validación

StratifiedGroupKFold × 5 · IC Wilson / bootstrap · McNemar · κ

→

5 Prueba ciega

125 normas · investigador A de GENIAL · etiquetas ocultas hasta evaluate.py

¿Por qué lineal?

Textos de 44 palabras y 673 ejemplos: más features que ejemplos. SVM, árboles, embeddings y caracteres quedaron dentro del ruido entre pliegues (±2 pp). El lineal explica cada predicción con sus términos.

¿Por qué por grupo de URL?

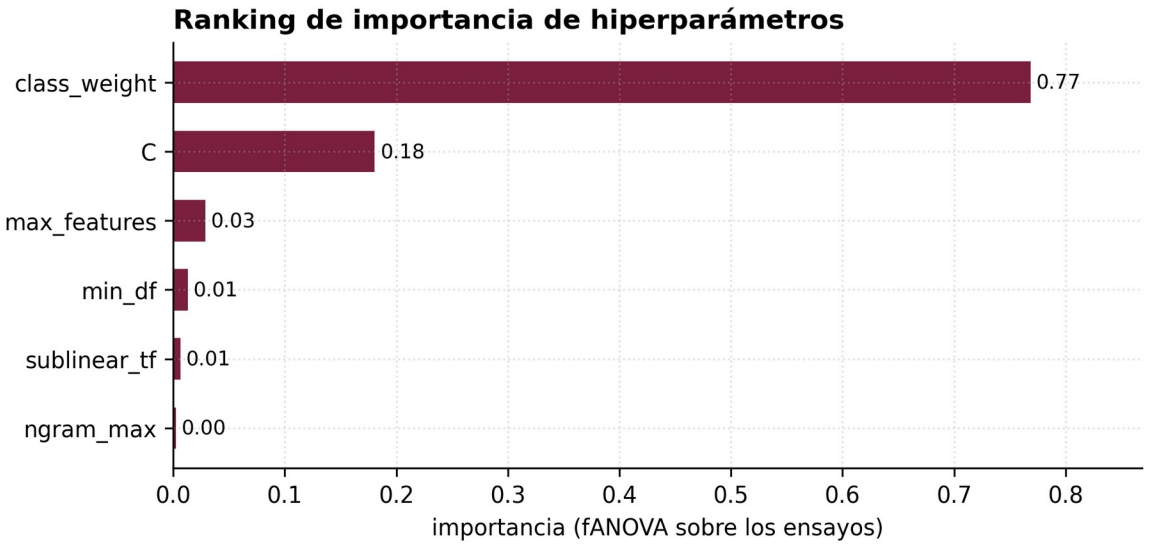
14 grupos de normas comparten URL oficial (8 con etiquetas distintas). Si cayeran a ambos lados de un pliegue, el modelo sería evaluado sobre duplicados de su entrenamiento.

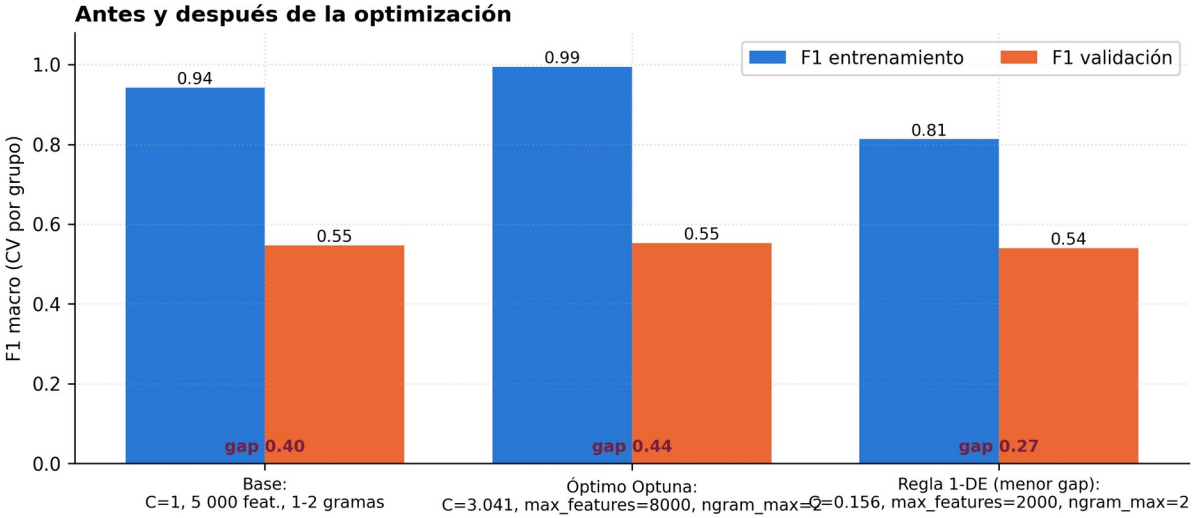
¿Por qué ese conjunto ciego?

Lo definió un instrumento externo (Framework D1-D6 del investigador), no un muestreo nuestro. Sobrerrepresenta países pequeños: prueba exigente por diseño.

Desarrollo y optimización: el sobreajuste y lo que Optuna enseñó

60 ensayos TPE · 6 hiperparámetros · importancia fANOVA · dependencia parcial · interacción C × vocabulario





Desafío

F1 0.94 en entrenamiento vs 0.55 en validación (gap 0.40). Curvas de validación planas: el error restante es de etiqueta y de muestra, no de hiperparámetros.

Hallazgo de sensibilidad

class_weight explica el 77 % de la varianza; C el 18 %; el resto mueve el F1 < 3 pp. El mejor ensayo gana +0.6 pp con más sobreajuste.

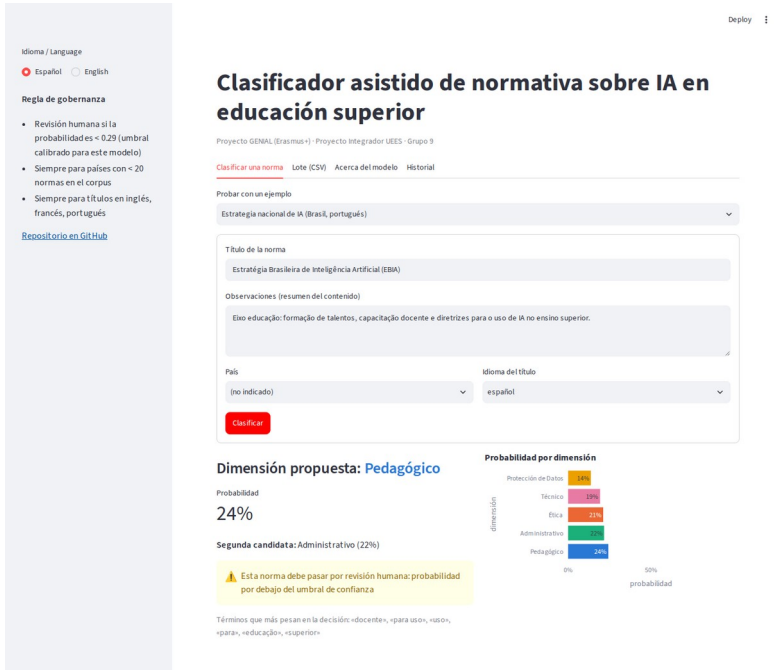
Decisión

Regla 1-DE: C = 0.157, 2 000 features → gap 0.27 con el mismo F1. Umbral de confianza calibrado por modelo (0.29) porque la regularización aplana las probabilidades.

La solución en acción

Grabación de pantalla de la aplicación real (Streamlit) · tres casos de uso + manejo de errores + lote CSV







1 · Ley de protección de datos (Chile)

Protección de Datos 42 % · aviso verde: supera el umbral · términos: «datos», «personales»

2 · Estrategia de IA (Brasil, pt)

Pedagógico 24 % · aviso amarillo: revisión humana por probabilidad baja e idioma

3 · Error y lote

Texto de 2 palabras → mensaje claro, no clasifica · CSV de 5 normas → tabla, gráfico, descarga

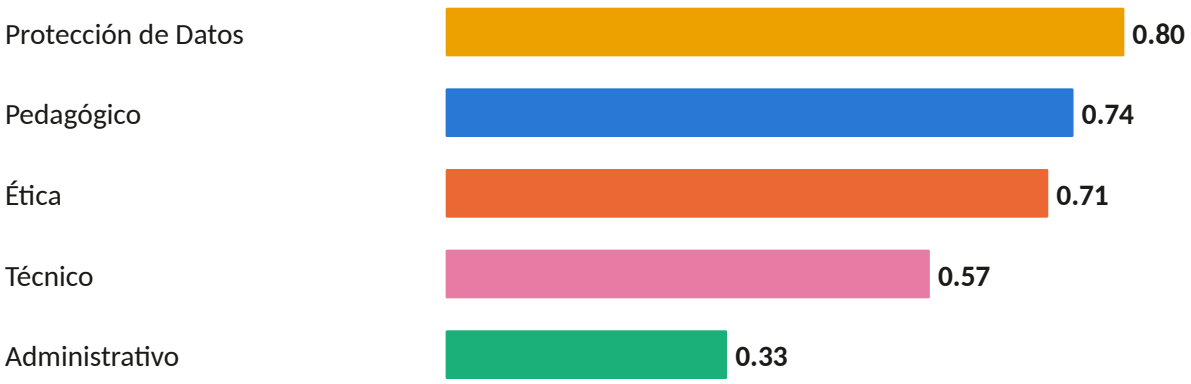
En el video, esta diapositiva se sustituye por la grabación de pantalla; se mantiene como respaldo visual.

Resultados en la prueba ciega (n = 125)

Etiquetas del investigador A · intervalos de confianza del 95 % · McNemar pareado

Rama	Exactitud [IC95]	F1 macro [IC95]	Top-2	κ
Clase mayoritaria	0.360 [0.281, 0.447]	0.106	0.360	0.00
Metadatos (tipo de norma)	0.544 [0.457, 0.629]	0.322	0.608	0.32
model_v1 (base)	0.688 [0.602, 0.763]	0.617 [0.505, 0.712]	0.872	0.56
best_model (regla 1-DE)	0.672 [0.586, 0.748]	**0.631 [0.530, 0.724]**	0.864	0.54

McNemar: vs mayoritaria p < 0.001 · vs metadatos p = 0.012 · model_v1 vs best_model p = 0.75 (n.s.)



F1 por clase · best_model

Dónde funciona

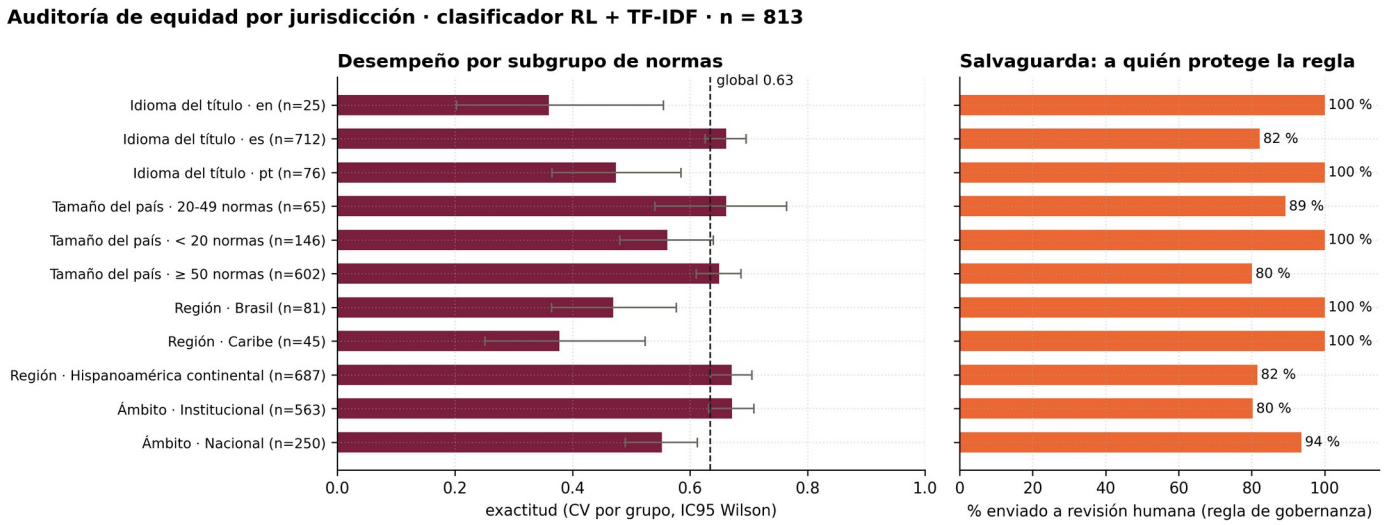
Protección de Datos (léxico propio), Pedagógico y Ética. En el 86 % de las normas la etiqueta correcta está entre las dos candidatas: espacio de decisión de 5 a 2.

Dónde no

Administrativo (F1 0.33) y Técnico comparten vocabulario con todo. Portugués 0.42 (n = 12). 35 de 37 errores revisados: normas multidimensionales donde el codificador también dudó (acierto 0.76 con confianza Alta vs 0.41 con Media).

Ética: la brecha por jurisdicción se contiene, no se oculta

Auditoría de equidad por idioma, región, tamaño de país, ámbito y codificador (anonimizado) · n = 813



Mitigaciones implementadas

- Revisión humana obligatoria: pt / en / fr, países < 20 normas, probabilidad < umbral → 100 % de esos grupos con respaldo humano
- Nombre del codificador excluido y anonimizado; corpus e instrumento fuera del repositorio
- Modelo explicable (términos, probabilidades, motivos); model card y datasheet
- Ninguna cifra del IMN sin % de respaldo humano y margen

Sesgos identificados

Geográfico (5 países = 67 %), de idioma (es 0.66 · pt 0.47 · en 0.36), de clase, de etiqueta única y de codificador. Razón mínima 0.54: no cumple la regla 4/5.

Impacto social

Un IMN con etiquetas automáticas subestimaría a Brasil, el Caribe y los países pequeños: los que el observatorio quiere visibilizar.

Limitaciones reconocidas

n = 125 en prueba (IC ± 9 pp) · etiqueta única donde la tarea es multi-etiqueta · κ humano-humano pendiente · riesgo mínimo bajo el AI Act, sin decisiones sobre personas

7. CIERRE · 4:45 – 5:00

Codificación asistida, reproducible, auditada y desplegada

F1 0.63 · κ 0.54 supera las líneas base (p < 0.05) en prueba ciega

Regla de gobernanza dice dónde no debe usarse: pt/en/fr, países pequeños, baja confianza

Reproducible hash del corpus, semilla, cuadernos 00-05 ejecutados, 14 pruebas, CI

Trabajo futuro multi-etiqueta · más normas del Caribe · κ humano-humano · rama LLM

Repositorio GitHub
jorgemaldonadom-cmd/
genial-clasificador-normativa

QR de la aplicación
(se genera al publicar en Streamlit Community Cloud)

Aplicación web
…streamlit.app

Jorge Javier Maldonado Mahauad · Melissa Figallo · Grupo 9 · Maestría en IA · UEES · 2026 · Gracias